

Notas de Clase: Econometría II

Regresión Multivariada, Modelos No Lineales y otras herramientas del análisis de datos

Benjamín Oliva ¹

Jésica Tapia ²

Omar Alfaro ³

Draft Febrero 2025

¹benjov@ciencias.unam.mx y <https://github.com/benjov>

²jesticatapia@gmail.com y <https://github.com/>

³omarxalpha@gmail.com

Documento siempre en proceso de mejora.
Comentarios, siempre serán bienvenidos...

Índice general

1. El concepto de esperanza condicional y su relación con la econometría	3
1.1. Introducción	3
1.2. Esperanza condicional y algunas de sus propiedades	5
1.3. Efectos Marginales	9
1.3.1. Ejercicios	10
1.4. Introducción a Gráficos Acíclicos Dirigidos o Directed Acycle Graphical	10
2. Teoría de convergencia asintótica	15
2.1. Convergencia de sucesiones	15
2.2. Convergencia en probabilidad y acotamientos en probabilidad	16
2.3. Convergencia en distribución	17
2.4. Teoremas límite para muestras aleatorias	18
2.5. Estimadores y estadísticas de prueba	18
3. Estimación de modelos lineales de una sola ecuación por el método de Mínimos Cuadrados Ordinarios	21
3.1. El estimador de Mínimos Cuadrados Ordinarios (MCO) y el análisis clásico de regresión	21
3.2. Bondad de ajuste	25
3.3. Modelos lineales y algunas de sus propiedades	28
3.4. Propiedades asintóticas de los estimadores de MCO	30
3.5. Inferencia asintótica bajo MCO	32
3.6. Ejercicios	40
4. Estimación de modelos lineales de una sola ecuación por el método de Variables Instrumentales	45

4.1.	Introducción y motivación	45
4.2.	Estimación por Mínimos Cuadrados en Dos Etapas – 2SLS . .	46
4.3.	Método de Variables Instrumentales en casos con múltiples instrumentos	47
4.4.	Ejercicios	50
5.	Estimación de sistemas de ecuaciones por el por el método de Mínimos Cuadrados Ordinarios y Mínimos Cuadrados Generalizados	55
5.1.	Introducción a Sistemas de Ecuaciones	55
5.2.	Estimación de Sistemas de Ecuaciones Multivariantes	57
5.3.	Mínimos Cuadrados Generalizados	59
5.4.	Estimación de Sistemas de Ecuaciones con Variables Instru- mentales	63
5.4.1.	Estimación de un sistema por Mínimos Cuadrados en Dos Etapas (2SLS)	65
5.4.2.	Estimación de un sistema por Mínimos Cuadrados en Tres Etapas (3SLS)	65
5.5.	Ejercicios	66
6.	Modelos de Datos Panel	67
6.1.	Introducción y motivación	67
6.2.	Modelos y métodos de estimación	68
6.2.1.	Efectos Fijos	69
6.2.2.	Efectos Aleatorios	71
6.2.3.	Regresión Pool	72
6.2.4.	Pruebas para seleccionar modelo	73
6.3.	Conclusión	74
7.	Métodos de estimación basados en verosimilitud	75
7.1.	Introducción	75
7.2.	Marco general de estimación por máxima verosimilitud	77
7.3.	Pruebas de hipótesis	78
8.	Estimación de modelos no lineales	79
8.1.	Modelos de respuesta binaria	79
8.1.1.	Planteamiento general	79
8.1.2.	Algunos planteamientos adicionales	80

8.1.3.	Modelos Logit y Probit	80
8.1.4.	Estimación	82
8.2.	Modelos de respuesta multinomial y ordenada	83
8.2.1.	Modelos de respuesta multinomial	83
8.2.2.	Modelos de respuesta ordenada: Logit y Probit Ordinal	85
8.2.3.	Regresión logística con información de videojuegos. . .	89
8.3.	Modelos de conteo y otras respuestas	96
8.3.1.	Modelos de conteo del tipo Poisson	96
9.	Modelos con datos truncados, censurados, con endogeneidad por selección de muestra y otros casos	99
9.1.	Truncamiento	99
9.2.	Datos con censura	106
10.	Introducción a inferencia causal	109
10.1.	Estimación de modelos para determinar efectos de tratamiento	109
10.1.1.	Motivación del procedimiento Difference - in - Differences (DiD)	109
10.1.2.	Estrategia de estimación	110
10.2.	Control Sintético	113
10.2.1.	Motivación	113
10.2.2.	Planteamiento del método de estimación	115
10.2.3.	¿Por qué usar el control sintético?	117
11.	Estimación de modelos de duración	119
12.	Introducción al Aprendizaje Estadístico	121
12.1.	Motivación, introducción y Notación en el análisis de regresión	121
12.2.	Modelos no lineales	123
12.2.1.	Regresión exponencial	124
12.2.2.	Regresión logarítmica	124
12.2.3.	Funciones logísticas	125
12.2.4.	Funciones polinomiales	127
12.3.	Aprendizaje Estadístico	128
12.3.1.	Ajuste y separación del conjunto de datos	130
12.3.2.	Método de regresiones restringidas (Shrinkage methods).	131
12.4.	Aplicación de modelos clasificación mediante clustering. . . .	134
12.4.1.	Análisis de Componentes Principales	134

12.4.2. Análisis Factorial	136
12.4.3. Clúster	136
12.4.4. Agrupamiento de datos de series temporales	142
12.5. Aplicación de modelos de regresión de respuesta binaria	149
12.5.1. Modelos de respuesta binaria	149
12.5.2. Modelos de respuesta multinomial y ordenada	153
12.5.3. Regresión logística con información de videojuegos. . .	160
12.6. Modelos de árboles de decisión y bosques aleatorios.	167
12.6.1. Métodos basados en árboles	167
12.7. Modelos de redes neuronales.	170
12.7.1. Introducción y Motivación	170
12.7.2. Algunos conceptos relevantes	170
12.7.3. Preprocesamiento de datos	175
12.7.4. Entrenamiento del modelo	175
Bibliografía	177
A. Algunos resultados importantes	179

Índice de figuras

1.1. Ejemplo 1 de un DAG	11
1.2. Ejemplo 2 de un DAG, confusor	11
1.3. Ejemplo 3 de un DAG, ganancias de la educación	12
1.4. Ejemplo 4 de un DAG, IV estimator	13
4.1. Instrumentación de la información de la demanda y la oferta, respectivamente	52
8.1. Probabilidades en un modelo de respuesta ordenada, conside- rando $J = 4$ (retomado de Greene (2012, 788) [Gre12])	91
8.2. En la tabla de datos ubicamos 417 tags distintas	96
9.1. ¿Talento y la belleza están negativamente correlacionados? . .	100
9.2. Relación entre belleza y talento, retomado de [Cun21].	101
10.1. Comparación de los casos de cólera según proveedor de agua en Londres.	112
12.1. ¿Qué relación hay entre años de educación y el salario?, reto- mado de: https://wol.iza.org/articles/using-linear-regression-to-establish-empirical-relationships-between-education-and-earnings?lang/es	122
12.2. Funciones exponenciales, Retomado de Larsen y Marx (2012, p. 532) [LARSEN]	125
12.3. Funciones logarítmicas, Retomado de Larsen y Marx (2012, p. 536) [LARSEN]	126
12.4. Funciones logísticas, Retomado de Larsen y Marx (2012, p. 540) [LARSEN]	126
12.5. Funciones polinomiales, retomado de https://discdown.org/flexregression/smoothreg.html	128

12.6. División del conjunto de datos, retomado de Hastie, Tibshirani, y Friedman (2017, p. 222) [HTF17]	131
12.7. US Arrest Hierarchical Clustering, retomado de Chang (2020, p 216) [Cha20]	138
12.8. K-Means algorithm, retomado de Ng (2023, p 146) [NG]	140
12.9. Agglomerative Clustering Algorithm and Dendrogram, retomado de Chang (2020, p 219) [Cha20]	141
12.10 División del conjunto de datos, retomado de Hastie, Tibshirani, y Friedman (2017, p. 222) [HTF17]	159
12.11 Probabilidades en un modelo de respuesta ordenada, considerando $J = 4$ (retomado de Greene (2012, 788) [Gre12])	162
12.12 En la tabla de datos ubicamos 417 tags distintas	167
12.13 Ejemplo de regiones. Retomado de Hastie et al (2017, 305)	168
12.14 Ejemplo de árbol. Retomado de Hastie et al (2017, 304)	169
12.15 Ejemplo de redes neuronales. Retomado de Shmueli et al (2019, 285) [Shm+19]	171
12.16 Ejemplo de la función de activación Sigmoide. Retomado de Jurafsky, et al (2024, Cap. 7, p.2) [JM23]	172
12.17 Ejemplo de la función de activación <i>tanh</i> . Retomado de Jurafsky, et al (2024, Cap. 7, p.4) [JM23]	173
12.18 Ilustración de una unidad neuronal. Retomado de Jurafsky, et al (2024, Cap. 7, p.3) [JM23]	174
12.19 Ilustración de una red neuronal con 1 capa oculta. Retomado de Jurafsky, et al (2024, Cap. 7, p.1) [JM23]	174

Índice de cuadros

3.1. Resultados de la regresión de salarios	42
10.1. Tabla XII de Snow (1854)–Casos de cólera en Londres por cada 10,000 habitantes según proveedor de agua, retomado de Cunningham(2021, p. 472) [Cun21]	111
12.1. Matriz de Confusión	159

Introducción, motivación y alcance del documento

Queremos discutir los documentos de la bibliografía como: Adams (2020) [Ada20], Cameron y Trivedi (2005) [CT05]; Cunningham (2021) [Cun21]; Greene (2012) [Gre12], Hastie, Tibshirani y Friedman (2017) [HTF17], James, Witten, Hastie y Tibshirani (2013) [Jam+13], y Wooldridge (2010) [Woo10]. Asimismo, discutir diversos papers relacionados.

Conocimientos previos

Preferentemente Econometría I y obligatoriamente Estadística II, Introducción a la Econometría o sus equivalentes.

Recursos en línea y otros materiales

Direcciones del GitHub, recomendaciones de cursos en línea, materiales recomendados y demás recursos para el autoaprendizaje.

1

El concepto de esperanza condicional y su relación con la econometría

1.1. Introducción

El objetivo del análisis empírico en las ciencias sociales es determinar cuál es el efecto o cambio que una variable causa en otra. Por ejemplo, cuando pensamos en qué factores o variables determinan el nivel salarial promedio de las personas es posible que relacionemos el efecto que tienen los años de estudio y en particular el efecto que tiene un año adicional de estudio. Otro ejemplo puede presentarse cuando tratamos de entender el efecto que tienen las horas de estudio en las calificaciones finales de un grupo de estudiantes.

Dentro del análisis empírico se suele hacer uso de dos términos o conceptos:

1. *Ceteris paribus*
2. *Causalidad*

El primero se emplea en el análisis empírico para establecer que el efecto de una variable se sostiene siempre que asumamos que el resto de variables que pueden afectar a dicha variable que queremos explicar permanecen constantes. El segundo sirve para entender que en el análisis empírico la existencia de correlaciones no significa la presencia de causalidad. La causalidad, en la primera parte del curso, será la condición observada entre dos variables y

deriva de la construcción teórica, modelación o racionalización que hagamos de los fenómenos que queremos analizar. Más adelante modificaremos esta condición.

Tanto *ceteris paribus* como causalidad son conceptos contenidos en lo que en estadística se conoce como **esperanza condicional**. Supongamos dos variables, y y x , que tienen una distribución conjunta y para las cuales queremos estimar el efecto que tiene la segunda en la primera. Así, es posible que utilicemos una expresión de la esperanza condicional de y en x , misma que solemos representar como:

$$\mathbb{E}[y|x, \mathbf{C}] \tag{1.1}$$

Donde $\mathbf{C}$ representa un conjunto o vector de variables de control, en el sentido de que también explican la variabilidad de y por lo que no podemos omitirlas en un proceso de estimación de la esperanza condicional.

Dicho lo anterior, el análisis empírico que proponemos en este curso está basado en identificar correlaciones que pueden ser interpretadas como causalidad y que consiste en estimar a la ecuación (1.1) y determinar el efecto marginal o efecto parcial que tiene x en y , condicional en que todas las demás variables permanecen constantes, es decir, *ceteris paribus*.

En la ecuación (1.1) hemos asumido que $\mathbf{C}$ contiene la información disponible que sirve de control, por lo que es un vector que contiene sólo información que es observable. Sin embargo, no siempre es posible observar toda la información que sirve de control. Por ejemplo, al responder qué factores determinan el salario de las personas podríamos pensar en múltiples factores cuantificables y observables como: edad, sexo, años de educación, etc. No obstante, también consideraríamos factores como las habilidades propias de cada individuo, las cuales no son necesariamente observables.

Adicionalmente, en el proceso de estimación de la ecuación (1.1) asumiremos que las muestras de datos que utilizaremos son muestras aleatorias de la población. En concreto asumiremos que la información es una muestra aleatoria independiente e idénticamente distribuida (iid) que proviene de una población dada.

Para finalizar esta sección introductoria plantearemos los tres casos que ejemplifican los tipos de datos que son comúnmente analizados en el análisis de regresión o econometría. El primero es un análisis de datos de sección cruzada en el que las ecuaciones representativas de la ecuación (1.1) son

como la siguiente:

$$\ln(\text{Salario}_i) = \beta_0 + \beta_1 \text{Educacion}_i + \beta_2 \text{Experiencia}_i$$

Donde las variables de Salario_i , Educacion_i y Experiencia_i son observadas para cada uno de los individuos en la muestra es indexado por $i = 1, 2, 3, \dots, N$.

El segundo ejemplo es respecto de datos de series de tiempo como la siguiente expresión:

$$\ln(\text{PIB}_t) = \beta_0 + \beta_1 \text{Empleo}_t + \beta_2 \text{Salarios}_t$$

Donde las variables PIB_t , Empleo_t y Salarios_t son observadas para un individuo o entidad a lo largo de una muestra del tiempo indexada por $t = 1, 2, 3, \dots, T$.

El tercer ejemplo resulta de la combinación de los dos anteriores. De esta forma podríamos observar a una muestra de un conjunto de individuos a lo largo del tiempo y analizar el comportamiento de una variable através de una ecuación como la siguiente:

$$\ln(\text{Salario}_{it}) = \beta_0 + \beta_1 \text{Educacion}_{it} + \beta_2 \text{Experiencia}_{it}$$

Donde las variables Salario_{it} , Educacion_{it} y Experiencia_{it} se observan para los mismos individuos a lo largo del tiempo que se indexan con los pares (i, t) , $i = 1, 2, 3, \dots, N$ y $t = 1, 2, 3, \dots, T$.

1.2. Esperanza condicional y algunas de sus propiedades

En primer lugar estableceremos un poco de notación. En análisis de regresión siempre partimos de una representación de una ecuación lineal como:

$$y_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \dots + \beta_K x_{iK} + \varepsilon_i$$

Donde cada una de las variables y_i , x_{ik} y ε_i , se observan para $i = 1, 2, 3, \dots, N$ y $k = 1, 2, \dots, K$, por lo que podremos utilizar una representa-

ción para cada i de la forma:

$$\begin{aligned}
 y_i &= \begin{pmatrix} x_{i1} & x_{i2} & \dots & x_{iK} \end{pmatrix} \begin{pmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_K \end{pmatrix} + \varepsilon_i \\
 &= \mathbf{X}'_i \boldsymbol{\beta} + \varepsilon_i
 \end{aligned} \tag{1.2}$$

En forma general la ecuación (12.2) se puede generalizar para el total de elementos en la muestra como:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} \tag{1.3}$$

Donde:

$$\begin{aligned}
 \mathbf{Y} &= \begin{pmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_N \end{pmatrix} \\
 \mathbf{X} &= \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1K} \\ x_{21} & x_{22} & \dots & x_{2K} \\ x_{31} & x_{32} & \dots & x_{3K} \\ \vdots & \vdots & \dots & \vdots \\ x_{N1} & x_{N2} & \dots & x_{NK} \end{bmatrix} \\
 \boldsymbol{\beta} &= \begin{pmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \\ \vdots \\ \beta_K \end{pmatrix} \\
 \boldsymbol{\varepsilon} &= \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \varepsilon_3 \\ \vdots \\ \varepsilon_N \end{pmatrix}
 \end{aligned}$$

En la mayoría de los casos analizados vamos a asumir que la ecuación (12.1) tiene un término constante, por lo que $x_{i1} = 1$ para todo $i = 1, 2, \dots, N$. Bajo este escenario, representaremos la matriz $\mathbf{X}$ con una columna compuesta del número 1 (uno) en todas sus entradas, tal que, el parámetro β_1 es un término constante en las ecuaciones (12.2) y (1.3). De esta forma la matriz anteriormente mostrada se puede ver como:

$$\mathbf{X} = \begin{bmatrix} 1 & x_{12} & \dots & x_{1K} \\ 1 & x_{22} & \dots & x_{2K} \\ 1 & x_{32} & \dots & x_{3K} \\ \vdots & \vdots & \dots & \vdots \\ 1 & x_{n2} & \dots & x_{nK} \end{bmatrix}$$

De forma similar al caso de una regresión lineal que incluye un término constante, podemos construir matrices $\mathbf{X}$ para casos en que alguna de las variables explicativas es dicotómica –que toma valores de 0 y 1– y casos en los que las variables explicativas han sido interactuadas –multiplicada entre sí– o transformadas mediante potencias o logaritmos.

Retomando las ecuaciones (12.1) y (1.3) y para facilitar la exposición no utilizaremos el índice i , plantearemos la siguiente definición de esperanza condicional.

Definición 1.1 *Sea y una variable aleatoria, la cual referiremos como la variable explicada o variable dependiente. Asimismo, sea $(x_1, x_2, \dots, x_K)$ un vector aleatorio de dimensión $K \times 1$ de variables explicativas. Finalmente, asumamos que $\mathbb{E}[|y|] < \infty$. Entonces, existe una función $\mu : \mathbb{R}^{K+1} \rightarrow \mathbb{R}$ tal que:*

$$\mathbb{E}[y|x_1, x_2, \dots, x_K] = \mu(x_1, x_2, \dots, x_K)$$

La función $\mu(x_1, x_2, \dots, x_k)$ determinará o describirá como el valor promedio de y cambia cuando observamos un cambio de alguno de los valores del conjunto $(x_1, x_2, \dots, x_k)$. Por ejemplo, cuando analizamos el efecto de la educación, la experiencia o el coeficiente IQ en el salario podríamos establecer:

$$\mathbb{E}[\text{Salario} | \text{Educacion}, \text{Experiencia}, \text{IQ}]$$

Esta expresión describe el salario promedio dadas las variables aleatorias mencionadas. Ahora bien, tomemos una definición del concepto de ecuación

de regresión y veamos como se relaciona con el concepto de esperanza condicional.

Definición 1.2 Sea $f(x_1, x_2, \dots, x_K, y)$ una función de densidad de probabilidad conjunta de $K + 1$ variables aleatorias, la regresión multivariada consiste en determinar la función de densidad condicional de y dado $X_1 = x_1, X_2 = x_2, \dots, X_K = x_K$ y entonces evaluar la integral (o la suma en el caso discreto) dada por:

$$\begin{aligned}\mu_{y|x_1, x_2, \dots, x_K} &= \mathbb{E}[y|x_1, x_2, \dots, x_K] \\ &= \int_{-\infty}^{\infty} y \cdot w(y|x_1, x_2, \dots, x_K) dy\end{aligned}$$

Donde:

$$w(y|x_1, x_2, \dots, x_K) = \frac{f(x_1, x_2, \dots, x_K, y)}{g(x_1, x_2, \dots, x_K)}$$

$$g(x_1, x_2, \dots, x_K) = \int_D f(x_1, x_2, \dots, x_K, y) dy$$

Visto de esta manera es claro que la Definición 1.1 es equivalente a la Definición 1.2. En nuestro caso particular para propósito de este curso asumiremos la siguiente equivalencia de la esperanza condicional:

$$\mu_{y|x_1, x_2, \dots, x_K} = \mu(x_1, x_2, \dots, x_K) = \mathbb{E}[y|x_1, x_2, \dots, x_K]$$

Note que la expresión anterior implica, como mostraremos más adelante, que $\mathbb{E}[\varepsilon|x_1, x_2, \dots, x_K] = \mathbb{E}[\varepsilon] = 0$. Veamos algunos ejemplos de las formas funcionales de la esperanza condicional $\mu(x_1, x_2, \dots, x_K)$:

1. $\mathbb{E}[y|x_1, x_2, \dots, x_K] = x_1\beta_1 + x_2\beta_2 + \dots + x_K\beta_K$
2. $\mathbb{E}[y|x_1, x_2, \dots, x_K] = x_1\beta_1 + x_2\beta_2 + \dots + x_K\beta_K + x_{K+1}^2\beta_{K+1}$
3. $\mathbb{E}[y|x_1, x_2, \dots, x_K] = e^{\beta_1 + \ln(x_2)\beta_2 + \dots + \ln(x_K)\beta_K}$, con $y > 0$ y $x_k > 0$, para todo $k = 1, 2, \dots, K$

1.3. Efectos Marginales

Una vez definida la esperanza condicional podemos, asu vez, definir el concepto de Efecto Parcial o Efecto Marginal de y –variable dependiente– cuando existe algún cambio de sólo una de las variables explicativas en el vector $(x_1, x_2, \dots, x_K)$, manteniendo el resto de las variables constantes.

Definición 1.3 *Decimos que el Efecto Marginal de una variable x_k como la derivada parcial dada por:*

$$\begin{aligned} EMg_k &= \frac{\partial \mathbb{E}[y|x_1, x_2, \dots, x_K]}{\partial x_k} \\ &\approx \frac{\Delta \mathbb{E}[y|x_1, x_2, \dots, x_K]}{\Delta x_k} \end{aligned}$$

Cuando la variable x_k es discreta o, más concretamente, dicotómica, por ejemplo, tomando valores de 0 o 1, el Efecto Marginal estará definido como sigue:

Definición 1.4 *Decimos que el Efecto Marginal de una variable dicotómica $x_1 = \{0, 1\}$ (caso extendible a cualquiera de la variables explicativas) como la diferencia dada por:*

$$EMg_1 = \mathbb{E}[y|x_1 = 1, x_2, \dots, x_K] - \mathbb{E}[y|x_1 = 0, x_2, \dots, x_K]$$

Las Definiciones 1.3 y 1.4 pueden particularizarse y extenerse en casos como el siguiente. Asumamos que el valor esperado tiene la forma funcional siguiente:

$$\mathbb{E}[y|x_1, x_2, \dots, x_K] = e^{\beta_1 + \beta_2 \ln(x_2) + \dots + \beta_K \ln(x_K)}$$

En este caso podríamos hacer la siguiente transformación:

$$\ln(\mathbb{E}[y|x_1, x_2, \dots, x_K]) = \beta_1 + \beta_2 \ln(x_2) + \dots + \beta_K \ln(x_K)$$

De esta manera podríamos aproximar el Efecto Marginal de $\ln(x_2)$ como:

$$\begin{aligned} \frac{\partial \ln(\mathbb{E}[y|x_1, x_2, \dots, x_K])}{\partial \ln(x_2)} &= \beta_2 \\ &= \frac{\frac{\partial \mathbb{E}[y|x_1, x_2, \dots, x_K]}{\mathbb{E}[y|x_1, x_2, \dots, x_K]}}{\frac{\partial \ln(x_2)}{x_2}} \end{aligned} \quad (1.4)$$

Así resulta evidente que la ecuación (1.4) se puede interpretar como una elasticidad.

1.3.1. Ejercicios

Para finalizar establezcamos una serie de ejercicios para continuar con la discusión del Efecto Marginal.

1. Sean y , x_1 y x_2 variables aleatorias y una forma funcional de la esperanza condicional de la forma:

$$\mathbb{E}[y|x_1, x_2] = \beta_1 + \beta_2 x_1 + \beta_3 x_2^2 + \beta_4 x_1 x_2$$

Al respecto, determine el Efecto Marginal de x_1 y x_2 .

2. Sean y , x_1 y $D = \{0, 1\}$ variables aleatorias y una forma funcional de la esperanza condicional de la forma:

$$\mathbb{E}[y|x_1, D] = e^{\beta_1 + \beta_2 x_1 + \gamma D}$$

Al respecto, determine el Efecto Marginal de x_1 y $D = \{0, 1\}$.

1.4. Introducción a Gráficos Acíclicos Dirigidos o Directed Acycle Graphical

La notación de los Gráficos Acíclicos Dirigidos (DAG) representa que la causalidad va en una dirección, así para mostrar causalidad en reversa es necesario crear múltiples nodos. La simultaneidad, tal como en el caso de las curvas de oferta y demanda, no tiene una representación directa o inmediata con los GAGs.

Otra forma plantear a los DAG es que se trata de una explicación de un fenómeno en términos de contrafactuales.

Definición 1.5 *Un DAG es una representación gráfica de una cadena de efectos causales. Los efectos causales están en sí mismos basados en algún proceso subyacente no observable.*

Los efectos causales pueden observarse en dos vías:

1. Directa: $D \longrightarrow Y$




Figura 1.1: Ejemplo 1 de un DAG




Figura 1.2: Ejemplo 2 de un DAG, confusor

2. Indirecta, a través de una tercer variable: $D \longrightarrow X \longrightarrow Y$

En este setido, la ausencia de $\longrightarrow$ indica que no hay relación entre las variables.

Un ejemplo sencillo de DAG es el siguiente:

El DAG mostrado en la Figura (1.1) ilustra que hay una ruta directa de D a Y , lo cual representa un efecto causal. Por su parte la ruta a D tiene una ruta trasera (backdoor path) a través de la ruta $D \longleftarrow X \longrightarrow Y$. En este caso consideremos que la ruta directa es un efecto causal, pero la backdoor path es no causal. En su caso este proceso crea una correlación espúrea entre D y Y .

Pensemos el proceso de ruta trasera como una situación en la que a veces cuando D toma diferentes valores, Y toma diferentes valores debido a que X toma diferentes valores. De esta forma, decimos que existe una correlación espuria entre D y Y .

Un segundo ejemplo de una DAG que nos permite ilustrar el concepto de confusor, el cual describe a una variable que no es observable, U , y que representamos su relación en el DAG con líneas punteadas de la forma que se muestra en la Figura (1.2).

De forma similar al caso anterior, existen dos formas para ir de D a Y . Existe la ruta directa de D a Y , lo cual representa un efecto causal. Por su parte la ruta a D tiene una ruta trasera a través de la ruta $D \longleftarrow U \longrightarrow Y$, pero con la diferencia de que la variable U es no observable.




Figura 1.3: Ejemplo 3 de un DAG, ganancias de la educación

Veamos otro ejemplo. Una pregunta clásica en economía laboral es si la educación, en general, tiene el potencial de incrementar los ingresos laborales de las personas. La teoría económica indica que la educación incrementa el producto marginal del trabajo, de esta forma los trabajadores serán mejor pagados, ya que sus salarios son establecidos en función de su producto marginal en mercados competidos. Así, la teoría afirma que la educación incrementa los ingresos.

Particularicemos el ejemplo a un caso en el cual analizamos el efecto que tiene la educación secundaria en los ingresos. Partamos del hecho de que educarse a un nivel secundario no es un fenómeno aleatorio, puesto que existen múltiples factores que lo pueden explicar. Partamos de el siguiente DAG en el cual D será la variable de tratamiento o la variable que indica si una persona tiene formación de educación secundaria; Y es nuestra variable de interés o los ingresos; PE es la variable que indica el nivel educativo de los padres; I es una variable de ingreso familiar, y B son el background no observable de la persona (factores como la genética, habilidades individuales, ambiente familiar, etc.).

El DAG de la Figura 1.3 es en sí mismo una historia. Cada persona tiene un cierto background que normalmente no se reporta en los conjuntos de datos. Medidas como el grado de inteligencia, la personalidad, la estabilidad emocional, capacidad de resiliencia, dinámica familiar y cualquier otro relacionado con factores ambientales o del entorno no se encuentran en los datos comúnmente. Por lo que se les denomina factores no observables.

Estos factores ambientales (B) están correlacionados o expresados en variables de padres e hijos. Este background causa que los padres elijan un nivel educativo o ruta de educación para los hijos y también afecta las decisiones individuales de los niños respecto de la ruta educativa que quieren seguir.

En este caso, también es posible notar que los DAG cuentan 2 historias. Nos dicen lo que está pasando, pero también nos dicen lo que no está pasando.




Figura 1.4: Ejemplo 4 de un DAG, IV estimator

Así, B no tiene un efecto directo en los ingresos laborales, exento a través de su efecto en la elección educativa. Sin embargo, en muchas ocasiones se suele criticar este tipo de planteamientos por parecer más un supuesto que un hecho real. En estos casos, la desición es del investigador.

Veamos un ejemplo más, el caso de las variables instrumentales. La Figura 1.4 ilustra que U son un conjunto de factores no observables que impiden indenticar la causalidad entre D y Y . De esta forma, bucamos un Z que no está correlacionado con U pero si con D con el objeto de hace una estimación auxiliar.

2

Teoría de convergencia asintótica

A continuación listamos y enunciamos una serie de definiciones relevantes para la teoría de grandes muestras. En su caso, en la medida de lo posible no haremos demostraciones de algunos de los resultados enunciados puesto que ello en sí mismo podría ser una parte significativa de un curso de probabilidad y estadística, lo que además implica tiempo de nuestro curso que podríamos requerir para otros temas.

2.1. Convergencia de sucesiones

Definición 2.1 *Sea una sucesión de números no aleatorios $\{a_N : N = 1, 2, \dots\}$, decimos que a_N converge a un número a (es decir, tiene su límite en a) si $\forall \varepsilon > 0$, $\exists N_\varepsilon$ tal que si $N > N_\varepsilon$, entonces:*

$$|a_N - a| < \varepsilon$$

Es decir, $a_N \longrightarrow a$ cuando $N \longrightarrow \infty$.

Definición 2.2 *Sea una sucesión de números no aleatorios $\{a_N : N = 1, 2, \dots\}$, decimos que la sucesión está acotada si y sólo si existe $b < \infty$ tal que $|a_N| \leq b$, $\forall N = 1, 2, \dots$.*

Estas definiciones aplican de forma similar a vectores y a matrices cuando las analizamos y aplicamos elemento a elemento.

2.2. Convergencia en probabilidad y acotamientos en probabilidad

Definición 2.3 Sea una sucesión de variables aleatorias $\{x_N : N = 1, 2, \dots\}$ decimos que una sucesión de variables aleatorias es convergente en probabilidad a una constante a si $\forall \varepsilon > 0$ tenemos que:

$$\lim_{N \rightarrow \infty} P[|x_N - a| > \varepsilon] = 0$$

Alternativamente, una sucesión de variables aleatorias tiene un límite en probabilidad en una constante a si cumple la condición anterior, lo cual escribiremos como:

$$p \lim x_N = a$$

Definición 2.4 Sea una sucesión de variables aleatorias $\{x_N : N = 1, 2, \dots\}$ decimos que la sucesión está acotada en probabilidad si y sólo si para cada $\varepsilon > 0$, existe un $b_\varepsilon < \infty$ y un entero N_ε tal que $\forall N \geq N_\varepsilon$ sucede que:

$$P[|x_N| \geq b_\varepsilon] < \varepsilon$$

Todas las definiciones de esta sección aplican elemento a elemento a sucesiones de vectores o matrices de variables aleatorias. Por ejemplo, si $\{\mathbf{X}_N : N = 1, 2, \dots\}$ es una sucesión de un vector de variables aleatorias o vector aleatorio de dimensión $K \times 1$, entonces decimos que $\mathbf{X}_N$ converge en probabilidad a $\mathbf{a}$ o $p \lim \mathbf{X}_N = \mathbf{a}$, donde $\mathbf{a}$ es un vector aleatorio de dimensión $K \times 1$, si y sólo si cada una de las entradas de la sucesión de vectores aleatorios cumple que:

$$p \lim x_{Nj} = a_j$$

Para todo $j = 1, 2, \dots, K$. Una forma equivalente de escribir este resultado es:

$$p \lim \|\mathbf{X}_N - \mathbf{a}\| = 0$$

Donde $\|b\| \equiv (b'b)^{1/2}$, es decir, que el simbolo es una distancia euclideanea de de un vector de dimensión $K \times 1$.

De forma similar, supongamos que analizamos una sucesión de matrices de variables aleatorias o matrices aleatorias $\{\mathbf{Z}_N : N = 1, 2, \dots\}$, cuya dimensión es de $M \times K$. Supongamos que existe una matriz de la misma dimensión $\mathbf{B}$, entonces podemos decir en forma equivalente que:

$$p \lim \|\mathbf{Z}_N - \mathbf{B}\| = 0$$

Donde $\|A\| \equiv [tr(A'A)]^{1/2}$ y $tr(C)$ denota la traza de una matriz simétrica.

Teorema 2.1 Sea $g : \mathbb{R}^K \longrightarrow \mathbb{R}^J$ una función continua en algún punto $c \in \mathbb{R}^K$. Sea $\{\mathbf{X}_N : N = 1, 2, \dots\}$ una sucesión de vectores aleatorios de dimensión $K \times 1$ tal que $p \lim \mathbf{X}_N = c$. Entonces,

$$\lim_{N \rightarrow \infty} g(\mathbf{X}_N) = g(c)$$

En otras palabras:

$$p \lim g(\mathbf{X}_N) = g(p \lim \mathbf{X}_N)$$

2.3. Convergencia en distribución

Definición 2.5 Una sucesión de variables aleatorias $\{x_N : N = 1, 2, \dots\}$ converge en distribución a una variable aleatoria continua si y sólo si $\forall \xi \in \mathbb{R}$:

$$\lim_{N \rightarrow \infty} F_N(\xi) = F(\xi)$$

Donde F_N es la función de distribución acumulada (c.d.f.) de x_N y F es la función de distribución acumulada continua de x . En otras palabras, la expresión anterior se puede escribir como:

$$x_N \xrightarrow{d} x$$

Definición 2.6 Una sucesión de vectores aleatorios $\{\mathbf{X}_N : N = 1, 2, \dots\}$ de dimensión $K \times 1$ converge en distribución a un vector aleatorio $\mathbf{X}$ de dimensión $K \times 1$ si y sólo si para cualquier vector aleatorio $\mathbf{C}$ de dimensión $K \times 1$ sucede que: $\mathbf{C}'\mathbf{C} = 1$, entonces:

$$\mathbf{C}'\mathbf{X}_N \xrightarrow{d} \mathbf{C}'\mathbf{X}$$

o simplemente:

$$\mathbf{X}_N \xrightarrow{d} \mathbf{X}$$

Por ejemplo, cuando $\mathbf{X} \sim \text{Normal}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, podemos decir que si:

$$\mathbf{C}'\mathbf{X}_N \xrightarrow{d} \text{Normal}(\mathbf{C}'\boldsymbol{\mu}, \mathbf{C}'\boldsymbol{\Sigma}\mathbf{C})$$

Para cada $\mathbf{C} \in \mathbb{R}^K$ tal que $\mathbf{C}'\mathbf{C} = 1$, en este caso escribiremos que:

$$\mathbf{X}_N \xrightarrow{d} \text{Normal}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

2.4. Teoremas límite para muestras aleatorias

Teorema 2.2 Sea $\{\mathbf{W}_N : N = 1, 2, \dots\}$ una sucesión de vectores aleatorios de dimensión $K \times 1$ que provienen de una población idénticamente distribuidos tal que: $\mathbb{E}[|w_{Nk}|] < \infty$, con $k = 1, 2, \dots K$. Entonces, la sucesión satisface Ley Débil del los Grandes Números:

$$N^{-1} \sum_{i=1}^N \mathbf{W}_i \xrightarrow{p} \boldsymbol{\mu}_w$$

Donde $\boldsymbol{\mu} \equiv \mathbb{E}[\mathbf{W}_i]$

Teorema 2.3 Sea $\{\mathbf{W}_N : N = 1, 2, \dots\}$ una sucesión de vectores aleatorios de dimensión $K \times 1$ independientes e idénticamente distribuidos tal que: $\mathbb{E}[w_{Nk}^2] < \infty$, con $k = 1, 2, \dots K$, y $\mathbb{E}[w_i] = 0$. Entonces, $\{\mathbf{W}_N : N = 1, 2, \dots\}$ satisface el Teorema del Límite Central en el siguiente sentido:

$$N^{-1/2} \sum_{i=1}^N \mathbf{W}_i \xrightarrow{d} \text{Normal}(\mathbf{0}, \mathbf{B})$$

Donde $\mathbf{B} = \text{Var}(\mathbf{W}_N) = \mathbb{E}[\mathbf{W}_N \mathbf{W}_N']$ es una matriz positiva definida.

2.5. Estimadores y estadísticas de prueba

Definición 2.7 Sea $\{\hat{\boldsymbol{\theta}}_N : N = 1, 2, \dots\}$ una sucesión de estimadores dados y acomodados en un vector $P \times 1$. Sea $\boldsymbol{\theta} \in \boldsymbol{\Theta}$, donde N indexa el tamaño de la muestra. Si $\hat{\boldsymbol{\theta}} \xrightarrow{p} \boldsymbol{\theta}$ para cualquier valor de $\boldsymbol{\theta}$, entonces decimos que $\hat{\boldsymbol{\theta}}_N$ es un estimador consistente de $\boldsymbol{\theta}$.

Definición 2.8 Sea $\{\hat{\boldsymbol{\theta}}_N : N = 1, 2, \dots\}$ una sucesión de estimadores dados y acomodados en un vector $P \times 1$. Sea $\boldsymbol{\theta} \in \boldsymbol{\Theta}$, donde N indexa el tamaño de la muestra. Asumamos que:

$$\sqrt{N}(\hat{\boldsymbol{\theta}}_N - \boldsymbol{\theta}) \xrightarrow{d} \text{Normal}(\mathbf{0}, \mathbf{V})$$

Donde $\mathbf{V}$ es una matriz semidefinida positiva de dimensión $P \times P$. Entonces, decimos que $\hat{\boldsymbol{\theta}}_N$ es $\sqrt{N}$ - asintóticamente distribuida de forma normal y $\mathbf{V}$ es la varianza asintótica de $\sqrt{N}(\hat{\boldsymbol{\theta}}_N - \boldsymbol{\theta})$ denotada como $A\text{Var}\sqrt{N}(\hat{\boldsymbol{\theta}}_N - \boldsymbol{\theta}) = \mathbf{V}$.

Teorema 2.4 *Supongamos que $\mathbf{V}$ es una matriz definida positiva. Entonces, para cualquier matriz no estocástica $\mathbf{R}$ de dimensión $Q \times P$, con $Q \leq P$ con $\text{Rango}(\mathbf{R}) = Q$, sucede que:*

$$\sqrt{N}\mathbf{R}(\hat{\boldsymbol{\theta}}_N - \boldsymbol{\theta}) \xrightarrow{d} \text{Normal}(\mathbf{0}, \mathbf{RVR}')$$

y que:

$$[\sqrt{N}\mathbf{R}(\hat{\boldsymbol{\theta}}_N - \boldsymbol{\theta})]'[\mathbf{RVR}']^{-1}[\sqrt{N}\mathbf{R}(\hat{\boldsymbol{\theta}}_N - \boldsymbol{\theta})] \xrightarrow{d} \chi_Q^2$$

3

Estimación de modelos lineales de una sola ecuación por el método de Mínimos Cuadrados Ordinarios

3.1. El estimador de Mínimos Cuadrados Ordinarios (MCO) y el análisis clásico de regresión

Si partimos de las ecuaciones (12.2) u (1.3), podemos establecer que el término de error estará dado por:

$$\varepsilon_i = y_i - \mathbf{X}_i' \boldsymbol{\beta} \quad (3.1)$$

Donde $i = 1, 2, \dots, N$. De forma similar podremos decir que un estimador de éste término de error será aquel que resulte de:

$$e_i = y_i - \mathbf{X}_i' \hat{\boldsymbol{\beta}} \quad (3.2)$$

Donde $\hat{\boldsymbol{\beta}}$ es un vector de estimadores de los parámetros $\boldsymbol{\beta}$. De lo dicho hasta ahora es fácil ver que la siguiente ecuación es cierta $\forall i$:

$$y_i = \mathbf{X}_i' \boldsymbol{\beta} + \varepsilon_i = \mathbf{X}_i' \hat{\boldsymbol{\beta}} + e_i \quad (3.3)$$

Intuitivamente, la ecuación (3.3) significa que siempre que poseamos una muestra de los elementos de la población, podremos explicar una parte de la variable dependiente, no su totalidad. En este sentido, el análisis de regresión consiste en un proceso de ajuste a la variable dependiente. Está es la idea que da origen al R^2 y otras medidas de bondad de ajuste, mismas que se analizan en textos convencionales de análisis de regresión.

El método de MCO, en consecuencia, resulta en encontrar la combinación de valores de los estimadores de los parámetros $\hat{\beta}$ que permita minimizar la suma de los residuales (estimadores de los términos de error ε) al cuadrado dada por:

$$\sum_{i=1}^N e_i^2 = \sum_{i=1}^N (y_i - \mathbf{X}'_i \hat{\beta})^2 \quad (3.4)$$

Donde $\hat{\beta}$ denota el vector de estimadores $\hat{\beta}_1, \dots, \hat{\beta}_K$. En términos matriciales, dado que $(e_1, e_2, \dots, e_n)'(e_1, e_2, \dots, e_n) = \mathbf{e}'\mathbf{e}$, el problema del método de MCO consiste en resolver el problema de optimización:

$$\begin{aligned} \text{Minimizar}_{\hat{\beta}} S(\hat{\beta}) &= \text{Minimizar}_{\hat{\beta}} \mathbf{e}'\mathbf{e} \\ &= \text{Minimizar}_{\hat{\beta}} (\mathbf{Y} - \mathbf{X}\hat{\beta})'(\mathbf{Y} - \mathbf{X}\hat{\beta}) \end{aligned}$$

Expandiendo la expresión $\mathbf{e}'\mathbf{e}$ obtenemos:

$$\mathbf{e}'\mathbf{e} = \mathbf{Y}'\mathbf{Y} - 2\mathbf{Y}'\mathbf{X}\hat{\beta} + \hat{\beta}'\mathbf{X}'\mathbf{X}\hat{\beta} \quad (3.5)$$

De esta forma obtenemos que las condiciones necesarias de un mínimo son:

$$\frac{\partial S(\hat{\beta})}{\partial \hat{\beta}} = -2\mathbf{X}'\mathbf{Y} + 2\mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{0} \quad (3.6)$$

De ecuación anterior obtenemos para la solución del problema del mínimo a las ecuaciones siguientes conocidas como *ecuaciones normales* dadas por:

$$\mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{X}'\mathbf{Y} \quad (3.7)$$

Notemos que dichas ecuaciones normales son en realidad un sistema de ecuaciones de K variables o incógnitas. Por un lado, recordemos que $\mathbf{X}$ es una matriz de dimensión $N \times K$, con lo cual $\mathbf{X}'$ es de dimensión $K \times N$. Así, el producto $\mathbf{X}'\mathbf{X}$ dará como resultado una matriz cuadrada de dimensión $K \times K$. Por otro lado, sabemos que $\mathbf{Y}$ es un vector de tamaño $N \times 1$, con

lo cual el producto $\mathbf{X}'\mathbf{Y}$ da como resultado un vector de dimensión $K \times 1$. En conclusión, el sistema de ecuaciones normales consiste en K ecuaciones con K incógnitas $(\hat{\beta}_1, \dots, \hat{\beta}_K)$. Ante este hecho, existen múltiples formas mediante las cuales se puede solucionar dicho sistema, sin embargo en nuestro caso seguiremos el siguiente procedimiento de operaciones matriciales.

Si la matriz $\mathbf{X}$ es de rango completo por columnas, entonces la inversa de la matriz $\mathbf{X}'\mathbf{X}$ existe. De esta forma, la solución está dada por la siguiente expresión:

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} \quad (3.8)$$

Esta expresión, a pesar de ser en apariencia compleja se puede ver como un conjunto de sumas. En general hemos supuesto que nuestra regresión a estimar está descrita por la ecuación: $y_i = x_{i1}\beta_1 + x_{i2}\beta_2 + \dots + x_{iK}\beta_K + \varepsilon_i$, de esta forma tenemos K variables independientes en nuestra regresión.

Ahora bien, si denotamos a $\mathbf{X}_k$ como el vector columna formado por todas las observaciones de la muestra ($i = 1, 2, \dots, N$) para la variable k , podemos decir que la matriz $\mathbf{X}$ que contiene todas las variables independientes se forma por la concatenación de cada uno de los K vectores columna. Dicho esto, podemos ver que las matrices $\mathbf{X}$ y $\mathbf{X}'$ se pueden expresar como:

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & x_{13} & \dots & x_{1K} \\ x_{21} & x_{22} & x_{23} & \dots & x_{2K} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ x_{N1} & x_{N2} & x_{N3} & \dots & x_{NK} \end{bmatrix} = [\mathbf{X}_1 \quad \mathbf{X}_2 \quad \mathbf{X}_3 \quad \dots \quad \mathbf{X}_K]$$

$$\mathbf{X}' = \begin{bmatrix} x_{11} & x_{12} & x_{13} & \dots & x_{1K} \\ x_{21} & x_{22} & x_{23} & \dots & x_{2K} \\ x_{31} & x_{32} & x_{33} & \dots & x_{3K} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ x_{N1} & x_{N2} & x_{N3} & \dots & x_{NK} \end{bmatrix} = \begin{bmatrix} \mathbf{X}'_1 \\ \mathbf{X}'_2 \\ \mathbf{X}'_3 \\ \vdots \\ \mathbf{X}'_K \end{bmatrix}$$

Si suponemos que nuestra regresión tiene una constante, la especificación sería: $y_i = \beta_1 + x_{i2}\beta_2 + \dots + x_{iK}\beta_K + \varepsilon_i$, con unas matrices $\mathbf{X}$ y $\mathbf{X}'$ dadas:

$$\mathbf{X} = \begin{bmatrix} 1 & x_{12} & x_{13} & \dots & x_{1K} \\ 1 & x_{22} & x_{23} & \dots & x_{2K} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_{N2} & x_{N3} & \dots & x_{NK} \end{bmatrix} = [\mathbf{1}_N \quad \mathbf{X}_2 \quad \mathbf{X}_3 \quad \dots \quad \mathbf{X}_K]$$

$$\mathbf{X}' = \begin{bmatrix} 1 & 1 & 1 & \dots & 1 \\ x_{12} & x_{22} & x_{32} & \dots & x_{N2} \\ x_{13} & x_{23} & x_{33} & \dots & x_{N3} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ x_{1K} & x_{2K} & x_{3K} & \dots & x_{NK} \end{bmatrix} = \begin{bmatrix} \mathbf{1}'_N \\ \mathbf{X}'_2 \\ \mathbf{X}'_3 \\ \vdots \\ \mathbf{X}'_K \end{bmatrix}$$

Donde $\mathbf{1}_N$ es un vector columna compuesto de 1's (unos). Retomando la ecuación (3.8), desarrollemos cada uno de los casos anteriores, así obtenemos lo siguiente para el caso general:

$$\mathbf{X}'\mathbf{X} = \begin{bmatrix} \mathbf{X}'_1 \\ \mathbf{X}'_2 \\ \mathbf{X}'_3 \\ \vdots \\ \mathbf{X}'_K \end{bmatrix} \begin{bmatrix} \mathbf{X}_1 & \mathbf{X}_2 & \mathbf{X}_3 & \dots & \mathbf{X}_K \end{bmatrix}$$

$$\begin{bmatrix} \mathbf{X}'_1\mathbf{X}_1 & \mathbf{X}'_1\mathbf{X}_2 & \mathbf{X}'_1\mathbf{X}_3 & \dots & \mathbf{X}'_1\mathbf{X}_K \\ \mathbf{X}'_2\mathbf{X}_1 & \mathbf{X}'_2\mathbf{X}_2 & \mathbf{X}'_2\mathbf{X}_3 & \dots & \mathbf{X}'_2\mathbf{X}_K \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ \mathbf{X}'_K\mathbf{X}_1 & \mathbf{X}'_K\mathbf{X}_2 & \mathbf{X}'_K\mathbf{X}_3 & \dots & \mathbf{X}'_K\mathbf{X}_K \end{bmatrix}$$

Por lo tanto, obtenemos que:

$$\mathbf{X}'\mathbf{X} = \begin{bmatrix} \sum_{i=1}^N x_{i1}^2 & \sum_{i=1}^N x_{i1}x_{i2} & \sum_{i=1}^N x_{i1}x_{i3} & \dots & \sum_{i=1}^N x_{i1}x_{iK} \\ \sum_{i=1}^N x_{i2}x_{i1} & \sum_{i=1}^N x_{i2}^2 & \sum_{i=1}^N x_{i2}x_{i3} & \dots & \sum_{i=1}^N x_{i2}x_{iK} \\ \sum_{i=1}^N x_{i3}x_{i1} & \sum_{i=1}^N x_{i3}x_{i2} & \sum_{i=1}^N x_{i3}^2 & \dots & \sum_{i=1}^N x_{i3}x_{iK} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ \sum_{i=1}^N x_{iK}x_{i1} & \sum_{i=1}^N x_{iK}x_{i2} & \sum_{i=1}^N x_{iK}x_{i3} & \dots & \sum_{i=1}^N x_{iK}^2 \end{bmatrix}$$

Por otro lado, cuando supongamos que existe un término constante:

$$\mathbf{X}'\mathbf{X} = \begin{bmatrix} N & \sum_{i=1}^N x_{i2} & \sum_{i=1}^N x_{i3} & \dots & \sum_{i=1}^N x_{iK} \\ \sum_{i=1}^N x_{i2} & \sum_{i=1}^N x_{i2}^2 & \sum_{i=1}^N x_{i2}x_{i3} & \dots & \sum_{i=1}^N x_{i2}x_{iK} \\ \sum_{i=1}^N x_{i3} & \sum_{i=1}^N x_{i3}x_{i2} & \sum_{i=1}^N x_{i3}^2 & \dots & \sum_{i=1}^N x_{i3}x_{iK} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ \sum_{i=1}^N x_{iK} & \sum_{i=1}^N x_{iK}x_{i2} & \sum_{i=1}^N x_{iK}x_{i3} & \dots & \sum_{i=1}^N x_{iK}^2 \end{bmatrix}$$

Adicionalmente, el producto $\mathbf{X}'\mathbf{Y}$, en el caso general, se puede expresar como:

$$\mathbf{X}'\mathbf{Y} = \begin{bmatrix} \mathbf{X}'_1 \\ \mathbf{X}'_2 \\ \mathbf{X}'_3 \\ \vdots \\ \mathbf{X}'_K \end{bmatrix} \mathbf{Y} = \begin{bmatrix} \mathbf{X}'_1\mathbf{Y} \\ \mathbf{X}'_2\mathbf{Y} \\ \mathbf{X}'_3\mathbf{Y} \\ \vdots \\ \mathbf{X}'_K\mathbf{Y} \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^N x_{i1}y_i \\ \sum_{i=1}^N x_{i2}y_i \\ \sum_{i=1}^N x_{i3}y_i \\ \vdots \\ \sum_{i=1}^N x_{iK}y_i \end{bmatrix} \quad (3.9)$$

Si en el modelo suponemos la existencia de un término constante, dicho producto se expresa como:

$$\mathbf{X}'\mathbf{Y} = \begin{bmatrix} \mathbf{1}'_N \\ \mathbf{X}'_2 \\ \mathbf{X}'_3 \\ \vdots \\ \mathbf{X}'_K \end{bmatrix} \mathbf{Y} = \begin{bmatrix} \mathbf{1}'_N\mathbf{Y} \\ \mathbf{X}'_2\mathbf{Y} \\ \mathbf{X}'_3\mathbf{Y} \\ \vdots \\ \mathbf{X}'_K\mathbf{Y} \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^N y_i \\ \sum_{i=1}^N x_{i2}y_i \\ \sum_{i=1}^N x_{i3}y_i \\ \vdots \\ \sum_{i=1}^N x_{iK}y_i \end{bmatrix}$$

Finalmente, para que esta solución dada para el procedimiento de MCO y mostrada en la ecuación (3.8) sea un mínimo, debemos buscar las condiciones de segundo orden:

$$\frac{\partial^2 S(\hat{\beta})}{\partial \hat{\beta} \partial \hat{\beta}'} = 2\mathbf{X}'\mathbf{X} \quad (3.10)$$

Donde la matriz $\mathbf{X}'\mathbf{X}$ debe ser positiva definida para que la solución de MCO sea un mínimo. Sea $q = \mathbf{c}'\mathbf{X}'\mathbf{X}\mathbf{c}$ para algún vector $\mathbf{c}$ distinto de cero. Entonces:

$$q = \mathbf{v}'\mathbf{v} = \sum_{i=1}^n v_i^2, \text{ donde } \mathbf{v} = \mathbf{X}\mathbf{c}$$

Así, q es positivo. Si $\mathbf{v}$ fuera cero, entonces existe una combinación lineal de las columnas de $\mathbf{X}$ que da como resultado cero, lo cual contradice el supuesto de que $\mathbf{X}$ es de rango completo. En todos los casos, si $\mathbf{X}$ es de rango completo, entonces la solución del método de MCO, $\hat{\beta}$, es la única que minimiza la suma de los residuales al cuadrado.

3.2. Bondad de ajuste

Una vez planteada la solución de MCO plantearemos una medida para determinar en qué grado los datos estimados, definidos como $\hat{\mathbf{Y}} = \mathbf{X}\hat{\beta}$, se

ajustan al valor real de $\mathbf{Y}$. La medida o métrica es el R^2 , la cual contrasta el análisis de regresión respecto de hacer una simple estimación de una media para dar un pronóstico de $\mathbf{Y}$. El coeficiente R^2 está montado en el supuesto de que el modelo incluye un término constante. Si el modelo no incluye una constante, no es posible hacer una interpretación del R^2 , en los siguientes párrafos abundaremos al respecto.

Antes de iniciar el desarrollo del R^2 , partamos de que la suma de residuales es igual a cero ($\sum_{i=1}^n e_i = 0$), si y sólo si, el modelo tiene un término constante. Un corolario de este hecho es que el valor promedio de los residuales es cero, sí y solo si, el modelo tiene un término constante, esto es, la única forma en que se cumpla la siguiente expresión es que la suma de residuales sea cero:

$$\begin{aligned}\bar{e} &= \frac{\sum_{i=1}^n e_i}{n} \\ &= \frac{1}{n} \cdot \begin{bmatrix} 1, & 1, & 1, & \dots & 1 \end{bmatrix} \begin{bmatrix} e_1 \\ e_2 \\ e_3 \\ \vdots \\ e_n \end{bmatrix} \\ &= 0\end{aligned}$$

Condición que resulta de las ecuaciones normales de MCO, recordemos que ellas se derivan de que $\mathbf{X}'\mathbf{e} = \mathbf{0}$, y que el primer producto punto de vectores implica a la columna de la constante en la matriz $\mathbf{X}$ y que está definido por $\begin{bmatrix} 1, & 1, & 1, & \dots & 1 \end{bmatrix}$.

El R^2 descompone la variación total en dos tramos: la variación originada por la regresión y la variación originada por el término de error. Como primer paso definamos la variación total observada respecto de la media ($\bar{Y}$) como:

$$\sum_{i=1}^n (y_i - \bar{Y})^2 = \begin{bmatrix} y_1 - \bar{Y}, & y_2 - \bar{Y}, & y_3 - \bar{Y}, & \dots & y_n - \bar{Y} \end{bmatrix} \begin{bmatrix} y_1 - \bar{Y} \\ y_2 - \bar{Y} \\ y_3 - \bar{Y} \\ \vdots \\ y_n - \bar{Y} \end{bmatrix}$$

$$\begin{aligned}
&= (\mathbf{Y} - \bar{\mathbf{Y}})'(\mathbf{Y} - \bar{\mathbf{Y}}) \\
&= \left[\mathbf{Y} - \frac{1}{n} \begin{bmatrix} 1 & 1 & \dots & 1 \\ 1 & 1 & \dots & 1 \\ 1 & 1 & \dots & 1 \\ \vdots & \vdots & \dots & \vdots \\ 1 & 1 & \dots & 1 \end{bmatrix} \mathbf{Y} \right]' \left[\mathbf{Y} - \frac{1}{n} \begin{bmatrix} 1 & 1 & \dots & 1 \\ 1 & 1 & \dots & 1 \\ 1 & 1 & \dots & 1 \\ \vdots & \vdots & \dots & \vdots \\ 1 & 1 & \dots & 1 \end{bmatrix} \mathbf{Y} \right] \\
&= \mathbf{Y}' \left[\mathbb{I}_n - \frac{1}{n} \begin{bmatrix} 1 & 1 & \dots & 1 \\ 1 & 1 & \dots & 1 \\ 1 & 1 & \dots & 1 \\ \vdots & \vdots & \dots & \vdots \\ 1 & 1 & \dots & 1 \end{bmatrix} \right]' \left[\mathbb{I}_n - \frac{1}{n} \begin{bmatrix} 1 & 1 & \dots & 1 \\ 1 & 1 & \dots & 1 \\ 1 & 1 & \dots & 1 \\ \vdots & \vdots & \dots & \vdots \\ 1 & 1 & \dots & 1 \end{bmatrix} \right] \mathbf{Y} \\
&= \mathbf{Y}' \mathbf{M}^0 \mathbf{Y} \tag{3.11}
\end{aligned}$$

En la expresión (3.11) a $\mathbf{M}^0$ se puede interpretar como una matriz que resta a una matriz o vector su promedio, notemos que como resultado dará las desviaciones respecto de la media. Asimismo, $\mathbf{M}^0$ tiene un par de propiedades que son fácilmente demostrables: idempotencia y simetría, es decir, i) $\mathbf{M}^0 = \mathbf{M}^{0'}$ y ii) $\mathbf{M}^0 \mathbf{M}^0 = \mathbf{M}^0$. Dicho lo anterior, retomemos a (3.11) para mostrar que:

$$\begin{aligned}
\mathbf{Y}' \mathbf{M}^0 \mathbf{Y} &= \mathbf{Y}' \mathbf{M}^{0'} \mathbf{M}^0 \mathbf{Y} \\
&= (\mathbf{X} \hat{\boldsymbol{\beta}} + \mathbf{e})' \mathbf{M}^{0'} \mathbf{M}^0 (\mathbf{X} \hat{\boldsymbol{\beta}} + \mathbf{e}) \\
&= (\hat{\boldsymbol{\beta}}' \mathbf{X}' + \mathbf{e}') \mathbf{M}^{0'} \mathbf{M}^0 (\mathbf{X} \hat{\boldsymbol{\beta}} + \mathbf{e}) \\
&= \hat{\boldsymbol{\beta}}' \mathbf{X}' \mathbf{M}^{0'} \mathbf{M}^0 \mathbf{X} \hat{\boldsymbol{\beta}} + \hat{\boldsymbol{\beta}}' \mathbf{X}' \mathbf{M}^{0'} \mathbf{M}^0 \mathbf{e} + \mathbf{e}' \mathbf{M}^{0'} \mathbf{M}^0 \mathbf{X} \hat{\boldsymbol{\beta}} + \mathbf{e}' \mathbf{M}^{0'} \mathbf{M}^0 \mathbf{e} \\
&= \hat{\boldsymbol{\beta}}' \mathbf{X}' \mathbf{M}^{0'} \mathbf{M}^0 \mathbf{X} \hat{\boldsymbol{\beta}} + \hat{\boldsymbol{\beta}}' \mathbf{X}' \mathbf{e} + \mathbf{e}' \mathbf{X} \hat{\boldsymbol{\beta}} + \mathbf{e}' \mathbf{e} \\
&= \hat{\boldsymbol{\beta}}' \mathbf{X}' \mathbf{M}^{0'} \mathbf{M}^0 \mathbf{X} \hat{\boldsymbol{\beta}} + \mathbf{e}' \mathbf{e} \\
&= \hat{\boldsymbol{\beta}}' \mathbf{X}' \mathbf{M}^0 \mathbf{X} \hat{\boldsymbol{\beta}} + \mathbf{e}' \mathbf{e} \tag{3.12}
\end{aligned}$$

No debe pasar desapercibido que el desarrollo algebraico para llegar a la ecuación (3.12) sólo es posible si el promedio de los residuales es cero, es

decir:

$$\mathbf{M}^0 \mathbf{e} = \mathbf{e} - \begin{bmatrix} \bar{e} \\ \bar{e} \\ \bar{e} \\ \vdots \\ \bar{e} \end{bmatrix} = \mathbf{e} - \begin{bmatrix} 0 \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix} = \mathbf{e} \quad (3.13)$$

De otra forma, no se puede concluir la expresión (3.12). Finalmente, (3.12) la expresaremos así:

$$\mathbf{Y}'\mathbf{M}^0\mathbf{Y} = \hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{M}^0\mathbf{X}\hat{\boldsymbol{\beta}} + \mathbf{e}'\mathbf{e} \quad (3.14)$$

Así, como mencionamos anteriormente, (3.14) se puede interpretar como que la variación total respecto de la media se puede descomponer en dos variaciones, una que se origina de la regresión, $\hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{M}^0\mathbf{X}\hat{\boldsymbol{\beta}}$, y otra de los residuales, $\mathbf{e}'\mathbf{e}$. De esta forma planteamos que R^2 es una metrica que cuantifica cuánto de la variación total es explicada por la regresión y cuánto es explicada por los residuales (es decir, por la información no observable):

$$\begin{aligned} R^2 &= \frac{Var.Regresion}{Var.Total} \\ &= \frac{\hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{M}^0\mathbf{X}\hat{\boldsymbol{\beta}}}{\mathbf{Y}'\mathbf{M}^0\mathbf{Y}} \\ &= \frac{\mathbf{Y}'\mathbf{M}^0\mathbf{Y}}{\mathbf{Y}'\mathbf{M}^0\mathbf{Y}} - \frac{\mathbf{e}'\mathbf{e}}{\mathbf{Y}'\mathbf{M}^0\mathbf{Y}} \\ &= 1 - \frac{\mathbf{e}'\mathbf{e}}{\mathbf{Y}'\mathbf{M}^0\mathbf{Y}} \end{aligned} \quad (3.15)$$

Existe una expresión más que se le denomina como un R^2 ajustado o $R^2 Adj.$, el cual castiga por un uso excesivo de variables independientes:

$$R^2 Adj. = 1 - \frac{n-1}{n-K} \frac{\mathbf{e}'\mathbf{e}}{\mathbf{Y}'\mathbf{M}^0\mathbf{Y}} \quad (3.16)$$

Así, es obvio que la siguiente relación siempre es cierta: $R^2 \geq R^2 Adj.$.

3.3. Modelos lineales y algunas de sus propiedades

Determinado una estimado de MCO dado por la ecuación (3.8), establezcamos el modelo poblacional que es lineal en sus parámetros y que está

dado por (notése que eliminamos los subíndices i para facilitar la exposición—digamos, por economía de pizarrón):

$$y = \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_K x_K + \varepsilon \quad (3.17)$$

Donde y y $x_1, x_2, \dots, x_K$ son variables aleatorias observables, ε es un término de error o perturbación no observable, y $\beta_1, \beta_2, \dots, \beta_K$ son los parámetros (constantes) que deseamos estimar.

La ecuación (3.17) es un modelo estructural estimable, el cual en ocasiones se obtiene directamente de una modelación teórica y otras veces deriva de un procedimiento algebraico para obtenerlo.

El término de error ε puede ser causa de una serie de fuentes relacionadas con: (1) información no observable, (2) variables relevantes omitidas y (3) errores de medición (que en el fondo implica la omisión de información).

Asumimos que para estimar consistentemente a β a través de una muestra aleatoria de la población, el término de error ε tiene una **media cero** que no está correlacionada con el resto de los regresores, es decir:

$$\begin{aligned} \mathbb{E}[\varepsilon_i] &= 0 \\ \text{Cov}(x_k, \varepsilon_i) &= 0 \end{aligned} \quad (3.18)$$

Donde $k = 1, 2, \dots, K$, e $i = 1, 2, \dots, n$. Dada la ecuación de regresión y el supuesto anterior en la ecuación (3.18), entonces podemos ver este caso como una proyección lineal de y en el vector formado por $(x_1, x_2, \dots, x_K)$ y descrito como: $x_1\beta_1 + x_2\beta_2 + \dots + x_K\beta_K$.

Partiendo de que en la ecuación (3.18) establecimos que el análisis de regresión deberá cumplir con $\mathbb{E}[\varepsilon_i] = 0$, entonces podemos establecer que:

$$\mathbb{E}[\varepsilon|x_1, x_2, \dots, x_K] = \mathbb{E}[\varepsilon|\mathbf{x}] = 0 \quad (3.19)$$

De esta forma podemos decir, utilizando la definición de función de regresión discutida en el capítulo previo tenemos que:

$$\mathbb{E}[y|\mathbf{x}] = \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_K x_K \quad (3.20)$$

Dicho esto, podemos hacer algunas observaciones respecto del efecto de las variables utilizadas. Decimos que una variable explicativa x_k es endógena en la ecuación de regresión si esta no cumple con la ecuación (3.18), es decir, está correlacionada con el término de error, ε . Por el contrario, si x_k no está

correlacionado con ε , entonces se dice que x_k es una variable exógena. De esta forma, la ecuación (3.19) se conoce como el supuesto de exogeneidad.

El supuesto de exogeneidad o el de endogeneidad (depende de cómo lo queramos ver) tiene algunas aristas que debemos analizar.

1. La primera es el problema de variables omitidas. Supongamos que la ecuación de regresión está dada por una expresión como $\mathbb{E}[y|\mathbf{x}, q]$. No obstante, asumamos que q es una variable que no es posible observarse, de forma que nos vemos obligados a estimar una ecuación de regresión del tipo $\mathbb{E}[y|\mathbf{x}]$. En este caso q formará parte del término de error ε . Si q y x_k son variables que están correlacionadas, entonces, tendremos el problema de que x_k será endógena.

Este tipo de situaciones, en las que existe correlación entre variables no observables y variables explicativas son conocidas como problemas de autoselección. En el capítulo de modelos de selección detallaremos más al respecto de este tipo de problemas.

2. La segunda es el problema de simultaneidad. que es un problema que aparece cuando una o más variables explicativas están determinadas simultáneamente con y . Así, si x_k está parcialmente determinada por y , entonces, x_k y ε estarán correlacionados. En otro capítulo más adelante retomaremos este caso.

3.4. Propiedades asintóticas de los estimadores de MCO

Partamos de una forma funcional general de la ecuación de regresión dada por:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

Así para algún individuo i y sin hacer uso del subíndice i , tendríamos:

$$y = \mathbf{x}\boldsymbol{\beta} + \varepsilon \tag{3.21}$$

Donde $\mathbf{x}$ es un vector de regresores de dimensión $1 \times K$ y los parámetros $\boldsymbol{\beta} = (\beta_1, \beta_2, \dots, \beta_K)'$ es un vector de dimensión $K \times 1$. Dado que la mayoría de las veces asumiremos que el modelo considera un término constantes, diremos que $x_1 = 1$.

Asumamos que podemos obtener una muestra aleatoria de tamaño N de la población con el objeto de estimar β a partir de una familia de vectores $\{(\mathbf{x}, y_i) : i = 1, 2, \dots, N\}$, que es una muestra aleatoria independiente e idénticamente distribuida.

Podemos decir que para cada observación $i = 1, 2, \dots, N$ tenemos que:

$$y_i = \mathbf{x}_i\beta + \varepsilon_i \quad (3.22)$$

De esta ecuación ahora discutamos algunas propiedades deseables que deberán cumplir los estimadores β .

La primera es **consistencia**, la cual es una condición de ortogonalidad de la población, la cual implica:

$$\mathbb{E}[\mathbf{x}_i\varepsilon_i] = 0 \quad (3.23)$$

Donde $i = 1, 2, \dots, N$. Si asumimos que el modelo tiene un término constante, entonces, esto implicaría que $\mathbb{E}[\varepsilon_i] = 0$. La segunda es una condición de **no multicolinealidad**:

$$\text{Rank}[\mathbb{E}[\mathbf{X}'\mathbf{X}]] = K \quad (3.24)$$

Así, buscamos que no exista dependencia lineal entre los elementos de $\mathbf{x}'_i\mathbf{x}_i$. Esto debería ponernos a pensar en qué pasa con casos en que incluimos una variable y su cuadrado, o cuando en un modelo que incluye constante decidimos agregar variables dicotómicas con poca variabilidad (e.g. casi todos los individuos son de un tipo), entre otros casos.

Bajo este par de supuestos de las ecuaciones (3.23) y (3.24) se cumplirán los siguientes casos. Diremos que β está identificada, en términos de que se trata de parámetros lineales estimados a partir de una muestra aleatoria tales que β puede ser escrita en términos de los momentos poblacionales, es decir, partiendo de la estimación de estos dada por MCO tendríamos:

$$\hat{\beta} = \mathbb{E}[\mathbf{x}'_i\mathbf{x}_i]^{-1}\mathbb{E}[\mathbf{x}'_iy_i] \quad (3.25)$$

Dado que esta expresión es válida para cada elemento de la muestra y que ilustra la dependencia de que β sea identificable, podemos extender el

análisis para obtener:

$$\begin{aligned}
\hat{\beta} &= \mathbb{E}[\mathbf{X}'\mathbf{X}]^{-1}\mathbb{E}[\mathbf{X}'\mathbf{Y}] \\
&= (\mathbf{X}'\mathbf{X})^{-1}\mathbb{E}[\mathbf{X}'\mathbf{Y}] \\
&= \beta + \mathbb{E}[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\varepsilon}] \\
&= \beta + \left(\frac{\sum_{i=1}^N \mathbf{x}_i' \mathbf{x}_i}{N} \right)^{-1} \left(\frac{\sum_{i=1}^N \mathbf{x}_i' \boldsymbol{\varepsilon}}{N} \right) \\
&= \beta
\end{aligned}$$

El último paso es válido Si tomamos el límite en probabilidad $p \lim \hat{\beta} = \beta + A^{-1} \times 0 = \beta$. Lo anterior implica que hemos demostrado el siguiente teorema:

Teorema 3.1 *Bajo los supuestos de las ecuaciones (3.23) y (3.24) el estimador $\hat{\beta}$ obtenido por MCO a partir de una muestra aleatoria es consistente para β .*

Este teorema implica que $\mathbf{X}\beta$ es una proyección ponderada de $\mathbf{X}$ sobre $\mathbf{Y}$. Más aún, implica que:

$$\mathbb{E}[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}] = \beta \quad (3.26)$$

3.5. Inferencia asintótica bajo MCO

Partamos de que:

$$\begin{aligned}
\hat{\beta} &= \beta + \left(\frac{\sum_{i=1}^N \mathbf{x}_i' \mathbf{x}_i}{N} \right)^{-1} \left(\frac{\sum_{i=1}^N \mathbf{x}_i' \boldsymbol{\varepsilon}}{N} \right) \\
\hat{\beta} - \beta &= \left(\frac{\sum_{i=1}^N \mathbf{x}_i' \mathbf{x}_i}{N} \right)^{-1} \left(\frac{\sum_{i=1}^N \mathbf{x}_i' \boldsymbol{\varepsilon}}{N^{1/2} N^{1/2}} \right) \\
\sqrt{N}(\hat{\beta} - \beta) &= \left(\frac{\sum_{i=1}^N \mathbf{x}_i' \mathbf{x}_i}{N} \right)^{-1} \left(\sqrt{N} \sum_{i=1}^N \mathbf{x}_i' \boldsymbol{\varepsilon} \right)
\end{aligned}$$

Entonces por el Teorema del Límite Central, tenemos que:

$$\sqrt{N} \sum_{i=1}^N \mathbf{x}_i' \boldsymbol{\varepsilon} \xrightarrow{d} \text{Normal}(\mathbf{0}, \Sigma) \quad (3.27)$$

Donde Σ es una matriz de dimensión $K \times K$ que resulta de:

$$\Sigma = \mathbb{E}[\mathbf{X}'\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}'\mathbf{X}]$$

En este momento introduciremos uno de los supuestos más importantes que es el de **homocedasticidad**, por lo que:

$$\Sigma = \mathbb{E}[\mathbf{X}'\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}'\mathbf{X}] = \sigma^2 \mathbb{E}[\mathbf{X}'\mathbf{X}] \quad (3.28)$$

Donde $\sigma^2 = \mathbb{E}[\varepsilon_i]$ para todo $i = 1, 2, \dots, N$. En general vamos a decir que $\mathbb{E}[\varepsilon_i|\mathbf{X}] = \text{Var}[\varepsilon_i|\mathbf{X}] = \sigma^2$. Dicho lo anterior vamos a enunciar un teorema:

Teorema 3.2 Normalidad asintótica de MCO. *Considerando los supuestos descritos en las ecuaciones (3.23) y (3.28), entonces:*

$$\sqrt{N}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) \sim \text{Normal}(\mathbf{0}, \sigma^2(\mathbb{E}[\mathbf{X}'\mathbf{X}])^{-1}) \quad (3.29)$$

El teorema anterior se puede interpretar como:

$$\begin{aligned} \sqrt{N}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) &\sim \text{Normal}\left(\mathbf{0}, \sigma^2 \left(\frac{\sum_{i=1}^N \mathbf{x}_i' \mathbf{x}_i}{N}\right)^{-1}\right) \\ (\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) &\sim \text{Normal}\left(\mathbf{0}, \sigma^2 \left(\sum_{i=1}^N \mathbf{x}_i' \mathbf{x}_i\right)^{-1}\right) \\ (\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) &\sim \text{Normal}(\mathbf{0}, \sigma^2[\mathbf{X}'\mathbf{X}]^{-1}) \\ \hat{\boldsymbol{\beta}} &\sim \text{Normal}(\boldsymbol{\beta}, \sigma^2[\mathbf{X}'\mathbf{X}]^{-1}) \end{aligned} \quad (3.30)$$

A partir de la expresión (3.30) contruiremos algunas pruebas. En estadística es común que porpongamos como estimador de σ^2 a:

$$\hat{\sigma}^2 = \frac{\mathbf{e}'\mathbf{e}}{n - K} \quad (3.31)$$

El cual es un estimador insesgado de la varianza. Además, queda pendiente en esta sección es demostrar que el estimador de MCO ($\hat{\boldsymbol{\beta}}$) alcanza la cota inferior Cramér-Rao. De esta forma podríamos afirmar que el estimador es de mínima varianza o, equivalentemente, es el más eficiente.

Dicho lo anterior podemos construir las dos pruebas: t y F. Previo a dicha construcción debemos recordar que una prueba t se construye por la relación

de una función normal con media cero y variación 1 (uno), y la raíz cuadrada de una función chi-cuadrado. Supongamos que una variable Z se distribuye de forma normal con media cero y variación 1 (uno), y que la variable χ_m^2 se distribuye de forma chi-cuadrado con m grados de libertad, entonces:

$$t = \frac{Z}{\sqrt{\frac{\chi_m^2}{m}}} \sim t_m \quad (3.32)$$

Donde t_m tal y como se describe en (3.32) es una distribución t de Student con m grados de libertad. Por otro lado, cuando se tiene una variable Z con distribución normal con media cero y varianza $\sigma^2 = 1$, entonces lo siguiente es cierto:

$$Z^2 \sim \chi_1^2$$

Así, la suma de variables chi-cuadrado es una chi-cuadrado en los siguientes términos:

$$\sum_{i=1}^m Z^2 \sim \chi_m^2$$

Dada la distribución $\hat{\beta}$, y que la varianza de cada uno de los elementos de $\hat{\beta}$, digamos $\hat{\beta}_k$, es: $\sigma^2(\mathbf{X}'\mathbf{X})_{kk}^{-1}$. En este punto denotaremos con $\hat{\beta}_k$ al elemento k -ésimo dentro de $\hat{\beta}$. Adicionalmente, con $(\mathbf{X}'\mathbf{X})_{kk}^{-1}$ al elemento en la fila k y la columna k en la matriz $(\mathbf{X}'\mathbf{X})^{-1}$. Derivado de lo anterior, lo siguiente es cierto:

$$Z = \frac{\hat{\beta}_k - \beta_k}{\sqrt{\sigma^2(\mathbf{X}'\mathbf{X})_{kk}^{-1}}} \sim \mathcal{N}(0, 1)$$

Considerando la distribución de ε_i y de que e_i es un estimador de ε_i , podemos afirmar que:

$$Z = \frac{e_i - 0}{\sigma} = \frac{e_i}{\sigma} \sim \mathcal{N}(0, 1)$$

De esta forma:

$$\sum_{i=1}^n Z_i^2 = \sum_{i=1}^n \frac{e_i^2}{\sigma^2} \sim \chi_n^2$$

Dada la distribución t de Student en la ecuación (3.32) y los elementos antes mencionados podemos llegar a las siguientes conclusiones:

$$\begin{aligned}
t &= \frac{\frac{\hat{\beta}_k - \beta_k}{\sqrt{\sigma^2(\mathbf{X}'\mathbf{X})_{kk}^{-1}}}}{\sqrt{\sum_{i=1}^n \frac{e_i^2}{\sigma^2} / (n - K)}} \\
&= \frac{\frac{\hat{\beta}_k - \beta_k}{\sqrt{\sigma^2(\mathbf{X}'\mathbf{X})_{kk}^{-1}}}}{\sqrt{\sum_{i=1}^n \frac{e_i^2}{(n-K)\sigma^2}}} \\
&= \frac{\frac{\hat{\beta}_k - \beta_k}{\sqrt{\sigma^2(\mathbf{X}'\mathbf{X})_{kk}^{-1}}}}{\sqrt{\frac{\hat{\sigma}^2}{\sigma^2}}} \\
&= \frac{\frac{\hat{\beta}_k - \beta_k}{\sqrt{\sigma^2} \sqrt{(\mathbf{X}'\mathbf{X})_{kk}^{-1}}}}{\frac{\sqrt{\hat{\sigma}^2}}{\sqrt{\sigma^2}}} \\
&= \frac{(\hat{\beta}_k - \beta_k) \sqrt{\sigma^2}}{\sqrt{\hat{\sigma}^2} \sqrt{\sigma^2} \sqrt{(\mathbf{X}'\mathbf{X})_{kk}^{-1}}} \\
&= \frac{\hat{\beta}_k - \beta_k}{\sqrt{\hat{\sigma}^2(\mathbf{X}'\mathbf{X})_{kk}^{-1}}}
\end{aligned}$$

De esta forma:

$$t = \frac{\hat{\beta}_k - \beta_k}{\sqrt{\hat{\sigma}^2(\mathbf{X}'\mathbf{X})_{kk}^{-1}}} \sim t_{n-k} \quad (3.33)$$

Construida esta expresión (3.33) podemos establecer el siguiente intervalo de confianza para cada uno de nuestros estimadores $\hat{\beta}_k$:

$$-t_{\alpha/2, n-K} \sqrt{\hat{\sigma}^2(\mathbf{X}'\mathbf{X})_{kk}^{-1}} < \hat{\beta}_k - \beta_k < t_{\alpha/2, n-K} \sqrt{\hat{\sigma}^2(\mathbf{X}'\mathbf{X})_{kk}^{-1}}$$

$$\hat{\beta}_k - t_{\alpha/2, n-K} \sqrt{\hat{\sigma}^2(\mathbf{X}'\mathbf{X})_{kk}^{-1}} < \beta_k < \hat{\beta}_k + t_{\alpha/2, n-K} \sqrt{\hat{\sigma}^2(\mathbf{X}'\mathbf{X})_{kk}^{-1}}$$

Donde $t_{\alpha/2, n-K}$ es el valor crítico de tablas t-Student. Así, podemos enunciar que el estimador de MCO de la ecuación (3.8) se sujetará a la siguiente

prueba de hipótesis general:

$$\begin{aligned} H_0 : \beta_k &= r \\ H_a : \beta_k &\neq r \end{aligned}$$

Donde $k = 1, 2, \dots, K$ y r es un valor respecto del cual se desea comparar a $\hat{\beta}_k$. Dicha prueba se distribuye como una t_{n-K} y su especificación más común en el análisis de regresión es la siguiente:

$$\begin{aligned} H_0 : \beta_k &= 0 \\ H_a : \beta_k &\neq 0 \end{aligned}$$

Lo que en términos de una prueba t es la siguiente:

$$t = \frac{\hat{\beta}_k - 0}{\sqrt{\hat{\sigma}^2 (\mathbf{X}'\mathbf{X})_{kk}^{-1}}} \sim t_{n-k} \quad (3.34)$$

Dicha prueba la podemos interpretar como sí es posible que el estimador $\hat{\beta}_k$ sea igual a 0, o en términos económicos, si existe evidencia estadística de que el efecto de la variable x_k en y es nulo.

Como se mostró anteriormente, sólo se hemos hablado de pruebas de hipótesis cuándo se desea comprobar si alguno de los estimadores $\hat{\beta}_k$ de MCO es estadísticamente igual a algún valor determinado. No obstante, en ciertas condiciones puede ser interesante cuestionar si en conjunto todos los estimadores cumplen una cierta restricción. A este tipo de situaciones se les suele conocer como pruebas de hipótesis globales. Sin pérdida de generalidad podemos enunciar a una prueba global como:

$$\begin{aligned} H_0 : \mathbf{R}\boldsymbol{\beta} &= \mathbf{r} \\ H_a : \mathbf{R}\boldsymbol{\beta} &\neq \mathbf{r} \end{aligned}$$

Donde, $\boldsymbol{\beta}$ es el vector de parámetros del MCO de la ecuación (3.8), $\mathbf{R}$ y $\mathbf{r}$ son de la siguiente manera:

$$\mathbf{R} = \begin{bmatrix} R_{11} & R_{12} & \dots & R_{1K} \\ R_{21} & R_{22} & \dots & R_{2K} \\ R_{31} & R_{32} & \dots & R_{3K} \\ \vdots & \vdots & \dots & \vdots \\ R_{J1} & R_{J2} & \dots & R_{JK} \end{bmatrix}$$

En $\mathbf{R}$ cada una de las R_{jk} toma el valor de 1 o 0, según sea la estructura de la restricción. Con $j = 1, 2, \dots, J$. En el caso de $\mathbf{r}$:

$$\mathbf{r} = \begin{bmatrix} r_1 \\ r_2 \\ r_3 \\ \vdots \\ r_J \end{bmatrix}$$

Donde cada uno de los r_j representa el valor de la restricción que es evaluada. No debe pasar desapercibido que en este caso existen J restricciones ($J \leq K$), mismas que se evalúan de forma conjunta en una sola prueba. Esa es la ventaja de la prueba que se enuncia a continuación.

Definamos a F de Fisher como la razón de dos pruebas t de Student, la primera para los valores de una combinación lineal de $\hat{\beta}$, y la segunda para el estimador de la varianza $\hat{\sigma}^2$:

$$\begin{aligned} \mathbf{F} &= \frac{(\mathbf{R}\hat{\beta} - \mathbf{r})'[\mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}']^{-1}(\mathbf{R}\hat{\beta} - \mathbf{r})/J}{\hat{\sigma}^2} \\ &= \frac{(\mathbf{R}\hat{\beta} - \mathbf{r})'[\mathbf{R}\hat{\sigma}^2(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}']^{-1}(\mathbf{R}\hat{\beta} - \mathbf{r})}{J} \\ &= \frac{(\mathbf{R}\hat{\beta} - \mathbf{r})'[\mathbf{R}Var(\hat{\beta})\mathbf{R}']^{-1}(\mathbf{R}\hat{\beta} - \mathbf{r})}{J} \end{aligned}$$

Por lo tanto la estadística F de prueba será:

$$F = \frac{(\mathbf{R}\hat{\beta} - \mathbf{r})'[\mathbf{R}\hat{\sigma}^2(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}']^{-1}(\mathbf{R}\hat{\beta} - \mathbf{r})}{J} \sim F_{J, n-K} \quad (3.35)$$

Así, la prueba de hipótesis que es la más común en el análisis de regresión y que se le conoce como prueba global. Dicha prueba asume una forma de la matriz $\mathbf{R}$ definida así:

$$\mathbf{R} = \begin{bmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ 0 & 0 & \dots & 0 \\ \vdots & \vdots & \dots & \vdots \\ 0 & 0 & \dots & 1 \end{bmatrix}$$

Y un vector $\mathbf{r}$:

$$\mathbf{r} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

De esta forma la hipótesis nula de una prueba global se puede escribir como:

$$\begin{aligned} H_0 : & \quad \beta_1 = \beta_2 = \dots = \beta_K = 0 \\ H_a : & \quad \text{No } H_0 \end{aligned}$$

Esta prueba se le conoce como prueba global, ya que prueba si en conjunto todas las variables independientes tienen un efecto nulo en $\mathbf{Y}$.

Pero ahora discutamos qué sucede cuando no se cumplen los supuestos. El primer caso es cuando no se cumple la ecuación (3.23). La respuesta es que en ese caso MCO no generará un estimador consistente. La solución a ese problema es la implementación del Método de Variables Instrumentales que discutiremos más adelante.

Por otro lado, en los casos en que existe un término de error heterocedástico, es decir, que no cumple con la ecuación (3.30), podemos corregir el problema mediante la matriz de White, la cual asume que la varianza asintótica de $\hat{\beta}$ estará dada por:

$$\widehat{AVar}(\hat{\beta}) = (\mathbf{X}'\mathbf{X})^{-1}(\mathbf{X}'\mathbf{W}\mathbf{X})(\mathbf{X}'\mathbf{X})^{-1} \quad (3.36)$$

Donde $\mathbf{W}$ es una matriz diagonal de dimensión $N \times N$ y cada uno de los elementos de la diagonal resultan de $w_i = e_i^2$, considerando que: $e_i = y_i - \mathbf{x}_i'\hat{\beta}$. Esta matriz por la que se pondera la varianza en la ecuación (3.36) fue introducida en la econometría por White en 1980.

La heterocedasticidad modelada y corregida de esta manera se conoce como errores estándar robustos. Una vez que podemos determinar los errores estándar, tendremos la posibilidad de establecer pruebas como la t . No obstante, cuando el supuesto de la ecuación (3.28) no se cumple diremos que la prueba F usual será errónea y no será válida para probar restricciones múltiples.

En este caso nos referimos a casos como:

$$H_0 : \mathbf{R}\beta = r$$

Donde $\mathbf{R}$ es una matriz de restricciones de dimensión $Q \times K$, con $Q \leq K$, r es un vector de dimensión $Q \times 1$. Así en casos de heterocedasticidad utilizaremos una prueba de Wald dada por:

$$\mathbf{W} = (\mathbf{R}\hat{\boldsymbol{\beta}} - r)'(\mathbf{R}\hat{\mathbf{V}}\mathbf{R}')^{-1}(\mathbf{R}\hat{\boldsymbol{\beta}} - r)$$

Donde $\hat{\mathbf{V}} = \widehat{AVar(\hat{\boldsymbol{\beta}})}$, por lo que la distribución de $\mathbf{W}$ será como:

$$\mathbf{W} \sim \chi_Q^2$$

Lo que implica que la formulación $F_{Q,N-K}$ no es de aplicación.

Otro tipo de pruebas que pueden realizarse son aquellas basadas en Multiplicadores de Lagrange. Supongamos un modelo lineal particionado de la siguiente manera:

$$y_i = \mathbf{x}_{i1}\boldsymbol{\beta}_1 + \mathbf{x}_{i2}\boldsymbol{\beta}_2 + \varepsilon \quad (3.37)$$

Donde se cumplen los supuestos dados en las ecuaciones (3.23), (3.24) y (3.28), y $\mathbf{x}_1$ y $\mathbf{x}_2$ son vectores de dimensión $1 \times K_1$ y $1 \times K_2$, respectivamente.

Supongamos que desemos probar la hipótesis de que:

$$H_0 : \boldsymbol{\beta}_2 = \mathbf{0}$$

Sea $\tilde{\boldsymbol{\beta}}_1$ el estimador de $\boldsymbol{\beta}_1$ bajo la hipótesis nula anterior, digamos que este estimador corresponde al modelo restringido. Definamos los residuales:

$$e_i = y_i - \mathbf{x}_{i1}\tilde{\boldsymbol{\beta}}_1$$

Bajo la hipótesis nula, $\mathbf{x}_{i2}$ debería ser una variable no correlacionada con e_i . En este caso la prueba estadística es obtenida como sigue:

1. Corremos una regresión de e_i en $\mathbf{x}_{i1}$ y $\mathbf{x}_{i2}$
2. Asumiendo que $\mathbf{x}_{i1}$ contiene término constante, digamos que R_E^2 denota al R^2 asociado a la regresión.
3. Entonces proponemos que la estadística de Multiplicadores de Lagrange es:

$$LM = N \cdot R_E^2$$

Para llegar a la expresión anterior se requiere de solucionar un problema de optimización.

4. Bajo la H_0 , tenemos que:

$$LM \sim \chi_{K_2}^2$$

Donde K_2 es el número de restricciones que hemos probado. De esta forma, si $N \cdot R_E^2$ es suficientemente grande, entonces e_i estaba significativamente correlacionado con $\mathbf{x}_{i2}$, por lo que la hipótesis debió ser rechazada.

En este punto debe quedar claro que R^2 requiere que $\sum_{i=1}^N e_i = 0$, lo que implica que el modelo tiene un término constante.

Veamos un ejemplo ilustrativo. Sea la siguiente ecuación:

$$\begin{aligned} \ln(\text{Salario}) = & \beta_1 + \beta_2 \text{Experiencia} + \beta_3 \text{Experiencia}^2 \\ & + \beta_4 \text{Educacion} + \beta_5 \text{Edad} + \beta_6 \text{NumHijos} + \varepsilon \end{aligned}$$

Supongamos que la hipótesis que queremos probar es:

$$H_0 : \beta_4 = \beta_5 = 0$$

3.6. Ejercicios

Ahora proponemos los siguientes ejercicios:

1. Utilice el material hasta ahora expuesto en el curso para analizar y determinar si las siguientes afirmaciones son FALSAS o VERDADERAS.

a) Cuando se realiza un proceso de estimación por el método de MCO, la suma de los errores resultantes siempre es igual a cero, es decir,

$$\sum_{i=1}^n e_i = 0$$

b) Suponga que realiza una estimación por el método de mínimos cuadrados de la ecuación dada por $y_i = \beta_2 x_{i2} + \beta_3 x_{i3} + \dots + \beta_K x_{iK} + \varepsilon_i$, para $i = 1, 2, \dots, N$. Asimismo, suponga que como resultado de su estimación encuentra que la estadística R^2 es muy próxima al valor de 0.5, entonces ¿se puede decir que las variables dadas por $x_{i2}, x_{i3}, \dots, x_{iK}$ explican aproximadamente la mitad de la variabilidad de la variable y_i ?

c) Suponga que estima una ecuación de salario dada por:

$$salario_i = \beta_1 + \beta_2 educa_i + \beta_3 educa_i^2 + \beta_4 DSexo_i + \varepsilon_i$$

Donde todas los estimadores $\hat{\beta}_k$, $k = 1, 2, 3, 4$ son estadísticamente significativos; $i = 1, 2, \dots, N$; $salario_i$ es el ingresos mensual por sueldos y salarios de una persona; $educa_i$ es la educación de una persona en años, y $DSexo_i$ es una variable dummy que toma el valor de 1 si el individuo es hombre y 0 en cualquier otro caso. Asuma que los resultados indican que: $\hat{\beta}_2 > 0$ y $\hat{\beta}_3 < 0$. Entonces, ¿podemos afirmar que existe evidencia estadística de la presencia de rendimientos marginales decrecientes de la educación en los salarios?

d) Asuma que estima una regresión de los salarios de las personas en una cierta industria y encuentra que sus resultados son:

$$\hat{y}_i = \underset{(2.5)}{5.15} + \underset{(0.3)}{1.17} x_i$$

Donde y_i es el salario mensual en miles de pesos de las personas, y x_i es una variable dummy que toma el valor de 1 cuando el individuo i es hombre y 0 cuando es mujer. Entre paréntesis se indica los errores estándar de los estimadores (conocidos como término respectivo a $\hat{\sigma}^2(\mathbf{X}'\mathbf{X})_{kk}^{-1}$).

Entonces, existe evidencia estadística y significativa para afirmar que la mejor estimación al salario de los hombres es 5.15 mil pesos y para las mujeres es de 6.31 mil pesos.

2. Suponga que ha decidido estimar una regresión del logaritmo natural del salario en función de un conjunto de variables para un conjunto de individuos en una industria; de tal forma que obtiene los resultados mostrados en el Cuadro 3.1.

En donde la variables son como se describe a continuación:

- a) Masculino: es una variable binaria que toma el valor de 1 (uno) cuando el individuo es del sexo masculino y 0 (cero) en cualquier otro caso.

Cuadro 3.1: Resultados de la regresión de salarios

Variable	Coefficiente	Error Estándar	Estadística t
Constante	4.216	0.078	
Masculino	0.154	0.005	
Primaria	0.224	0.018	
Secundaria	0.833	0.063	
Preparatoria	0.902	0.063	
Univesidad	0.550	0.065	8.462
ln(Experiencia)	0.907		22.535
Primaria×Masculino	-0.97		-1.242
Secundaria×Masculino	-0.67		-2.272
Preparatoria×Masculino	-0.72		-2.317
Univesidad×Masculino	-0.146	0.076	
ln(Experiencia)×Masculino	0.041		4.891
$R^2 = 0.6032$	$F = 89.69$	$n = 1,000$	$e'e = 415.37$

- b) Primaria, Secundaria, Preparatoria y Universidad: son un conjunto de variables categóricas (Dummy) que indican el nivel máximo de estudios del individuo, es decir, toman el valor de 1 si el individuo cumple con la categoría y cero si su nivel máximo de estudios es algún otro nivel. Por lo tanto hemos dejado fuera la dummy que indica nula educación.
- c) Experiencia: es una variable que indica el número de años de experiencia del individuo.

Se le solicita:

- a) Completar el Cuadro 3.1, así como indicar la hipótesis nula y alternativa asociada. También deberá determinar cuales de las variables incluidas en la regresión resultan estadísticamente significativas.
- b) Utilizando la información de Cuadro 3.1 determine la hipótesis nula y alternativa para saber si el logaritmo natural de la experiencia es estadísticamente igual a 1. realice la prueba t asociada y concluya si se puede rechazar la hipótesis nula.

- c) Utilizando la información de Cuadro 3.1 determine y explique cuál es el Efecto Marginal de la variable Universidad.
3. Cómo se modifica el resultado expresado en la ecuación (3.15) cuando el R^2 no es respecto de la media $\bar{y}$, es decir, cuando la variación total es como se muestra en la ecuación (3.38):

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (y_i - 0)^2 \quad (3.38)$$

4. Un embotellador de bebidas gaseosas analiza las rutas de servicio de las máquinas expendedoras en su sistema de distribución. Le interesa predecir el tiempo necesario para que el representante de ruta atienda las máquinas expendedoras en una tienda. Esta actividad de servicio consiste en abastecer la máquina con productos embotellados, y algo de mantenimiento o limpieza. El ingeniero industrial responsable del estudio ha sugerido que las dos variables más importantes que afectan el tiempo de entrega, y , son la cantidad de cajas de producto abastecido, x_1 , y la distancia caminada por el representante, x_2 . El ingeniero ha reunido una muestra aleatoria de algunas observaciones de tiempo de entrega.

Suponga que desea estimar la ecuación de regresión asumiendo una media condicional dada por:

$$\mu_{y_i|x_{i1},x_{i2},x_{i3}} = \beta_1 + \beta_2 x_{i2} + \beta_3 x_{i3} \quad (3.39)$$

Derivado de la operación matricial de la muestra suponga que obtiene los siguientes resultados:

$$= \begin{bmatrix} \sum y_i^2 & \sum y_i x_{i1} & \sum y_i x_{i2} & \sum y_i x_{i3} \\ \sum x_{i1} y_i & \sum x_{i1}^2 & \sum x_{i1} x_{i2} & \sum x_{i1} x_{i3} \\ \sum x_{i2} y_i & \sum x_{i2} x_{i1} & \sum x_{i2}^2 & \sum x_{i2} x_{i3} \\ \sum x_{i3} y_i & \sum x_{i3} x_{i1} & \sum x_{i3} x_{i2} & \sum x_{i3}^2 \end{bmatrix} = \begin{bmatrix} 18310.63 & 559.60 & 7375.44 & 324972.70 \\ 559.60 & 25.00 & 219.00 & 9932.00 \\ 7375.44 & 219.00 & 3055.00 & 129099.00 \\ 324972.69 & 9932.00 & 129099.00 & 6402888.00 \end{bmatrix} \quad (3.40)$$

Al respecto:

- a)* Determine los coeficientes β de regresión lineal
- b)* Determine el valor de la varianza estimada de los errores: $\hat{\sigma}^2$
- c)* Pruebe la hipótesis nula de que $\beta_2 = 0$ con un $\alpha = 0.05$
- d)* Pruebe la hipótesis nula de que $\beta_3 = 0$ con un $\alpha = 0.05$
- e)* Escriba una conclusión de las dos pruebas de hipótesis planteadas
- f)* Determine el valor del R^2 asociado al caso, para ello recuerde que el procedimiento empleado para determinar la ecuación (3.15)

4

Estimación de modelos lineales de una sola ecuación por el método de Variables Instrumentales

4.1. Introducción y motivación

El método de Variables Instrumentales (VI o IV, por sus siglas en inglés) es el segundo método después de MCO más utilizado en el análisis de regresión. Principalmente, la implementación de IV bajo un procedimiento conocido como Mínimos Cuadrados Ordinarios en 2 Etapas (en inglés Two-Stage Least Squares (2SLS)). Para iniciar partamos de un modelo lineal:

$$y = \beta_1 x_1 + \dots + \beta_k x_k + \varepsilon \quad (4.1)$$

Donde asumimos que $\mathbb{E}[\varepsilon] = 0$ y $Cov[x_j, \varepsilon] = 0$, para $j = 1, 2, \dots, K - 1$. Así, asumiremos que la variable x_K es la única que está correlacionada con el término de error de forma que $Cov[x_K, \varepsilon] \neq 0$. En otras palabras, diremos que sólo las variables $x_1, x_2, \dots, x_{K-1}$ son exógenas y que potencialmente x_K es una variable endógena en la ecuación (4.1).

El método de IV provee una solución general al problema de endogeneidad de una o múltiples variables explicativas. Para utilizar el procedimiento necesitamos encontrar una variable observable z , que no éste incluida en la ecuación (4.1) y que además cumpla con las siguientes dos condiciones:

1. z no debe estar correlacionada con ε , es decir:

$$Cov[z, \varepsilon] \neq 0$$

Es decir, que el siguiente vector de variables explicativas son exógenas:
 $\{x_1, x_2, \dots, x_{K-1}, z\}$.

2. La proyección lineal de x_K en todas las variables exógenas estará dada por:

$$x_K = \delta_0 + \delta_1 x_1 + \dots + \delta_{K-1} x_{K-1} + \theta z + \xi_K$$

Donde $\mathbb{E}[\xi_K] = 0$, y ξ_K no está correlacionado con $\{x_1, x_2, \dots, x_{K-1}, z\}$ y $\theta \neq 0$

Si $Cov(z, \varepsilon) = 0$ y $x_K = \delta_0 + \delta_1 x_1 + \dots + \delta_{K-1} x_{K-1} + \theta z + \xi_K$, entonces z es una variable instrumental para x_K . A la proyección $x_K = \delta_0 + \delta_1 x_1 + \dots + \delta_{K-1} x_{K-1} + \theta z + \xi_K$ la denominaremos como la forma reducida. Si introducimos la forma reducida en la ecuación (4.1) podríamos plantear una expresión como:

$$y = \alpha_0 + \alpha_1 x_1 + \dots + \alpha_{K-1} x_{K-1} + \lambda z + \nu$$

Donde $\nu = \varepsilon + \beta_K \xi_K$ es la forma reducida del término de error, $\alpha_j = \beta_j + \beta_K \delta_j$, $\alpha_0 = \beta_K \delta_0$ y $\lambda = \beta_K \theta$.

4.2. Estimación por Mínimos Cuadrados en Dos Etapas – 2SLS

Ahora plateamos la situación al problema de estimación. Para verlo, partamos:

$$y_i = \mathbf{x}_i' \boldsymbol{\beta} + \varepsilon_i$$

Asumamos:

$$\begin{aligned} \mathbf{x}_i &= (1, x_{i2}, \dots, x_{iK}) \\ \mathbf{z}_i &= (1, x_{i2}, \dots, x_{iK-1}, z) \end{aligned}$$

Donde $\mathbf{z}_i$ tiene todas las variables exógenas, por lo que cumple con:

$$\mathbb{E}[\mathbf{z}_i' \varepsilon] = \mathbf{0}$$

De esta forma, podríamos multiplicar la ecuación (4.2) por $\mathbf{z}_i$ y tomamos valor esperado, obtendríamos:

$$\begin{aligned}\mathbf{z}'_i y_i &= \mathbf{z}'_i \mathbf{x}_i \boldsymbol{\beta} + \mathbf{z}'_i \varepsilon_i \\ \mathbb{E}[\mathbf{z}' y] &= \mathbb{E}[\mathbf{z}' \mathbf{x}] \boldsymbol{\beta} + \mathbb{E}[\mathbf{z}' \varepsilon]\end{aligned}$$

Donde $\mathbf{z}' \mathbf{x}$ es de rango $K \times K$ y $\mathbf{z}' y$ es de $K \times 1$. Por lo tanto, la solución poblacional estará dada por:

$$\begin{aligned}\hat{\boldsymbol{\beta}} &= (\mathbb{E}[\mathbf{z}' \mathbf{x}])^{-1} \mathbb{E}[\mathbf{z}' y] \\ &= \left(N^{-1} \sum_{i=1}^N \mathbf{z}'_i \mathbf{x}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{z}'_i y_i \right) \\ &= (\mathbf{Z}' \mathbf{X})^{-1} \mathbf{Z}' \mathbf{Y}\end{aligned}$$

Por lo tanto el estimador de Variables Instrumentales estará dado por:

$$\hat{\boldsymbol{\beta}} = (\mathbf{Z}' \mathbf{X})^{-1} \mathbf{Z}' \mathbf{Y} \quad (4.2)$$

Donde $\mathbf{Z}$ y $\mathbf{X}$, ambas, son dimensión $N \times K$. Ahora veamos un ejemplo para el caso de estimación por VI en el caso de variables omitidas puesto que la variable es no observable.

Supongamos una ecuación del logaritmo de los salarios para una muestra dada, la cual estima de la forma:

$$\ln(\text{Salario}) = \beta_1 + \beta_2 \text{Experiencia} + \beta_3 \text{Experiencia}^2 + \beta_4 \text{Educacion} + \varepsilon$$

Donde ε está correlacionado con la variable de *Educacion*, ya que en la estimación hemos omitido las variables relacionadas con la habilidad, así como otros factores, tales como calidad de la educación y los antecedentes basados en condiciones familiares.

Suponngamos que ha sido posible identntificar la educación de la madre, la cual no está correlacionada con el término ε , pero si lo está con los factores omitidos.

4.3. Método de Variables Instrumentales en casos con múltiples instrumentos

Consideremos un modelo como el de la ecuación (4.1), donde x_K puede estar correlacionada con el ε . Asumamos que tenemos más de una variable

instrumental para x_K , las cuales:

$$\{z_1, z_2, \dots, z_M\}$$

Cada una de las variables cumple con $Cov(z_h, \varepsilon) = 0$, $h = 1, 2, \dots, M$. Así, cada una de las variables z_h es exógena, por lo que cualquier combinación lineal de:

$$\{x_1, x_2, \dots, x_{K-1}, z_1, z_2, \dots, z_M\}$$

será exógena o no estará correlacionada con ε . Digamos que el vector que incluye las variables anteriores será definido como por uno de dimensión $1 \times L$, donde $L = K + M$:

$$\mathbf{z} = (1, x_1, x_2, \dots, x_{K-1}, z_1, z_2, \dots, z_M)$$

Entonces, podemos escribir la forma reducida como:

$$x_k = \delta_0 + \delta_1 x_1 + \dots + \delta_{K-1} x_{K-1} + \theta_1 z_1 + \dots + \theta_M z_M + \xi_K$$

Dado que hemos asumido que ξ_K no está correlacionado con el resto de los regresores, entonces podemos establecer que:

$$x_K^* = \delta_0 + \delta_1 x_1 + \dots + \delta_{K-1} x_{K-1} + \theta_1 z_1 + \dots + \theta_M z_M$$

es la parte de x_K que está correlacionada con ε .

Partiendo de lo anterior podemos escribir una ecuación para $\hat{x}_K$ de la forma:

$$\hat{x}_{iK} = \hat{\delta}_0 + \hat{\delta}_1 x_{i1} + \dots + \hat{\delta}_{K-1} x_{iK-1} + \hat{\theta}_1 z_{i1} + \dots + \hat{\theta}_M z_{iM}$$

Entonces podemos definir al vector:

$$\hat{\mathbf{x}}_K = (x_{i1}, \dots, x_{iK-1}, \hat{x}_{iK})$$

Usando lo anterior podemos utilizar el estimado de IV para determinar:

$$\begin{aligned} \hat{\beta} &= \left(\sum_{i=1}^N \hat{\mathbf{x}}_K \mathbf{x}_K \right)^{-1} \left(\sum_{i=1}^N \hat{\mathbf{x}}_K y \right) \\ &= (\hat{\mathbf{X}}' \mathbf{X})^{-1} \hat{\mathbf{X}}' \mathbf{Y} \end{aligned} \tag{4.3}$$

Por otro lado, podemos establecer el siguiente vector:

$$\mathbf{z}_i = (1, x_{i1}, \dots, x_{iK-1}, z_{i1}, \dots, z_{iM})$$

Contruyendo de forma simimar a otras matrices a $\mathbf{Z}$ apilado la información de cada uno de los individuos. De esta forma podremos constriuir $\hat{\mathbf{X}}$ mediante el uso de un estimador de MCO:

$$\begin{aligned}\hat{\mathbf{X}} &= \mathbf{Z}\hat{\boldsymbol{\gamma}} \\ &= \mathbf{Z}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'\mathbf{X}\end{aligned}$$

De lo anterior tendríamos que:

$$\hat{\mathbf{X}}' = \mathbf{X}'\mathbf{Z}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'$$

Usando las expresiones anteriores en la ecuación (4.3), obtenemos que:

$$\begin{aligned}\hat{\boldsymbol{\beta}} &= (\mathbf{X}'\mathbf{Z}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'\mathbf{X})^{-1}\hat{\mathbf{X}}'\mathbf{Y} \\ &= (\mathbf{X}'\mathbf{Z}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'\mathbf{Z}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'\mathbf{X})^{-1}\hat{\mathbf{X}}'\mathbf{Y} \\ &= (\hat{\mathbf{X}}'\hat{\mathbf{X}})^{-1}\hat{\mathbf{X}}'\mathbf{Y}\end{aligned}\tag{4.4}$$

De forma similar al caso de MCO proponemos el siguiente estimador de la varianza del término de error:

$$\hat{\sigma}^2 = \sum_{i=1}^N \frac{e_i^2}{N-K}\tag{4.5}$$

Utilizando la ecuación (4.4) establecemos que la varianza de $\hat{\boldsymbol{\beta}}$ estará dada por:

$$Var(\hat{\boldsymbol{\beta}}) = \hat{\sigma}^2(\hat{\mathbf{X}}'\hat{\mathbf{X}})^{-1}$$

De esta forma todas las pruebas de hipótesis planteadas para MCO son aplicables.

Finalmente, una prueba que se requiere es la determinar si los intrumentos no están correlacionados con el término de error, por lo que se requiere de estimar:

$$e_i = \delta_0 + \delta_1 x_1 + \dots + \delta_{K-1} + \theta z_1 + \dots + \theta_M z_M$$

De esta expresión requerimos mostrar que todos los parámetros son no significativos ya sea de forma individual o en conjunto. En este punto es posible incorporar una prueba de LM como la explicada en la sección anterior.

4.4. Ejercicios

En esta sección platearemos un caso típico del método de VI. Para lo cual le pedimos seguir la discusión y realizar las actividades que se le piden. Consideremos un modelo de equilibrio de mercado (la discusión original se encuentra en el trabajo de *Working (1927). What do statistical demand curves show?. Quarterly Journal of Economics, 41 pp. 212 - 235*). Supongamos que tenemos el siguiente modelo de demanda o modelo en su forma estructural:

$$\begin{aligned}q^d &= \alpha_0 + \alpha_1 p_i + u_i \\q^s &= \beta_0 + \beta_1 p_i + v_i\end{aligned}$$

Donde q^d es la cantidad demandada para el bien en cuestión, q^s es la cantidad ofertada, p_i es el precio de dicho bien. Los términos de error u_i y v_i representan otros factores observables que afectan o desplazan a la cantidad ofertada y a la cantidad demandada. Podemos asumir que dichos elementos u_i y v_i son factores no observables. De esta forma $\mathbb{E}[u_i] = 0$ y que $\mathbb{E}[v_i] = 0$. Adicionalment, suponga que $Cov[u_i, v_i] = 0$ y que $q^d = q^s = q$, de tal forma que el mercado está en equilibrio, por lo que tenemos:

$$q = \alpha_0 + \alpha_1 p_i + u_i \quad (4.6)$$

$$q = \beta_0 + \beta_1 p_i + v_i \quad (4.7)$$

Ambas ecuaciones tienen problemas de endogeneidad, ya que el precio p_i es endógeno en cada una de las ecuaciones, ya que se determina simultáneamente.

Utilizando las ecuaciones (4.6) y (4.7) obtenga la ecuación de demanda:

$$q_i = \frac{\alpha_1 \beta_0 - \alpha_0 \beta_1}{\alpha_1 - \beta_1} + \frac{\alpha_1 v_i - \beta_1 u_i}{\alpha_1 - \beta_1} \quad (4.8)$$

$$p_i = \frac{\beta_0 - \alpha_0}{\alpha_1 - \beta_1} + \frac{v_i - u_i}{\alpha_1 - \beta_1} \quad (4.9)$$

De esta forma hemos obtendrá dos expresiones (4.8), ecuación de demanda, y (4.9), ecuación de oferta, que representan la solución para el sistema de ecuaciones. No obstante, se puede apreciar que cada una de las variables tiene influencia del término de error de cada una de las ecuaciones, por lo que NO se pueden separar enteramente y se sule decir que tenemos un problema de endogeneidad.

A partir de la ecuación (4.9), determine la covarianza entre p_i y cada uno de los factores de cambio de la demanda (u_i) y de la oferta (v_i). Muestre que es igual a:

$$Cov(p_i, u_i) = -\frac{Var(u_i)}{\alpha_1 - \beta_1} \quad (4.10)$$

$$Cov(p_i, v_i) = \frac{Var(v_i)}{\alpha_1 - \beta_1} \quad (4.11)$$

De esta forma, el precio está correlacionado positivamente con los factores que modifican la demanda y negativamente con los factores que modifican la oferta, ello en razón de que la pendiente de la demanda es negativa ($\alpha_1 < 0$) y la de la oferta es positiva ($\beta_1 > 0$). En este caso, decimos que el problema de endogenidad se origina por el proceso de equilibrio en el mercado.

La razón de la endogenidad referida es que de la curva de demanda o de la curva de oferta no es posible inferir si los cambios en el nivel de precios o en las cantidades en el mercado son por causa de desplazamientos de la curva de oferta o de la curva de demanda. Esto significa que sólo es posible estimar la curva de oferta o de demanda si es posible observar alguno de los factores que determina a la demanda o la oferta.

Supongamos que el efecto del término de error en la cantidad ofertada, v_i , puede ser dividido en: los factores observables que están asociados a la demanda x_i y un factor no observable ζ_i que no está correlacionado con x_i . Es decir, que tenemos una formulación de la ecuación de oferta similar a:


$$q_i = \beta_0 + \beta_1 p_i + \beta_2 x_i + \zeta_i \quad (4.12)$$

De esta forma podemos decir que existe una posibilidad de que se elimine la endogeneidad, esto es, que se pueda instrumentar mediante el uso de variables asociadas a la demanda (x_i). Lo anterior, para efecto de separar del término de error la información que puede ser endógena al sistema, tal y como se muestra en la ecuación (4.12). La Figura 4.1 ilustra esta discusión para cada uno de los casos: de la demanda y de la oferta.


Esta discusión es una aplicación del Método de Variables Instrumentales (IV). Para el cual requerimos un regresor que es endógeno y que requerimos sea instrumentado. Al instrumento se le denomina variable instrumental. En este caso, es la variable x_i quién será nuestra variable instrumental. Retomemos nuestro sistema de ecuaciones de demanda y oferta. Si realizamos el

Figura 4.1: Instrumentación de la información de la demanda y la oferta, respectivamente

(a) No shifts in demand



(b) No shifts in supply



mismo procedimiento de solución del sistema de ecuaciones pero considerando a la ecuación (4.12).

Dicho lo anterior, muestre que obtendríamos un sistema que quedará como sigue:

$$p_i = \frac{\beta_0 - \alpha_0}{\alpha_1 - \beta_1} + \frac{\beta_2}{\alpha_1 - \beta_1} + \frac{\zeta_i - u_i}{\alpha_1 - \beta_1} \quad (4.13)$$

$$q_i = \frac{\alpha_1\beta_0 - \alpha_0\beta_1}{\alpha_1 - \beta_1} + \frac{\alpha_1\beta_2}{\alpha_1 - \beta_1} + \frac{\alpha_1\zeta_i - \beta_1u_i}{\alpha_1 - \beta_1} \quad (4.14)$$

En este punto, si fue posible instrumentar correctamente la variable endógena, muestre que deberá pasar que $Cov(x_i, \zeta_i) = 0$. Es decir, es esperado que no exista información endógena. Así aseguraríamos que $Cov(x_i, u_i) = 0$.

5

Estimación de sistemas de ecuaciones por el por el método de Mínimos Cuadrados Ordinarios y Mínimos Cuadrados Generalizados

5.1. Introducción a Sistemas de Ecuaciones

En esta sección analizaremos una extensión de la estimación por MCO de una sola ecuación al caso de múltiples ecuaciones para el caso de los Sistemas Ecuaciones Aparentemente No Relacionados (SUR). Adicionalmente, si el tiempo nos lo permite, incorporaremos el análisis de Mínimos Cuadrados Generalizados Factibles, en el cual propondremos una solución por el caso en el que existe heterocedásticidad, y para sistemas de ecuaciones con problemas de endogenidad. Algunas de las características de esta metodología aplican al caso de los modelos de datos panel, en estricto sentido los modelos de datos panel son un caso particular de los sistemas de ecuaciones, como lo veremos más adelante.

Supongamos un conjunto de G ecuaciones descritas como:

$$\begin{aligned} y_1 &= \mathbf{x}_1\boldsymbol{\beta}_1 + \varepsilon_1 \\ y_2 &= \mathbf{x}_2\boldsymbol{\beta}_2 + \varepsilon_2 \\ &\vdots \\ y_G &= \mathbf{x}_G\boldsymbol{\beta}_G + \varepsilon_G \end{aligned} \tag{5.1}$$

Donde $\mathbf{x}_g$ es un vector de dimensión $1 \times K_g$, y $\boldsymbol{\beta}_g$ es un vector de dimensión $K_g \times 1$, para $g = 1, 2, \dots, G$.

En muchos casos $\mathbf{x}_g$ podría ser el mismo para cada una de las G ecuaciones y, en consecuencia, $\boldsymbol{\beta}_g$ necesariamente tiene la misma dimensión. No obstante, el modelo debe permitir que los elementos en $\mathbf{x}_g$ cambien a lo largo de las ecuaciones.

Pongamos como ejemeplo un caso en el que queremos estimar funciones de demanda de las familias de un país, por ejemplo:

$$\begin{aligned} \text{Vivienda} &= \beta_{11} + \beta_{12}\text{PrecioCasas} + \beta_{13}\text{PrecioAlimentos} \\ &\quad + \beta_{14}\text{PrecioRopa} + \beta_{15}\text{Ingreso} + \beta_{16}\text{IntHogar} + \varepsilon \\ \text{Alimentos} &= \beta_{11} + \beta_{12}\text{PrecioCasas} + \beta_{13}\text{PrecioAlimentos} \\ &\quad + \beta_{14}\text{PrecioRopa} + \beta_{15}\text{Ingreso} + \beta_{16}\text{IntHogar} + \varepsilon \\ \text{Vestido} &= \beta_{11} + \beta_{12}\text{PrecioCasas} + \beta_{13}\text{PrecioAlimentos} \\ &\quad + \beta_{14}\text{PrecioRopa} + \beta_{15}\text{Ingreso} + \beta_{16}\text{IntHogar} + \varepsilon \end{aligned}$$

En general hemmos omitido el subíndice $i = 1, 2, \dots, N$, puesto que la forma adecuada de cada ecuación sería:

$$y_{ig} = \mathbf{x}_{ig} + \varepsilon_{ig}$$

En los casos como el modelo anterior en la ecuación (5.1) asumimos que no existe endogeneidad (por razones como omisión de variables, errores estándar o simultaneidad), en particular hemos asumido que existe exogenidad estricta:

$$\mathbb{E}[\varepsilon_g | \mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_g] = 0 \text{ para } g = 1, 2, \dots, G$$

De forma general podemos decir que:

$$\mathbb{E}[y_g | \mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_g] = \mathbb{E}[y_g | \mathbf{x}] = \mathbf{x}_g\boldsymbol{\beta}_g, \text{ para } g = 1, 2, \dots, G$$

5.2. Estimación de Sistemas de Ecuaciones Multivariantes

Ahora generalicemos el problema. Asumamos que tenemos observaciones de corte transversal independienntes e idénticamente distribuidas:

$$\{\mathbf{X}_i, \mathbf{Y}_i; i = 1, 2, \dots, N\}$$

Donde $\mathbf{X}_i$ es una matriz $G \times K$ y $\mathbf{Y}_i$ es un vector $G \times 1$. Así, la matriz $\mathbf{X}_i$ continene todas las variables explicativas que aparecen en el sistema, para cada uno de los individuos indexados i :

$$\mathbf{Y}_i = \mathbf{X}_i \boldsymbol{\beta} + \boldsymbol{\varepsilon}_i \quad (5.2)$$

Donde $\boldsymbol{\beta}$ es un vector $K \times 1$ y $\boldsymbol{\varepsilon}_i$ es un vector $G \times 1$. De esta forma en general tendríamos:

$$\mathbf{Y}_i = \begin{bmatrix} y_{i1} \\ y_{i2} \\ \vdots \\ y_{iG} \end{bmatrix}$$

$$\boldsymbol{\varepsilon}_i = \begin{bmatrix} \varepsilon_{i1} \\ \varepsilon_{i2} \\ \vdots \\ \varepsilon_{iG} \end{bmatrix}$$

Donde $i = 1, 2, \dots, N$.

$$\boldsymbol{\beta} = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_G \end{bmatrix}$$

Donde:

$$\boldsymbol{\beta}_g = \begin{bmatrix} \beta_{1g} \\ \beta_{2g} \\ \vdots \\ \beta_{K_g g} \end{bmatrix}$$

Y $g = 1, 2, \dots, G$. por lo que $\boldsymbol{\beta}$ es de dimensión $(K_1 + K_2 + \dots + K_G) \times 1$, considerando que $K = K_1 + K_2 + \dots + K_G$.

Par el caso particular de un modelo de ecuaciones simultáneas aparentemente no relacionadas que no compartan variables explicativas:

$$\mathbf{x}_{ig} = [x_{i1}, x_{i2}, \dots, x_{iK_g}]$$

Así, podemos proponer que la matriz $\mathbf{X}_i$ con dimensión $G \times (K_1 + K_2 + \dots + K_G)$ es de la forma:

$$\mathbf{X}_i = \begin{bmatrix} \mathbf{x}_{i1} & \mathbf{0} & \dots & \mathbf{0} \\ \mathbf{0} & \mathbf{x}_{i2} & \dots & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{0} & \mathbf{0} & \dots & \mathbf{x}_{iG} \end{bmatrix}$$

Dado el modelo de la ecuación (5.2) establecemos las condiciones de ortogonalidad para $\boldsymbol{\beta}$ como el supuesto:

$$\mathbb{E}[\mathbf{X}_i' \boldsymbol{\epsilon}_i] = \mathbf{0} \quad (5.3)$$

Dado este supuesto obtenemos que:

$$\begin{aligned} \mathbb{E}[\boldsymbol{\epsilon}_i] &= \mathbf{0} \\ \mathbb{E}[\boldsymbol{\epsilon}_{ig} | \mathbf{X}_i] &= 0 \text{ para } g = 1, 2, \dots, G \end{aligned}$$

Bajo este supuesto de ortogonalidad entonces:

$$\begin{aligned} \mathbb{E}[\mathbf{X}_i' \boldsymbol{\epsilon}_i] &= \mathbb{E}[\mathbf{X}_i' (\mathbf{Y}_i - \mathbf{X}_i \boldsymbol{\beta})] \\ \mathbb{E}[\mathbf{X}_i' \mathbf{Y}_i] &= \mathbb{E}[\mathbf{X}_i' \mathbf{X}_i] \boldsymbol{\beta} \end{aligned}$$

Donde la expresión anterior implica que $\mathbf{X}_i' \mathbf{Y}_i$ es de dimensión $X \times 1$ y $\mathbf{X}_i' \mathbf{X}_i$ es de dimensión $K \times K$ y no es una matriz singular.

De esta forma, el estimador $\boldsymbol{\beta}$ de sistemas de ecuaciones será:

$$\begin{aligned} \hat{\boldsymbol{\beta}} &= \mathbb{E}[\mathbf{X}_i' \mathbf{X}_i]^{-1} \mathbb{E}[\mathbf{X}_i' \mathbf{Y}_i] \\ &= \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{Y}_i \right) \\ &= (\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \mathbf{Y} \end{aligned}$$

Donde $\mathbf{X}$ es una matriz $NG \times K$ y $\mathbf{Y}$ es un vector de $NG \times 1$. En este punto podemos enunciar el siguiente teorema:

Teorema 5.1 *Consistencia del Sistema OLS.* Bajo los supuestos anteriores $\hat{\beta} \xrightarrow{p} \beta$

De forma similar al caso de MCO requerimos establecer una distribución para $\hat{\beta}$, partamos de:

$$\begin{aligned}\sqrt{N}(\hat{\beta} - \beta) &= \sqrt{N}((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} - \beta) \\ &= \sqrt{N}((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{X}\beta + \varepsilon) - \beta) \\ &= \sqrt{N}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\varepsilon_i \\ &= \left(N^{-1} \sum_{i=1}^N \mathbf{x}_i' \mathbf{x}_i \right)^{-1} \left(N^{-1/2} \sum_{i=1}^N \mathbf{x}_i' \varepsilon_i \right)\end{aligned}$$

De esta forma, por el Teorema del Límite Central:

$$N^{-1/2} \sum_{i=1}^N \mathbf{x}_i' \varepsilon_i \xrightarrow{d} N(0, \Sigma)$$

Donde $\Sigma = \mathbb{E}[\mathbf{X}'\varepsilon\varepsilon'\mathbf{X}] = Var(\mathbf{X}'\varepsilon)$. Así, si el modelo es homocedástico:

$$\Sigma = \sigma^2(\mathbf{X}'\mathbf{X})^{-1} \quad (5.4)$$

$$Var(\hat{\beta}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1} \quad (5.5)$$

Donde:

$$\hat{\sigma}^2 = \frac{\mathbf{e}'\mathbf{e}}{N - K}$$

Si el modelo tiene heterocedasticidad la varianza asintótica de $\hat{\beta}$ estará dada por:

$$Var(\hat{\beta}) = (\mathbf{X}'\mathbf{X})^{-1}(\mathbf{X}'\mathbf{e}\mathbf{e}'\mathbf{X})(\mathbf{X}'\mathbf{X})^{-1}$$

Finalmente, podemos establecer las mismas pruebas de hipótesis que en el caso de MCO.

5.3. Mínimos Cuadrados Generalizados

Como vimos en la sección anterior, podemos generalizar un modelo de regresión lineal commola ecuación:

$$\mathbf{Y} = \mathbf{X}\beta + \varepsilon$$

Donde el número de elementos o individuos en la muestra es N (segmentada de la forma que sea, en el caso de un sistema de ecuaciones) y el número de variables en $\mathbf{X}$ es K (segmenta de la forma que sea). Asimismo, del cual asumimos que se cumplen:

$$\begin{aligned}\mathbb{E}[\boldsymbol{\varepsilon}|\mathbf{X}] &= \mathbf{0} \\ \mathbb{E}[\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}'|\mathbf{X}] &= \Sigma = \sigma^2\Omega\end{aligned}$$

En general, Σ puede contener elementos que nos indiquen un problema de heterodadística y autocorrelación. Sin embargo, para nuestro caso utilizaremos como supuesto que el modelo sólo tienen heterocedística, de esta forma enfrentaremos un caso en el que la matriz estará dada por:

$$\begin{aligned}\Sigma &= \sigma^2\Omega \\ &= \begin{bmatrix} \sigma_1^2 & 0 & \dots & 0 \\ 0 & \sigma_2^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_n^2 \end{bmatrix} \\ &= \sigma^2 \begin{bmatrix} \omega_1 & 0 & \dots & 0 \\ 0 & \omega_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \omega_n \end{bmatrix}\end{aligned}$$

No debe pasar desapercibido que en el caso de que en el modelo exista autocorrelación es posible que enfrentemos una matriz como:

$$\Sigma = \begin{bmatrix} \sigma_1^2 & \rho_1 & \dots & \rho_{n-1} \\ \rho_1 & \sigma_2^2 & \dots & \rho_{n-2} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{n-1} & \rho_{n-2} & \dots & \sigma_n^2 \end{bmatrix}$$

En estos casos es cuando necesitamos un procedimiento del tipo de Mínimos Cuadrados Generalizados. El método consiste en un algoritmo que asume que:

$$\begin{aligned}\Sigma^{-1} &= \mathbf{P}'\mathbf{P} \\ &= \Sigma' \\ \Sigma &= \mathbf{P}\mathbf{P}'\end{aligned}$$

Si lo anterior es posible, entonces podemos establecer un nuevo modelo lineal como:

$$\begin{aligned}\mathbf{PY} &= \mathbf{PX}\boldsymbol{\beta} + \mathbf{P}\boldsymbol{\varepsilon} \\ \mathbf{Y}_* &= \mathbf{X}_*\boldsymbol{\beta} + \boldsymbol{\varepsilon}_*\end{aligned}\tag{5.6}$$

Así, los supuestos necesarios para resolver el problema de regresión en la ecuación (5.6) son:

$$\begin{aligned}\mathbb{E}[\boldsymbol{\varepsilon}_*|\mathbf{X}_*] &= \mathbf{0} \\ \mathbb{E}[\boldsymbol{\varepsilon}_*\boldsymbol{\varepsilon}_*'\mathbf{X}_*] &= \sigma^2\mathbb{I}_n\end{aligned}$$

La explicación para este último resultado es que:

$$\begin{aligned}\mathbb{E}[\boldsymbol{\varepsilon}_*\boldsymbol{\varepsilon}_*'\mathbf{X}_*] &= \mathbb{E}[\mathbf{P}\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}'\mathbf{P}'|\mathbf{X}] \\ &= \mathbf{P}\mathbb{E}[\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}'|\mathbf{X}]\mathbf{P}' \\ &= \mathbf{P}\boldsymbol{\Sigma}\mathbf{P}' \\ &= \sigma^2\mathbb{I}_n\end{aligned}$$

Bajo esta condición, veríamos que el estimador de Mínimos Cuadrados estará dado por:

$$\begin{aligned}\hat{\boldsymbol{\beta}} &= (\mathbf{X}_*'\mathbf{X}_*)^{-1}\mathbf{X}_*'\mathbf{Y}_* \\ &= (\mathbf{X}'\mathbf{P}'\mathbf{P}\mathbf{X})^{-1}\mathbf{X}'\mathbf{P}'\mathbf{P}\mathbf{Y} \\ &= (\mathbf{X}'\boldsymbol{\Sigma}^{-1}\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\Sigma}^{-1}\mathbf{Y}\end{aligned}$$

Definamos al estimador de Mínimos Cuadros Generalizados Factibles al siguiente:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\hat{\boldsymbol{\Sigma}}^{-1}\mathbf{X})^{-1}\mathbf{X}'\hat{\boldsymbol{\Sigma}}^{-1}\mathbf{Y}$$

Entonces el procedimiento consiste en determinar o estimar a $\hat{\boldsymbol{\Sigma}}$, para lo cual debemos seguir el siguiente algoritmo:

1. Asumamos una forma funcional de σ_i^2 :

$$\sigma_i^2 = \sigma^2 f(\mathbf{z}_i)$$

Donde $\mathbf{z}_i$ es un conjunto de variables que pueden explicar la heterocedasticidad.

2. Estimamos $\hat{\sigma}_i^2$, asumiendo que $\sigma_i^2 = e_i^2$, que provienen de una regresión de mínimos cuadrados ordinarios:

$$\mathbf{e} = \mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}$$

3. Determinamos cada elemento de la diagonal de la matriz $\hat{\Sigma}$ será como se describe en el inciso 2.
4. Estimamos:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\hat{\Sigma}^{-1}\mathbf{X})^{-1}\mathbf{X}'\hat{\Sigma}^{-1}\mathbf{Y}$$

En este punto la única incógnita es cómo determinar si el modelo tiene heterocedasticidad. Para lo cual planteamos una hipótesis dada por:

$$\begin{aligned} H_0 &: \sigma_i^2 = \sigma^2, \forall i \\ H_1 &: \text{No } H_0 \end{aligned}$$

Para probar la hipótesis anterior vamos a utilizar una prueba de Breusch-Pagan / Godfrey que está basada en una prueba LM. Esta prueba asume que $\sigma_i^2 = \sigma^2 f(\mathbf{z}_i)$ y propone como estadística a:

$$LM = 1/2 \cdot \begin{bmatrix} \frac{e_1^2}{\mathbf{e}'\mathbf{e}} - 1 \\ \frac{e_2^2}{\mathbf{e}'\mathbf{e}} - 1 \\ \vdots \\ \frac{e_n^2}{\mathbf{e}'\mathbf{e}} - 1 \end{bmatrix}' \mathbf{Z}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}' \begin{bmatrix} \frac{e_1^2}{\mathbf{e}'\mathbf{e}} - 1 \\ \frac{e_2^2}{\mathbf{e}'\mathbf{e}} - 1 \\ \vdots \\ \frac{e_n^2}{\mathbf{e}'\mathbf{e}} - 1 \end{bmatrix} \quad (5.7)$$

Donde la ecuación (5.7) se distribuye como:

$$LM \sim \chi^2_{[\text{Número de variables en } \mathbf{Z}]}$$

Notemos que es una convención utilizar una forma funcional de la varianza a:

$$\sigma_i^2 = \sigma^2 \cdot e^{\mathbf{z}_i\gamma}$$

5.4. Estimación de Sistemas de Ecuaciones con Variables Instrumentales

El enfoque moderno para la estimación del sistema con variables instrumentales se basa en el principio del método generalizado de momentos (GMM). Una clase relacionada de estimadores cae bajo el título de variables instrumentales generalizadas (GIV). También veremos que el estimador GIV, debido a su dependencia de una transformación similar a GLS, es inconsistente en algunos casos importantes cuando GMM permanece consistente.

Partamos de un modelo lineal:

$$\mathbf{Y}_i = \mathbf{X}_i\boldsymbol{\beta} + \boldsymbol{\varepsilon}_i \quad (5.8)$$

Donde $\mathbf{X}_i$ es una matriz $G \times K$ y $\mathbf{Y}_i$ es un vector $G \times 1$. Así, la matriz $\mathbf{X}_i$ contiene todas las variables explicativas que aparecen en el sistema, para cada uno de los individuos indexados i .

De forma similar al caso de Variables Instrumentales, podemos asumir que:

$$\mathbb{E}[\mathbf{Z}_i'\boldsymbol{\varepsilon}_i] = \mathbf{0}$$

Donde $\mathbf{Z}_i$ es una matriz $G \times L$ de variables instrumentales y $L \geq K$. También asumiremos que la matriz siguiente es de rango completo:

$$\text{rank}\mathbb{E}[\mathbf{Z}_i'\mathbf{X}_i'] = K$$

El proceso de estimación que plantearemos aquí es el del Método Generalizado de Momentos (GMM, por sus siglas en inglés). De esta forma proponemos que la condición del momento poblacional que plantearemos es:

$$\mathbb{E}[\mathbf{Z}_i'(\mathbf{Y}_i - \mathbf{X}_i\boldsymbol{\beta})] = \mathbf{0} \quad (5.9)$$

De esta forma nuestra propuesta de solución será aquella dada por elegir el estimador $\hat{\boldsymbol{\beta}}$ que resulta de:

$$N^{-1} \sum_{i=1}^N \mathbf{Z}_i'(\mathbf{Y}_i - \mathbf{X}_i\hat{\boldsymbol{\beta}}) = \mathbf{0} \quad (5.10)$$

La ecuación (5.10) es un conjunto de L ecuaciones con K incógnitas. Para analizar este caso primero consideremos el caso en el que $L = K$, es

decir, estamos en un caso de Variables Instrumentales pero para un sistema de ecuaciones. En este caso sabemos que la matriz siguiente que resulta de despejar $\hat{\beta}$ en (5.10) es de dimensión $K \times K$ y es no singular:

$$\hat{\beta} = \left(N^{-1} \sum_{i=1}^N \mathbf{Z}'_i \mathbf{X}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{Z}'_i \mathbf{Y}_i \right) \quad (5.11)$$

Lo cual podemos reescribir en forma matricial como:

$$\hat{\beta} = (\mathbf{Z}'\mathbf{X})^{-1} \mathbf{Z}'\mathbf{Y} \quad (5.12)$$

Donde, por se un sistema de ecuaciones, $\mathbf{Z}$ es una matriz de $N \times G \times L$ obtenida por el apilamiento de cada $\mathbf{Z}_i$, para $i = 1, 2, \dots, N$, $\mathbf{X}$ es una matriz de $N \times G \times K$ obtenida por el apilamiento de cada $\mathbf{X}_i$, para $i = 1, 2, \dots, N$ y $\mathbf{Y}$ es un vector de $N \times G \times 1$ obtenido por el apilamiento de cada $\mathbf{Y}_i$, para $i = 1, 2, \dots, N$. De esta forma la ecuación (5.12) es un estimado de Variables Instrumentales para un sistema de ecuaciones.

¿Qué sucede cuando $L > K$? En esos casos tenemos más columnas en la matriz de variables instrumentales $\mathbf{Z}$ que las necesarias para poder identificar el sistema. Es decir, elegir $\hat{\beta}$ es más complicado. En estos casos proponemos obtener un estimador generado mediante la creación de una matriz de pesos ("weighting matrix") en la forma cuadrática siguiente.

Sea $\hat{\mathbf{W}}$ una matriz simétrica definida positiva, definamos el estimador de GMM de $\hat{\beta}$ como aquel que resulta de resolver el problema:

$$\min_{\beta} \left[\sum_{i=1}^N \mathbf{Z}'_i (\mathbf{Y}_i - \mathbf{X}_i \beta) \right]' \hat{\mathbf{W}} \left[\sum_{i=1}^N \mathbf{Z}'_i (\mathbf{Y}_i - \mathbf{X}_i \beta) \right] \quad (5.13)$$

Dado que la ecuación (5.13) es una forma cuadrática función de β , la solución es una solución cerrada.

[FALTA procedimiento para demostrar lo siguiente]

De esta forma la solución estará dada por:

$$\hat{\beta} = (\mathbf{X}'\mathbf{Z}\hat{\mathbf{W}}\mathbf{Z}'\mathbf{X})^{-1} (\mathbf{X}'\mathbf{Z}\hat{\mathbf{W}}\mathbf{Z}'\mathbf{Y}) \quad (5.14)$$

5.4.1. Estimación de un sistema por Mínimos Cuadrados en Dos Etapas (2SLS)

Una forma de seleccionar a $\hat{\mathbf{W}}$ es la siguiente:

$$\hat{\mathbf{W}} = \left(N^{-1} \sum_{i=1}^N \mathbf{Z}'_i \mathbf{Z}_i \right)^{-1} = \left(\frac{\mathbf{Z}'\mathbf{Z}}{N} \right)^{-1} \quad (5.15)$$

Donde la ecuación (5.15) es un estimador consistente de $\mathbb{E}[\mathbf{Z}'_i \mathbf{Z}_i]^{-1}$. Reemplazando la ecuación (5.15) en la ecuación (5.14) podemos obtener:

$$\begin{aligned} \hat{\beta} &= \left(\mathbf{X}'\mathbf{Z} \left(\frac{\mathbf{Z}'\mathbf{Z}}{N} \right)^{-1} \mathbf{Z}'\mathbf{X} \right)^{-1} \left(\mathbf{X}'\mathbf{Z} \left(\frac{\mathbf{Z}'\mathbf{Z}}{N} \right)^{-1} \mathbf{Z}'\mathbf{Y} \right) \\ &= \left(\mathbf{X}'\mathbf{Z} (\mathbf{Z}'\mathbf{Z})^{-1} \mathbf{Z}'\mathbf{X} \right)^{-1} \left(\mathbf{X}'\mathbf{Z} (\mathbf{Z}'\mathbf{Z})^{-1} \mathbf{Z}'\mathbf{Y} \right) \\ &= \left(\mathbf{X}'\mathbf{Z} (\mathbf{Z}'\mathbf{Z})^{-1} (\mathbf{Z}'\mathbf{Z}) (\mathbf{Z}'\mathbf{Z})^{-1} \mathbf{Z}'\mathbf{X} \right)^{-1} \left(\mathbf{X}'\mathbf{Z} (\mathbf{Z}'\mathbf{Z})^{-1} \mathbf{Z}'\mathbf{Y} \right) \\ &= \left(\hat{\mathbf{X}}'\hat{\mathbf{X}} \right)^{-1} \hat{\mathbf{X}}'\mathbf{Y} \end{aligned} \quad (5.16)$$

A la ecuación (5.16) la conocemos como el estimador de 2SLS para un sistema de ecuaciones.

5.4.2. Estimación de un sistema por Mínimos Cuadrados en Tres Etapas (3SLS)

En algunas momentos el estimador GMM se usa con una forma particular de ponderadores. Así podemos definir el estimador de Mínimos Cuadrados en Tres Etapas, 3SLS, sean los residuales de una estimación inicial, usualmente, de un 2SLS:

$$\mathbf{e}_i = \mathbf{Y}_i - \mathbf{X}_i \hat{\beta}$$

Definamos la matrix $G \times G$ como

$$\hat{\Sigma} = N^{-1} \sum_{i=1}^N \mathbf{e}_i \mathbf{e}'_i \quad (5.17)$$

Usando los mismos argumentos de Mínimos Cuadrados Generalizados Factibles, podemos proponer que:

$$\hat{\mathbf{W}} = \left(N^{-1} \sum_{i=1}^N \mathbf{Z}'_i \hat{\boldsymbol{\Sigma}} \mathbf{Z}_i \right)^{-1} = \left(\frac{\mathbf{Z}'(\mathbf{I}_N \otimes \hat{\boldsymbol{\Sigma}})\mathbf{Z}}{N} \right)^{-1} \quad (5.18)$$

Donde $\mathbf{I}_N$ es la matriz identidad. Sustituyendo la ecuación (5.18) en la ecuación (5.14) podemos obtener:

$$\begin{aligned} \hat{\boldsymbol{\beta}} &= \left(\mathbf{X}'\mathbf{Z} \left(\frac{\mathbf{Z}'(\mathbf{I}_N \otimes \hat{\boldsymbol{\Sigma}})\mathbf{Z}}{N} \right)^{-1} \mathbf{Z}'\mathbf{X} \right)^{-1} \left(\mathbf{X}'\mathbf{Z} \left(\frac{\mathbf{Z}'(\mathbf{I}_N \otimes \hat{\boldsymbol{\Sigma}})\mathbf{Z}}{N} \right)^{-1} \mathbf{Z}'\mathbf{Y} \right) \\ &= \left(\mathbf{X}'\mathbf{Z} \left(\mathbf{Z}'(\mathbf{I}_N \otimes \hat{\boldsymbol{\Sigma}})\mathbf{Z} \right)^{-1} \mathbf{Z}'\mathbf{X} \right)^{-1} \left(\mathbf{X}'\mathbf{Z} \left(\mathbf{Z}'(\mathbf{I}_N \otimes \hat{\boldsymbol{\Sigma}})\mathbf{Z} \right)^{-1} \mathbf{Z}'\mathbf{Y} \right) \end{aligned} \quad (5.19)$$

A la ecuación (5.19) la conocemos como el estimador de 3SLS para un sistema de ecuaciones.

5.5. Ejercicios

[PENDIENTE, abril 2020]

6

Modelos de Datos Panel

6.1. Introducción y motivación

Datos panel es un caso particular del problema de sistemas de ecuaciones, no obstante, le dedicaremos una sección de estas notas. Un conjunto de datos longitudinales o conjunto de datos panel tiene múltiples observaciones para un número dado de unidades de sección cruzada. Como su nombre lo sugiere un panel tiene dos dimensiones:

1. La primera para las observaciones de sección cruzada
2. La segunda para otro tipo de observaciones, por ejemplo, tiempo u otra característica

En adelante utilizaremos 'grupo' para identificar a la unidad de sección cruzada.

La motivación principal para el concepto de datos panel es el componente de error del modelo o **sesgo por omisión de información relevante** contenida en el término de error. Esta información puede ser observable o no observable. Condición que da lugar a dos modelos tradicionales de datos panel.

El primer tipo de error está relacionado con información que no cambia a través de la segunda dimensión (por ejemplo, a través del tiempo) y que está capturada por el término de error. Este tipo de información relevante omitida no se puede solucionar por el método de variables instrumentales, puesto que no existen instrumentos como tal. A este planteamiento se le conoce como **efecto fijo**.

De forma similar existen un **efecto aleatorio** que que está contenido en el término de error y no es capturado por el ninguno de los regresores empleados. Es decir, es información del término de error que no está correlacionada con los regresores.

Así, la principal diferencia entre ambos planteamientos, como mostraré más adelante es si la información omitida está correlacionada con lo regresores o no.

6.2. Modelos y métodos de estimación

Al igual que en casos anteriores supondremos que la muestra de datos es una muestra aleatoria. De esta forma tendremos que para cada una de las unidades o grupos de individuos $i = 1, 2, \dots, n$ tendremos que M observaciones que corresponden con la segunda dimensión de nuestro panel de datos:

$$\mathbf{y}_i = \begin{bmatrix} y_{i1} \\ y_{i2} \\ y_{i3} \\ \vdots \\ y_{iM} \end{bmatrix}$$

$$\mathbf{x}_i = \begin{bmatrix} x_{i11} & x_{i12} & x_{i13} & \dots & x_{i1K} \\ x_{i21} & x_{i22} & x_{i23} & \dots & x_{i2K} \\ x_{i31} & x_{i32} & x_{i33} & \dots & x_{i3K} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{iM1} & x_{iM2} & x_{iM3} & \dots & x_{iMK} \end{bmatrix}$$

Así, para cada grupo tendremos M ecuaciones expresadas como:

$$\begin{bmatrix} y_{i1} \\ y_{i2} \\ y_{i3} \\ \vdots \\ y_{iM} \end{bmatrix} = \begin{bmatrix} x_{i11} & x_{i12} & x_{i13} & \dots & x_{i1K} \\ x_{i21} & x_{i22} & x_{i23} & \dots & x_{i2K} \\ x_{i31} & x_{i32} & x_{i33} & \dots & x_{i3K} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{iM1} & x_{iM2} & x_{iM3} & \dots & x_{iMK} \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \\ \vdots \\ \beta_K \end{bmatrix} + \begin{bmatrix} \varepsilon_{i1} \\ \varepsilon_{i2} \\ \varepsilon_{i3} \\ \vdots \\ \varepsilon_{iM} \end{bmatrix}$$

$$\mathbf{y}_i = \mathbf{x}_i \boldsymbol{\beta} + \boldsymbol{\varepsilon}_i \quad (6.1)$$

Donde:

$$\mathbb{E}[\boldsymbol{\varepsilon}_i \cdot \mathbf{x}_i] = 0$$

Así, al igual que en el caso del planteamiento del modelo lineal clásico, en datos panel asumiremos una serie de supuestos:

1. Diremos que el modelo será lineal en sus parámetros: $\mathbf{y}_i = \mathbf{x}_i\boldsymbol{\beta} + \boldsymbol{\varepsilon}_i$
2. Asumiremos que la matriz $\mathbf{x}_i$ es de rango completo $M \times K$
3. Esperamos que las variables incluidas como regresores sean exógenas, es decir, $\mathbb{E}[\boldsymbol{\varepsilon}_i|\mathbf{x}_j] = 0$ para $i, j = 1, 2, \dots, n$
4. El término de error es homocedástico y sin autocorrelación

Dicho lo anterior, para la estimación y modelación de datos panel existen tres alternativas que veremos en este curso: estimación considerando efectos fijos, estimación con efectos aleatorios y estimaciones pool ('pooled regresion').

6.2.1. Efectos Fijos

En este caso, diremos que $\mathbf{x}_i$ es una matriz de regresores exógenos. Ahora bien, supondremos que la perturbación es un componenete dado por:

$$\varepsilon_{im} = \alpha_i + \eta_{im}$$

Donde $m = 1, 2, \dots, M$. Al primer componente α_i se le conoce como el componente de los errores que es común a lo largo de la segunda dimensión, a este se le conoce como efecto individual, heterogeneidad individual o efecto fijo.

Así, la ecuación (6.1) se verá modificada para quedar como:

$$\begin{bmatrix} y_{i1} \\ y_{i2} \\ y_{i3} \\ \vdots \\ y_{iM} \end{bmatrix} = \begin{bmatrix} x_{i11} & x_{i12} & x_{i13} & \dots & x_{i1K} \\ x_{i21} & x_{i22} & x_{i23} & \dots & x_{i2K} \\ x_{i31} & x_{i32} & x_{i33} & \dots & x_{i3K} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{iM1} & x_{iM2} & x_{iM3} & \dots & x_{iMK} \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \\ \vdots \\ \beta_K \end{bmatrix} + \begin{bmatrix} \alpha_i \\ \alpha_i \\ \alpha_i \\ \vdots \\ \alpha_i \end{bmatrix} + \begin{bmatrix} \eta_{i1} \\ \eta_{i2} \\ \eta_{i3} \\ \vdots \\ \eta_{iM} \end{bmatrix}$$

$$\mathbf{x}_i = \mathbf{x}_i\boldsymbol{\beta} + \boldsymbol{\alpha}_i + \boldsymbol{\eta}_i \quad (6.2)$$

Donde

$$\begin{aligned}
\mathbb{E}[\boldsymbol{\varepsilon}_i \cdot \mathbf{x}_i] &= 0 \\
\mathbb{E}[\alpha_i \cdot x_{im}] &= 0 \\
\text{Obs} &: \text{ si la matriz de regresores tiene constante, entonces } m \neq 1 \\
\mathbb{E}[\eta_{im} \cdot x_{im}] &= 0
\end{aligned}$$

Para estimar este modelo se requiere de acomodar la información para cada uno de los grupos de forma que al final quedaría una expresión como:

$$\begin{aligned}
\begin{bmatrix} y_{11} \\ y_{12} \\ y_{13} \\ \vdots \\ y_{1M} \\ y_{2M} \\ \vdots \\ y_{2M} \\ \vdots \\ y_{n1} \\ y_{n2} \\ y_{n3} \\ \vdots \\ y_{nM} \end{bmatrix} &= \begin{bmatrix} 1 & 0 & \dots & 0 & x_{111} & x_{112} & x_{113} & \dots & x_{11K} \\ 1 & 0 & \dots & 0 & x_{121} & x_{122} & x_{123} & \dots & x_{12K} \\ 1 & 0 & \dots & 0 & x_{131} & x_{132} & x_{133} & \dots & x_{13K} \\ \vdots & \vdots & \dots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & 0 & \dots & 0 & x_{1M1} & x_{1M2} & x_{1M3} & \dots & x_{1MK} \\ 0 & 1 & \dots & 0 & x_{211} & x_{212} & x_{213} & \dots & x_{21K} \\ \vdots & \vdots & \dots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 1 & \dots & 0 & x_{2M1} & x_{2M2} & x_{2M3} & \dots & x_{2MK} \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 & x_{n11} & x_{n12} & x_{n13} & \dots & x_{n1K} \\ 0 & 0 & \dots & 1 & x_{n21} & x_{n22} & x_{n23} & \dots & x_{n2K} \\ 0 & 0 & \dots & 1 & x_{n31} & x_{n32} & x_{n33} & \dots & x_{n3K} \\ \vdots & \vdots & \dots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 & x_{nM1} & x_{nM2} & x_{nM3} & \dots & x_{nMK} \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_n \\ \beta_1 \\ \beta_2 \\ \beta_3 \\ \vdots \\ \beta_K \end{bmatrix} \\
&+ \begin{bmatrix} \eta_{11} \\ \eta_{12} \\ \eta_{13} \\ \vdots \\ \eta_{1M} \\ \vdots \\ \eta_{n1} \\ \eta_{n2} \\ \eta_{n3} \\ \vdots \\ \eta_{nM} \end{bmatrix}
\end{aligned}$$

6.2.2. Efectos Aleatorios

En este caso, igualmente que en el caso anterior, diremos que $\mathbf{x}_i$ es una matriz de regresores exógenos. Ahora bien, supondremos que la perturbación es un componente dado por:

$$\varepsilon_{im} = \nu_i + \eta_{im}$$

Donde $m = 1, 2, \dots, M$ y ν_i es una perturbación aleatoria que captura la información estocástica del individuo y que no está correlacionada con los regresores. A este componente ν_i se le conoce como el componente de los errores que es aleatorio a lo largo de la segunda dimensión, a este se le conoce como efecto aleatorio.

Así, la ecuación (6.1) se verá modificada para quedar como:

$$\begin{bmatrix} y_{i1} \\ y_{i2} \\ y_{i3} \\ \vdots \\ y_{iM} \end{bmatrix} = \begin{bmatrix} x_{i11} & x_{i12} & x_{i13} & \dots & x_{i1K} \\ x_{i21} & x_{i22} & x_{i23} & \dots & x_{i2K} \\ x_{i31} & x_{i32} & x_{i33} & \dots & x_{i3K} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{iM1} & x_{iM2} & x_{iM3} & \dots & x_{iMK} \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \\ \vdots \\ \beta_K \end{bmatrix} + \begin{bmatrix} \nu_i \\ \nu_i \\ \nu_i \\ \vdots \\ \nu_i \end{bmatrix} + \begin{bmatrix} \eta_{i1} \\ \eta_{i2} \\ \eta_{i3} \\ \vdots \\ \eta_{iM} \end{bmatrix}$$

$$\mathbf{x}_i = \mathbf{x}_i \boldsymbol{\beta} + \boldsymbol{\nu}_i + \boldsymbol{\eta}_i \quad (6.3)$$

Donde

$$\begin{aligned} \mathbb{E}[\boldsymbol{\varepsilon}_i \cdot \mathbf{x}_i] &= 0 \\ \mathbb{E}[\nu_i \cdot x_{im}] &= 0 \\ \mathbb{E}[\eta_{im} \cdot x_{im}] &= 0 \end{aligned}$$

Para estimar este modelo se requiere de acomodar la información para cada uno de los grupos de forma similar al modelo de efectos fijos para que

al final quedaría una expresión como:

$$\begin{bmatrix} y_{11} \\ y_{12} \\ y_{13} \\ \vdots \\ y_{1M} \\ y_{2M} \\ \vdots \\ y_{2M} \\ \vdots \\ y_{n1} \\ y_{n2} \\ y_{n3} \\ \vdots \\ y_{nM} \end{bmatrix} = \begin{bmatrix} x_{111} & x_{112} & x_{113} & \dots & x_{11K} \\ x_{121} & x_{122} & x_{123} & \dots & x_{12K} \\ x_{131} & x_{132} & x_{133} & \dots & x_{13K} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{1M1} & x_{1M2} & x_{1M3} & \dots & x_{1MK} \\ x_{211} & x_{212} & x_{213} & \dots & x_{21K} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{2M1} & x_{2M2} & x_{2M3} & \dots & x_{2MK} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{n11} & x_{n12} & x_{n13} & \dots & x_{n1K} \\ x_{n21} & x_{n22} & x_{n23} & \dots & x_{n2K} \\ x_{n31} & x_{n32} & x_{n33} & \dots & x_{n3K} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{nM1} & x_{nM2} & x_{nM3} & \dots & x_{nMK} \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \\ \vdots \\ \beta_K \end{bmatrix} + \begin{bmatrix} \nu_1 + \eta_{11} \\ \nu_1 + \eta_{12} \\ \nu_1 + \eta_{13} \\ \vdots \\ \nu_1 + \eta_{1M} \\ \nu_2 + \eta_{21} \\ \vdots \\ \nu_2 + \eta_{2M} \\ \vdots \\ \nu_n + \eta_{n1} \\ \nu_n + \eta_{n2} \\ \nu_n + \eta_{n3} \\ \vdots \\ \nu_n + \eta_{nM} \end{bmatrix}$$

6.2.3. Regresión Pool

Si $\mathbf{x}_i$ contine sólo una constante, entonces estimamos por mínimos cuadrados un estimador consistente y estará dado por los estimadores del vector $\boldsymbol{\beta}$. Asimismo, en este asumiremos que el término de error no se puede separar de fomar que sólo quedará como $\boldsymbol{\varepsilon}_{im}$

Para estimar este modelo se requiere de acomodar la información para cada uno de los grupos de forma similar al modelo de efectos aleatorios para

que al final quedaría una expresión como:

$$\begin{bmatrix} y_{11} \\ y_{12} \\ y_{13} \\ \vdots \\ y_{1M} \\ y_{2M} \\ \vdots \\ y_{2M} \\ \vdots \\ y_{n1} \\ y_{n2} \\ y_{n3} \\ \vdots \\ y_{nM} \end{bmatrix} = \begin{bmatrix} x_{111} & x_{112} & x_{113} & \dots & x_{11K} \\ x_{121} & x_{122} & x_{123} & \dots & x_{12K} \\ x_{131} & x_{132} & x_{133} & \dots & x_{13K} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{1M1} & x_{1M2} & x_{1M3} & \dots & x_{1MK} \\ x_{211} & x_{212} & x_{213} & \dots & x_{21K} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{2M1} & x_{2M2} & x_{2M3} & \dots & x_{2MK} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{n11} & x_{n12} & x_{n13} & \dots & x_{n1K} \\ x_{n21} & x_{n22} & x_{n23} & \dots & x_{n2K} \\ x_{n31} & x_{n32} & x_{n33} & \dots & x_{n3K} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{nM1} & x_{nM2} & x_{nM3} & \dots & x_{nMK} \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \\ \vdots \\ \beta_K \end{bmatrix} + \begin{bmatrix} \varepsilon_{11} \\ \varepsilon_{12} \\ \varepsilon_{13} \\ \vdots \\ \varepsilon_{1M} \\ \varepsilon_{21} \\ \vdots \\ \varepsilon_{2M} \\ \vdots \\ \varepsilon_{n1} \\ \varepsilon_{n2} \\ \varepsilon_{n3} \\ \vdots \\ \varepsilon_{nM} \end{bmatrix}$$

6.2.4. Pruebas para seleccionar modelo

Para datos panel existen dos pruebas. La primera es la de Hausman la cual nos permite analizar si la estimación por el efecto fijo no es distinta de la estimación por efectos aleatorios. De esta forma tenemos que:

$$\begin{aligned} H_0 & : \beta_{Fix} = \beta_{Random} \\ H_1 & : \beta_{Fix} \neq \beta_{Random} \end{aligned}$$

Equivalentemente:

$$\begin{aligned} H_0 & : \beta_{Fix} - \beta_{Random} = \mathbf{q} = 0 \\ H_1 & : \beta_{Fix} - \beta_{Random} \neq 0 \end{aligned}$$

Donde β_{Fix} es el estimador de parámetros asumiendo efectos fijos y β_{Random} es el estimador asumiendo efectos aleatorios.

De esta forma la estadística planteada estará dada por:

$$\begin{aligned} H & = n \cdot \mathbf{q}'(Var(\mathbf{q}))^{-1} \mathbf{q} \\ & = n \cdot (\beta_{Fix} - \beta_{Random})'(Var(\mathbf{q}))^{-1} (\beta_{Fix} - \beta_{Random}) \\ & \sim \chi_K^{(2)} \end{aligned}$$

La segunda, es una prueba para determinar si existen efectos aleatorios. La forma de determinarlo es si existe un componente de varianza asociado a ν , de forma que la hipótesis quedará planteada como una prueba basada en Multiplicadores de Lagrange (LM) de Breush y Pagan:

$$\begin{aligned}H_0 &: \sigma_\nu^2 = 0 \\H_1 &: \sigma_\nu^2 \neq 0\end{aligned}$$

6.3. Conclusión

- El modelo de efectos fijo y aleatorios supone que existe información individual que fue omitida.
- La distinción entre efectos fijos y efectos aleatorios es si el efecto no observable individual está correlacionado con los regresores o si no lo está. Así, esto no tiene que ver con si dicho efecto es estocástico o no.
- Cuando todo falla, la alternativa es estimar un modelo pool para los datos panel.

7

Métodos de estimación basados en verosimilitud

7.1. Introducción

En esta sección discutiremos el tratamiento general para la estimación por máxima verosimilitud. La diferencia significativa en estos casos es que asumiremos una distribución subyacente. Noten que los metodos utilizados anteriormente no requieren de que asumamos una distribución particular para realizar la estimación.

El planteamiento general del método de máxima verisimilitud considera un conjunto de observaciones independientes e idénticamente distribuidas descritas por la familia: $\{y_i, \mathbf{x}_i : y_i \in \mathbb{R}, \mathbf{x}_i \in \mathbb{R}^K\}$.

En estos casos también supondremos que buscamos etimar la regresión de y_i es $\mathbf{x}_i$ y no el caso contario. Por lo tanto, el método requiere de la función de densidad condicional de y_i en $\mathbf{x}_i$, es decir:

$$f(y_i|\mathbf{x}_i)$$

Así, al método en realidad se le conoce como método de máxima verosimilitud condicional. Su aplicación es amplia en casos como:

1. Modelos lineales: regresión de una sola ecuación, sistemas de ecuaciones, modelos de datos panel y modelos generalizados con heterocedásticidad y autocorrelación
2. Modelos no lineales: repuesta binaria, respuesta categórica, respuesta multinivel

3. Modelos de conteo y duración

Ejemplo. Sea y_i^* una variable aleatoria latente que se pueda expresar como:

$$y_i^* = \mathbf{x}_i \boldsymbol{\theta} + \varepsilon_i$$

Donde ε_i es independiente de $\mathbf{x}_i$, el cual es un vector de $1 \times K$ que contienen un término constante. $\boldsymbol{\theta}$ es un vector de $K \times 1$ parámetros a estimar. Finalmente, asumiremos que:

$$\varepsilon_i \sim Normal(0, 1)$$

Supongamos que en lugar de y_i^* nosotros sólo podemos observar la variable binaria indicadora:

$$y_i = \begin{cases} 1 & \text{si } y_i^* > 0 \\ 0 & \text{si } y_i^* \leq 0 \end{cases}$$

En este caso, la pregunta que pretendemos responder sería: ¿cuál es la probabilidad de que $y_i = 1$ condicional en que tenemos el vector $\mathbf{x}_i$?

$$\begin{aligned} P(y_i = 1) &= P(y_i^* > 0 | \mathbf{x}_i) \\ &= P(\mathbf{x}_i \boldsymbol{\theta} + \varepsilon_i > 0 | \mathbf{x}_i) \\ &= P(\varepsilon_i > -\mathbf{x}_i \boldsymbol{\theta} | \mathbf{x}_i) \end{aligned}$$

Dada la distribución ε_i , entonces:

$$P(\varepsilon_i > -\mathbf{x}_i \boldsymbol{\theta} | \mathbf{x}_i) = \int_{-\mathbf{x}_i \boldsymbol{\theta}}^{\infty} f(\varepsilon_i | \mathbf{x}_i) d\varepsilon_i$$

Sabemos que toda función de densidad cumple con:

$$\begin{aligned} 1 &= \int_{-\infty}^{\infty} f(\varepsilon_i | \mathbf{x}_i) d\varepsilon_i \\ &= \int_{-\infty}^{-\mathbf{x}_i \boldsymbol{\theta}} f(\varepsilon_i | \mathbf{x}_i) d\varepsilon_i + \int_{-\mathbf{x}_i \boldsymbol{\theta}}^{\infty} f(\varepsilon_i | \mathbf{x}_i) d\varepsilon_i \\ &= \int_{-\infty}^{-\mathbf{x}_i \boldsymbol{\theta}} f(\varepsilon_i | \mathbf{x}_i) d\varepsilon_i + \int_{-\infty}^{\mathbf{x}_i \boldsymbol{\theta}} f(\varepsilon_i | \mathbf{x}_i) d\varepsilon_i \\ &= \Phi(-\mathbf{x}_i \boldsymbol{\theta}) + \Phi(\mathbf{x}_i \boldsymbol{\theta}) \\ &= (1 - \Phi(\mathbf{x}_i \boldsymbol{\theta})) + \Phi(\mathbf{x}_i \boldsymbol{\theta}) \\ &= P(\varepsilon_i < -\mathbf{x}_i \boldsymbol{\theta} | \mathbf{x}_i) + P(\varepsilon_i > -\mathbf{x}_i \boldsymbol{\theta} | \mathbf{x}_i) \end{aligned}$$

De esta forma tenemos dos ecuaciones:

$$\begin{aligned} P(y_i = 1|\mathbf{x}_i) &= P(\varepsilon_i > -\mathbf{x}_i\boldsymbol{\theta}|\mathbf{x}_i) = \Phi(\mathbf{x}_i\boldsymbol{\theta}) \\ P(y_i = 0|\mathbf{x}_i) &= P(\varepsilon_i < -\mathbf{x}_i\boldsymbol{\theta}|\mathbf{x}_i) = 1 - \Phi(\mathbf{x}_i\boldsymbol{\theta}) \end{aligned}$$

Estas dos funciones de probabilidad son independientes. De esta forma, la función de densidad condicional de y_i será:

$$\begin{aligned} f(y_i|\mathbf{x}_i) &= P(y_i = 1|\mathbf{x}_i)^{y_i} \cdot P(y_i = 0|\mathbf{x}_i)^{1-y_i} \\ &= \Phi(\mathbf{x}_i\boldsymbol{\theta})^{y_i} \cdot (1 - \Phi(\mathbf{x}_i\boldsymbol{\theta}))^{1-y_i} \end{aligned}$$

7.2. Marco general de estimación por máxima verosimilitud

Sea $f(y_i|\mathbf{x}_i)$ la función de densidad condicional de y_i dado $\mathbf{x}_i$. Sea $\boldsymbol{\theta}$ un conjunto de parámetros de la función. Entonces la función de densidad conjunta de variables aleatorias independientes $\{y_i : y_i \in \mathbb{R}\}$ dados los valores $\{\mathbf{x}_i : \mathbf{x}_i \in \mathbb{R}^K\}$ estará dada por:

$$\Pi_{i=1}^n f(y_i|\mathbf{x}_i; \boldsymbol{\theta}) = f(y_1, y_2, \dots, y_n | \mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n; \boldsymbol{\theta}) = L(\boldsymbol{\theta}) \quad (7.1)$$

A la ecuación (7.1) se le conoce como ecuación de verosimilitud. El problema de máxima verosimilitud entonces será:

$$\max_{\boldsymbol{\theta} \in \Theta} \Pi_{i=1}^n f(y_i|\mathbf{x}_i; \boldsymbol{\theta}) = \max_{\boldsymbol{\theta} \in \Theta} L(\boldsymbol{\theta}) \quad (7.2)$$

Dado que el logaritmo natural es una transformación monótona, podemos decir que el problema de la ecuación (7.2) es equivalente a:

$$\max_{\boldsymbol{\theta} \in \Theta} \ln L(\boldsymbol{\theta}) = \max_{\boldsymbol{\theta} \in \Theta} \ln \Pi_{i=1}^n f(y_i|\mathbf{x}_i; \boldsymbol{\theta}) = \max_{\boldsymbol{\theta} \in \Theta} \sum_{i=1}^n \ln f(y_i|\mathbf{x}_i; \boldsymbol{\theta}) \quad (7.3)$$

Para solucionar el problema se tiene que determinar las condiciones de primer y segundo orden, las cuales serán:

$$\frac{\partial}{\partial \boldsymbol{\theta}} \ln L(\boldsymbol{\theta}) = \nabla \ln L(\boldsymbol{\theta}) \quad (7.4)$$

$$\frac{\partial^2}{\partial^2 \boldsymbol{\theta}} \ln L(\boldsymbol{\theta}) = \frac{\partial}{\partial \boldsymbol{\theta}} \ln L(\boldsymbol{\theta}) \cdot \frac{\partial}{\partial \boldsymbol{\theta}} \ln L(\boldsymbol{\theta}') = H(\boldsymbol{\theta}) \quad (7.5)$$

La solución estará dada por aquel valor de $\hat{\boldsymbol{\theta}}$ que hace:

$$\frac{\partial}{\partial \boldsymbol{\theta}} \ln L(\hat{\boldsymbol{\theta}}) = 0$$

A su vez, la varianza será aquella que resulta de:

$$Var[\hat{\boldsymbol{\theta}}|\mathbf{X}] = (-\mathbb{E}_{\hat{\boldsymbol{\theta}}}[\mathbf{H}(\boldsymbol{\theta})])^{-1}$$

7.3. Pruebas de hipótesis

1. Para el caso de pruebas de hipótesis sobre cada uno de los coeficientes estimados $\hat{\theta}_i$, dada la construcción de la función de verosimilitud y que se trata de grandes muestras, la función de distribución de ese coeficiente será una normal, por lo que las hipótesis planteadas serán asumiendo:

$$Z = \frac{\hat{\theta}_i - \theta_i}{\sqrt{Var(\hat{\theta}_i)}} \sim N(0, Var(\hat{\theta}_i)) \quad (7.6)$$

2. Para pruebas globales utilizaremos la prueba de Wald:

$$W = c(\hat{\boldsymbol{\theta}})'(\hat{C}Var(\hat{\boldsymbol{\theta}})\hat{C}')^{-1}c(\hat{\boldsymbol{\theta}}) \sim \chi^2_{(Q)} \quad (7.7)$$

Donde $c(\hat{\boldsymbol{\theta}})$ es una función de los coeficientes, $\hat{C}$ es el jacobiano de $c(\hat{\boldsymbol{\theta}})$, Q es el número de restricciones.

3. Alternativamente, para pruebas sobre los coeficientes podremos utilizar pruebas de razón de verosimilitud:

$$LR = 2[\ln L(\hat{\boldsymbol{\theta}}_0) - \ln L(\hat{\boldsymbol{\theta}}_R)] \sim \chi^2_{(Q)} \quad (7.8)$$

8

Estimación de modelos no lineales

8.1. Modelos de respuesta binaria

8.1.1. Planteamiento general

En el caso de modelos de respuesta binaria, asumiremos que y_i es una variable aleatoria que toma sólo valores de 0 y 1. Los ejemplos pueden ser amplios. Decisiones sobre consumir o no, pagar o no, ir a una escuela determinada, viajar por tierra o aire. En general diremos que 1 es éxito y 0 es fracaso.

Como en el caso de modelos lineales diremos que y_i es la variable dependiente y $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{iK})$ un vector de variables independientes o explicativas. Así, en los modelos no lineales de respuesta binaria estaremos interesados en la probabilidades:

$$P(y_i = 1|\mathbf{x}_i) = P(y_i = 1|x_{i1}, x_{i2}, \dots, x_{iK})$$

Dicho lo anterior y de forma similar al de la regresión lineal, podemos establecer el efecto marginal para el caso de una variable independiente x_j continua:

$$EMg_j = \frac{\partial}{\partial x_j} P(y_i = 1|x_{i1}, x_{i2}, \dots, x_{iK})$$

Cuando la variable independiente es una variable dummy:

$$EMg_j = P(y_i = 1|x_{i1}, x_{i2}, \dots, x_{ij} = 1, \dots, x_{iK}) - P(y_i = 1|x_{i1}, x_{i2}, \dots, x_{ij} = 0, \dots, x_{iK})$$

Este tipo de modelos se basan en el modelo de Bernoulli, cuya función de densidad de probabilidad condicional y podemos plantearlo como:

$$\begin{aligned} P(y_i = 1|\mathbf{x}_i) &= p(x) \\ P(y_i = 0|\mathbf{x}_i) &= 1 - p(x) \\ Var(y_i|\mathbf{x}_i) &= p(x) \cdot (1 - p(x)) \end{aligned}$$

8.1.2. Algunos planteamientos adicionales

Cuando la variable dependiente es binaria (0 y 1) no se puede implementar una ecuación lineal de la forma tradicional, ya que no es posible determinar una ecuación:

$$y_i = \mathbf{x}_i\boldsymbol{\beta} + \varepsilon_i$$

Por otro la, tambien enfrentaremos el mismo problema con modelos de probabilidad lineal:

$$P(y_i = 1|\mathbf{x}_i) = \mathbf{x}_i\boldsymbol{\beta} + \varepsilon_i$$

Y:

$$P(y_i = 0|\mathbf{x}_i) = \mathbf{x}_i\boldsymbol{\beta} + \varepsilon_i$$

En ambos casos es difícil lograr la estimación.

8.1.3. Modelos Logit y Probit

Este tipo de modelos suponen que tenemos que existe una variable latente que se puede expresar como una ecuación lineal dada por:

$$y_i^* = \mathbf{x}_i\boldsymbol{\beta} + \varepsilon_i$$

Donde ε_i es una variable aleatoria con función de densidad con media cero y distribución simétrica al rededor de cero. Dado lo anterior, para nosotros sólo es visible que:

$$y_i = \begin{cases} 1 & \text{si } y_i^* > 0 \\ 0 & \text{si } y_i^* < 0 \end{cases}$$

De esta forma tenemos una estructura de la probabilidad dada por:

$$\begin{aligned} P(y_i = 1|\mathbf{x}_i) &= P(\mathbf{x}_i\boldsymbol{\beta} + \varepsilon_i > 0) = P(\varepsilon_i > -\mathbf{x}_i\boldsymbol{\beta}) = G(\mathbf{x}_i\boldsymbol{\beta}) \\ P(y_i = 0|\mathbf{x}_i) &= P(\mathbf{x}_i\boldsymbol{\beta} + \varepsilon_i < 0) = P(\varepsilon_i < -\mathbf{x}_i\boldsymbol{\beta}) = 1 - G(\mathbf{x}_i\boldsymbol{\beta}) \end{aligned}$$

Donde $\mathbf{x}_i$ es un vector de dimensión $K \times 1$ que contiene al menos el término constante y $\boldsymbol{\beta}$ es un vector de parámetros a estimar, de forma que asumiremos:

$$\mathbf{x}_i\boldsymbol{\beta} = \beta_1 + x_{i2}\beta_2 + \dots + x_{iK}\beta_K$$

Asumiremos que $G(\cdot)$ es una función de densidad acumulada de forma que:

$$0 < G(\mathbf{x}_i\boldsymbol{\beta}) < 1, \forall \mathbf{x}_i\boldsymbol{\beta} \in \mathbb{R}$$

En este caso utilizaremos dos modelos que dependen de la forma funcional de $G(\cdot)$ que está determinada por la distribución de ε_i . De esta forma tendremos dos modelos: Probit y Logit:

1. **Modelo Probit**, cuando

$$G(\mathbf{x}_i\boldsymbol{\beta}) = \Phi(\mathbf{x}_i\boldsymbol{\beta}) = \int_{-\infty}^{\mathbf{x}_i\boldsymbol{\beta}} \phi(\nu) d\nu$$

Donde $\phi(\cdot)$ es la densidad de probabilidad normal estándar:

$$\phi(\mathbf{x}_i\boldsymbol{\beta}) = \frac{1}{\sqrt{2\pi}} e^{-1/2\phi(\mathbf{x}_i\boldsymbol{\beta})}$$

2. **Modelo Logit**, cuando

$$G(\mathbf{x}_i\boldsymbol{\beta}) = \Lambda(\mathbf{x}_i\boldsymbol{\beta}) = \frac{e^{\mathbf{x}_i\boldsymbol{\beta}}}{1 + e^{\mathbf{x}_i\boldsymbol{\beta}}}$$

Donde $\lambda(\cdot)$ es la función de densidad acumulada logística.

Sin importar el modelo que estemos ocupando, la forma de interpretar el modelo es mediante el efecto marginal, cuando x_j sea una variable continua:

$$EMg_j = \frac{\partial}{\partial x_j} P(y = 1|\mathbf{x}_i) = \frac{\partial}{\partial x_j} G(\mathbf{x}_i\boldsymbol{\beta}) = g(\mathbf{x}_i\boldsymbol{\beta})\beta_j$$

Por su parte, cuando x_j sea una variable dicotómica:

$$\begin{aligned}
 EMg_j &= P(y = 1 | \mathbf{x}_i, x_j = 1) - P(y = 1 | \mathbf{x}_i, x_j = 0) \\
 &= G(\mathbf{x}_i \boldsymbol{\beta} | x_j = 1) - G(\mathbf{x}_i \boldsymbol{\beta} | x_j = 0) \\
 &= G(\beta_1 + x_2 \beta_2 + \dots + \beta_j + \dots + x_K \beta_K) \\
 &\quad - G(\beta_1 + x_2 \beta_2 + \dots + 0 + \dots + x_K \beta_K)
 \end{aligned}$$

8.1.4. Estimación

Supongamos n observaciones de una variables aleatoria independientes e idénticamente distribuidas. En estos casos la función de densidad para cada y_i , $i = 1, 2, \dots, n$, estará dada por:

$$f(y_i | \mathbf{x}_i; \boldsymbol{\beta}) = [G(\mathbf{x}_i \boldsymbol{\beta})]^{y_i} [1 - G(\mathbf{x}_i \boldsymbol{\beta})]^{1-y_i}, \text{ donde } y_i = 0, 1$$

En estos términos la función de verosimilitud estará dada por:

$$\begin{aligned}
 L(\boldsymbol{\beta}) &= \prod_{i=1}^n f(y_i | \mathbf{x}_i; \boldsymbol{\beta}) \\
 &= \prod_{i=1}^n [G(\mathbf{x}_i \boldsymbol{\beta})]^{y_i} [1 - G(\mathbf{x}_i \boldsymbol{\beta})]^{1-y_i}
 \end{aligned}$$

En versión logaritmica:

$$\begin{aligned}
 \ln L(\boldsymbol{\beta}) &= \sum_{i=1}^n \ln(f(y_i | \mathbf{x}_i; \boldsymbol{\beta})) \\
 &= \sum_{i=1}^n y_i \ln[G(\mathbf{x}_i \boldsymbol{\beta})] + \sum_{i=1}^n (1 - y_i) \ln[1 - G(\mathbf{x}_i \boldsymbol{\beta})]
 \end{aligned}$$

Las condiciones de primer orden serán:

$$\frac{\partial}{\partial \boldsymbol{\beta}} \ln L(\boldsymbol{\beta}) = \sum_{i=1}^n y_i \frac{g(\mathbf{x}_i \boldsymbol{\beta})}{G(\mathbf{x}_i \boldsymbol{\beta})} \mathbf{x}_i' - \sum_{i=1}^n (1 - y_i) \frac{g(\mathbf{x}_i \boldsymbol{\beta})}{1 - G(\mathbf{x}_i \boldsymbol{\beta})} \mathbf{x}_i'$$

Finalmente, las condiciones de segundo orden y varianza estará dada por:

$$\begin{aligned}
 \frac{\partial^2}{\partial \boldsymbol{\beta} \partial \boldsymbol{\beta}'} \ln L(\boldsymbol{\beta}) &= - \sum_{i=1}^n \frac{y_i g(\mathbf{x}_i \boldsymbol{\beta})^2}{G(\mathbf{x}_i \boldsymbol{\beta}) [1 - G(\mathbf{x}_i \boldsymbol{\beta})]} \mathbf{x}_i' \mathbf{x}_i \\
 &= H(\boldsymbol{\beta})
 \end{aligned}$$

Por lo tanto:

$$\begin{aligned} \text{Var}(\hat{\boldsymbol{\beta}}) &= [-\mathbb{E}[H(\boldsymbol{\beta})]]^{-1} \\ &= \left[\sum_{i=1}^n \frac{y_i g(\mathbf{x}_i \boldsymbol{\beta})^2}{G(\mathbf{x}_i \boldsymbol{\beta}) [1 - G(\mathbf{x}_i \boldsymbol{\beta})]} \mathbf{x}_i' \mathbf{x}_i \right]^{-1} \end{aligned}$$

8.2. Modelos de respuesta multinomial y ordenada

En esta sección analizaremos modelos de respuesta discreta con más de 2 resultados posibles, los cuales se dividen:

1. Modelos de respuesta no ordenada, son modelos conocidos como de respuesta nominal, donde los valores de los distintos resultados son arbitrarios y no tienen un efecto en la estimación. Ejemplos de estos modelos son casos de selección de seguro, lugar de hospedaje, etc.
2. Modelos de respuesta ordenada, en estos modelos se asigna a cada un valor no arbitrario a la respuesta. Por ejemplo, modelos de calificación de crédito, modelos de preferencia de bienes, etc.

8.2.1. Modelos de respuesta multinomial

Logit multinomial

Este primer modelo aplica en situaciones en las que la unidad de respuesta o elección depende de las características individuales de los elementos de la muestra, pero no de la atribuciones de la elección.

Dado lo anterior, definiremos el modelo en términos de variables aleatorias que representan a la población subyacente. Sea y_i una variable aleatoria que toma valores en un conjunto $\{0, 1, 2, \dots, J\}$. Sea $\mathbf{x}_i$ un conjunto de valores o regresores para $i = 1, 2, \dots, n$.

Como en el modelo de respuesta binaria, estimaremos el efecto de una variable en la probabilidad de ocurrencia de uno de los valores de respuesta. Dichas variables de respuesta estarán dados por:

$$P(y_i = j | \mathbf{x}_i), \text{ para } j = 1, 2, \dots, J$$

Dado que la suma de probabilidades debe ser 1, se suele tomar como práctica estimar $P(y_i = 0|\mathbf{x}_i)$ como diferencia del resto de los casos $j = \{1, 2, \dots, J\}$. Así, sea $\mathbf{x}_i$ un vector de dimensión $1 \times K$. De esta forma, el modelo Logit tendrá como probabilidad de cada una de las respuestas a:

$$P(y_i = j|\mathbf{x}_i) = \frac{e^{\mathbf{x}_i\boldsymbol{\beta}_j}}{1 + e^{\mathbf{x}_i\boldsymbol{\beta}_1} + e^{\mathbf{x}_i\boldsymbol{\beta}_2} + \dots + e^{\mathbf{x}_i\boldsymbol{\beta}_J}}$$

Donde cada una de las $\boldsymbol{\beta}_j$, $j = 1, \dots, J$ es de dimensión $K \times 1$. Es fácil observar que si la suma de probabilidades es 1, entonces, la probabilidad de $y = 0|\mathbf{x}_i$ estará dada por:

$$\begin{aligned} P(y_i = 0|\mathbf{x}_i) &= \frac{e^0}{1 + e^{\mathbf{x}_i\boldsymbol{\beta}_1} + e^{\mathbf{x}_i\boldsymbol{\beta}_2} + \dots + e^{\mathbf{x}_i\boldsymbol{\beta}_J}} \\ &= \frac{1}{1 + e^{\mathbf{x}_i\boldsymbol{\beta}_1} + e^{\mathbf{x}_i\boldsymbol{\beta}_2} + \dots + e^{\mathbf{x}_i\boldsymbol{\beta}_J}} \end{aligned}$$

De esta forma tenemos:

$$\begin{aligned} 1 &= \sum_{j=0}^J P(y_i = j|\mathbf{x}_i) \\ &= \frac{1}{1 + e^{\mathbf{x}_i\boldsymbol{\beta}_1} + e^{\mathbf{x}_i\boldsymbol{\beta}_2} + \dots + e^{\mathbf{x}_i\boldsymbol{\beta}_J}} \\ &\quad + \frac{e^{\mathbf{x}_i\boldsymbol{\beta}_1}}{1 + e^{\mathbf{x}_i\boldsymbol{\beta}_1} + e^{\mathbf{x}_i\boldsymbol{\beta}_2} + \dots + e^{\mathbf{x}_i\boldsymbol{\beta}_J}} \\ &\quad + \dots + \\ &\quad + \frac{e^{\mathbf{x}_i\boldsymbol{\beta}_J}}{1 + e^{\mathbf{x}_i\boldsymbol{\beta}_1} + e^{\mathbf{x}_i\boldsymbol{\beta}_2} + \dots + e^{\mathbf{x}_i\boldsymbol{\beta}_J}} \end{aligned}$$

Para el proceso de estimación consideraremos la función de verosimilitud dada por:

$$\begin{aligned} L(\boldsymbol{\beta}_1, \boldsymbol{\beta}_2, \dots, \boldsymbol{\beta}_J) &= \prod_{i=1}^n [(P(j = 0|\mathbf{x}_i))^{I(0)} \cdot (P(j = 1|\mathbf{x}_i))^{I(1)} \\ &\quad \dots (P(j = J|\mathbf{x}_i))^{I(J)}] \end{aligned}$$

Donde $I(j)$ es la función indicadora que toma el valor de 1 o 0 dependiendo de cual de las opciones posibles $j = 0, 1, 2, \dots, J$ es cierta para cada individuo $i = 1, 2, \dots, n$. De forma similar al caso de respuesta binaria en los modelos Logit Multinomiales se interpretan en sus efectos marginales y no de forma directa en los coeficientes $\boldsymbol{\beta}_j$.

Para una variable x_{ik} continua y para cada opción $j = 0, 1, 2, \dots, J$ el efecto marginal será:

$$\begin{aligned} EMg_k &= \frac{\partial P(y_i = j | \mathbf{x}_i)}{\partial x_{ik}} \\ &= P(y_i = j | \mathbf{x}_i) \cdot \left[\beta_{jk} - \frac{\sum_{h=1}^J \beta_{hk} \cdot e^{\mathbf{x}_i \beta_h}}{1 + e^{\mathbf{x}_i \beta_1} + e^{\mathbf{x}_i \beta_2} + \dots + e^{\mathbf{x}_i \beta_J}} \right] \end{aligned}$$

Donde β_{hk} es el k -ésimo elemento del vector β_h . En el caso de que x_{ik} se una variable dicotómica (o categórica) y para cada opción $j = 0, 1, 2, \dots, J$ el efecto marginal será:

$$EMg_k = P(y_i = j | \mathbf{x}_i, x_{ik} = 1) - P(y_i = j | \mathbf{x}_i, x_{ik} = 0)$$

8.2.2. Modelos de respuesta ordenada: Logit y Probit Ordinal

Sea y_i una variable que representa ordenada que toma los valores de $\{0, 1, 2, \dots, J\}$. En estos casos en que importa el orden de la respuesta existen dos mecanismos de estimación: el Modelo Probit y el Modelo Logit.

Modelo Probit Ordinal. Este modelo se puede derivar de forma similar al modelo probit de dos respuestas 0 y 1, probit binario. Así, partimos de una variable latente y_i^* definida como:

$$y_i^* = \mathbf{x}_i \beta + \varepsilon_i; \quad \varepsilon_i \sim N(0, 1)$$

Donde β es un vector $(K - 1) \times 1$ ya que en este caso asumiremos que no se considera un término constante, por las razones que mostramos más adelante. Sean $\alpha_1, \alpha_2, \dots, \alpha_J$ un conjunto de umbrales que particionan la probabilidad de la siguiente forma:

$$\begin{aligned} y_i = 0 & \quad \text{si} \quad y_i^* \leq \alpha_1 \\ y_i = 1 & \quad \text{si} \quad \alpha_1 < y_i^* \leq \alpha_2 \\ & \quad \vdots \\ y_i = j & \quad \text{si} \quad \alpha_j < y_i^* \leq \alpha_{j+1} \\ & \quad \vdots \\ y_i = J & \quad \text{si} \quad \alpha_J < y_i^* \end{aligned}$$

Dado que ϵ_i tiene una distribución normal estándar, para cada uno de los casos anteriores podemos establecer:

$$\begin{aligned}
P(y_i = 0|\mathbf{x}_i) &= P(y_i^* \leq \alpha_1|\mathbf{x}_i) = P(\mathbf{x}_i\boldsymbol{\beta} + \epsilon_i \leq \alpha_1|\mathbf{x}_i) \\
P(y_i = 1|\mathbf{x}_i) &= P(\alpha_1 < y_i^* \leq \alpha_2|\mathbf{x}_i) = P(\alpha_1 < \mathbf{x}_i\boldsymbol{\beta} + \epsilon_i \leq \alpha_2|\mathbf{x}_i) \\
&\vdots \\
P(y_i = j|\mathbf{x}_i) &= P(\alpha_j < y_i^* \leq \alpha_{j+1}|\mathbf{x}_i) = P(\alpha_j < \mathbf{x}_i\boldsymbol{\beta} + \epsilon_i \leq \alpha_{j+1}|\mathbf{x}_i) \\
&\vdots \\
P(y_i = J|\mathbf{x}_i) &= P(\alpha_J < y_i^*|\mathbf{x}_i) = P(\alpha_J < \mathbf{x}_i\boldsymbol{\beta} + \epsilon_i|\mathbf{x}_i)
\end{aligned}$$

Desarrollando las ecuaciones anteriores tenemos para el caso de $y_i = 0$:

$$\begin{aligned}
P(y_i = 0|\mathbf{x}_i) &= P(\mathbf{x}_i\boldsymbol{\beta} + \epsilon_i \leq \alpha_1|\mathbf{x}_i) \\
&= P(\epsilon_i \leq \alpha_1 - \mathbf{x}_i\boldsymbol{\beta}|\mathbf{x}_i) \\
&= \Phi(\alpha_1 - \mathbf{x}_i\boldsymbol{\beta})
\end{aligned}$$

En el caso de $y_i = j$, $j = 1, 2, \dots, J - 1$:

$$\begin{aligned}
P(y_i = j|\mathbf{x}_i) &= P(\alpha_j < \mathbf{x}_i\boldsymbol{\beta} + \epsilon_i \leq \alpha_{j+1}|\mathbf{x}_i) \\
&= P(\alpha_j - \mathbf{x}_i\boldsymbol{\beta} < \epsilon_i \leq \alpha_{j+1} - \mathbf{x}_i\boldsymbol{\beta}|\mathbf{x}_i) \\
&= P(\epsilon_i \leq \alpha_{j+1} - \mathbf{x}_i\boldsymbol{\beta}|\mathbf{x}_i) - P(\epsilon_i < \alpha_j - \mathbf{x}_i\boldsymbol{\beta}|\mathbf{x}_i) \\
&= \Phi(\alpha_{j+1} - \mathbf{x}_i\boldsymbol{\beta}) - \Phi(\alpha_j - \mathbf{x}_i\boldsymbol{\beta})
\end{aligned}$$

Finalmente, para el caso $y_i = J$:

$$\begin{aligned}
P(y_i = J|\mathbf{x}_i) &= P(\alpha_J < \mathbf{x}_i\boldsymbol{\beta} + \epsilon_i|\mathbf{x}_i) \\
&= P(\alpha_J - \mathbf{x}_i\boldsymbol{\beta} < \epsilon_i|\mathbf{x}_i) \\
&= 1 - P(\epsilon_i < \alpha_J - \mathbf{x}_i\boldsymbol{\beta}|\mathbf{x}_i) \\
&= 1 - \Phi(\alpha_J - \mathbf{x}_i\boldsymbol{\beta})
\end{aligned}$$

Es sencillo observar y analizar que:

$$1 = \sum_{j=0}^J P(y_i = j|\mathbf{x}_i)$$

Notemos que en este modelo los cambios en la probabilidad no serán determinados por $\mathbf{x}_i$, ya que lo que determina el cambio es el umbral α_j ,

$j = 0, 1, \dots, J$. También en este caso los coeficientes no se interpretan de forma directa, en cambio se utiliza el efecto marginal que tiene expresiones similares al del probit bivariado como más adelante mostraremos.

Modelo Logit Ordinal. Este modelo se puede derivar de forma similar al modelo Probit Ordinal con una variable latente y_i^* , también con β es un vector $(K - 1) \times 1$ ya que en este caso asumiremos que no se considera un término constante, por las razones que hemos mostrado anteriormente. Igualmente, sean $\alpha_1, \alpha_2, \dots, \alpha_J$ un conjunto de umbrales que particionan la probabilidad considerando una función logística $\Lambda(\cdot)$ de la siguiente forma:

$$\varepsilon_i \sim \Lambda(\cdot)$$

$$P(y_i = J | \mathbf{x}_i) = P(\alpha_J < y_i^* | \mathbf{x}_i) = P(\alpha_J < \mathbf{x}_i \beta + \varepsilon_i | \mathbf{x}_i)$$

Desarrollando las ecuaciones de probabilidad de forma similar al Probit Multinomial tenemos para el caso de $y_i = 0$:

$$\begin{aligned} P(y_i = 0 | \mathbf{x}_i) &= P(y_i^* \leq \alpha_1 | \mathbf{x}_i) \\ &= P(\mathbf{x}_i \beta + \varepsilon_i \leq \alpha_1 | \mathbf{x}_i) \\ &= P(\varepsilon_i \leq \alpha_1 - \mathbf{x}_i \beta | \mathbf{x}_i) \\ &= \Lambda(\alpha_1 - \mathbf{x}_i \beta) \end{aligned}$$

En el caso de $y_i = j$, $j = 1, 2, \dots, J - 1$:

$$\begin{aligned} P(y_i = j | \mathbf{x}_i) &= P(\alpha_j < y_i^* \leq \alpha_{j+1} | \mathbf{x}_i) \\ &= P(\alpha_j < \mathbf{x}_i \beta + \varepsilon_i \leq \alpha_{j+1} | \mathbf{x}_i) \\ &= P(\alpha_j - \mathbf{x}_i \beta < \varepsilon_i \leq \alpha_{j+1} - \mathbf{x}_i \beta | \mathbf{x}_i) \\ &= P(\varepsilon_i \leq \alpha_{j+1} - \mathbf{x}_i \beta | \mathbf{x}_i) - P(\varepsilon_i \leq \alpha_j - \mathbf{x}_i \beta | \mathbf{x}_i) \\ &= \Lambda(\alpha_{j+1} - \mathbf{x}_i \beta) - \Lambda(\alpha_j - \mathbf{x}_i \beta) \end{aligned}$$

Finalmente, para el caso $y_i = J$:

$$\begin{aligned} P(y_i = J | \mathbf{x}_i) &= P(\alpha_J < y_i^* | \mathbf{x}_i) \\ &= P(\alpha_J < \mathbf{x}_i \beta + \varepsilon_i | \mathbf{x}_i) \\ &= P(\alpha_J - \mathbf{x}_i \beta < \varepsilon_i | \mathbf{x}_i) \\ &= 1 - P(\varepsilon_i \leq \alpha_J - \mathbf{x}_i \beta | \mathbf{x}_i) \\ &= 1 - \Lambda(\alpha_J - \mathbf{x}_i \beta) \end{aligned}$$

También, es sencillo observar y analizar que en los Logit Multinomiales:

$$1 = \sum_{j=0}^J P(y_i = j | \mathbf{x}_i)$$

Notemos que en este modelo los cambios en la probabilidad no serán determinados por $\mathbf{x}_i$, ya que lo que determina el cambio es el umbral α_j , $j = 0, 1, \dots, J$. También en este caso los coeficientes no se interpretan de forma directa, en cambio se utiliza el efecto marginal que tiene expresiones similares al del probit bivariado como más adelante mostraremos.

Estimación de modelos Probit y Logit Ordinal. Para la estimación implementaremos un proceso de maximización de la siguiente función de verosimilitud:

$$L(\alpha, \beta) = \prod_{i=1}^n P(y_i = 0 | \mathbf{x}_i)^{I(0)} \cdot P(y_i = 1 | \mathbf{x}_i)^{I(1)} \dots P(y_i = J | \mathbf{x}_i)^{I(J)}$$

Donde $I(j)$ es la función indicadora que toma el valor de 0 y 1 si el individuo i -ésimo tiene como respuesta alguno de los posibles valores de $j = 0, 1, \dots, J$. La función es válida sin importar la función $\Phi(\cdot)$ o $\Lambda(\cdot)$ que utilicemos para determinar la $P(y_i = j | \mathbf{x}_i)$, para $j = 1, 2, \dots, J$. Por lo cual simbolizaremos indistintamente estas funciones como $G(\cdot)$.

Finalmente, sin importar el modelo que estemos ocupando, Probit o Logit ordinal, la forma de interpretar el modelo es mediante el efecto marginal, cuando x_k sea una variable continua:

$$EMg_k = \frac{\partial}{\partial x_k} P(y_i = j | \mathbf{x}_i) = \frac{\partial}{\partial x_k} G(\alpha_j - \mathbf{x}_i \beta) = -\beta_k \cdot g(\alpha_j - \mathbf{x}_i \beta)$$

Por su parte, cuando x_j sea una variable dicotómica:

$$\begin{aligned} EMg_k &= P(y_i = j | \mathbf{x}_i, x_{ik} = 1) - P(y_i = j | \mathbf{x}_i, x_{ik} = 0) \\ &= G(\alpha_j - \mathbf{x}_i \beta | \mathbf{x}_i, x_{ik} = 1) - G(\alpha_j - \mathbf{x}_i \beta | \mathbf{x}_i, x_{ik} = 0) \\ &= G(\alpha_j - (\beta_1 + x_2 \beta_2 + \dots + \beta_k + \dots + x_K \beta_K)) \\ &\quad - G(\alpha_j - (\beta_1 + x_2 \beta_2 + \dots + 0 + \dots + x_K \beta_K)) \end{aligned}$$

También es posible hacer un efecto marginal intra respuestas, es decir, para cambios entre una respuesta j y una $j + h$, la cual será:

$$EMg_{j-h} = \beta_k \cdot [g(\alpha_h - \mathbf{x}_i \beta) - g(\alpha_j - \mathbf{x}_i \beta)], \text{ con } h < j$$

Donde $k = 1, 2, \dots, K - 1$ y $j = 0, 1, \dots, J$.

8.2.3. Regresión logística con información de videojuegos.

Planteamiento del caso

Supuestos y necesidades del caso:

1. Determinar cuáles son las features/características/steam tags que se asocian con videojuegos para PC exitosos.
2. Hay varias tiendas de videojuegos (Steam, itch, etc.) que utilizan estas tags para clasificar a sus juegos.

Propuesta: Usar un modelo de respuesta ordenada

Sea y una variable que representa una respuesta ordenada que toma valores $\{0, 1, 2, \dots, J\} \in \mathbb{Z}$. El modelo de repuesta ordenada (conocido como Probit o Logit ordenado) para y (condicional en un vector de variables explicativas $\mathbf{X}$ —features, características, tags, etc.—) es derivado a partir de un modelo de variable latente y^* , el cual se puede escribir como:

$$y^* = \mathbf{X}\boldsymbol{\beta} + \varepsilon, \varepsilon|\mathbf{X} \sim f(\varepsilon) \quad (8.1)$$

Donde $f(\cdot)$ es una función de densidad de probabilidad simétrica cuya función de densidad acumulada será denotada por $F(\cdot)$, $\boldsymbol{\beta}$ es un vector de dimensión $K \times 1$ y, por razones que más adelante explicamos, $\mathbf{X}$ no tiene término constante. Por otro lado, sean $\mu_1 < \mu_2 < \dots < \mu_J$ puntos de corte o parámetros umbrales que definen lo siguiente:

$$\begin{aligned} y = 0 & \quad \text{si} \quad y^* \leq \mu_1 \\ y = 1 & \quad \text{si} \quad \mu_1 < y^* \leq \mu_2 \\ & \quad \vdots \\ y = J & \quad \text{si} \quad y^* > \mu_J \end{aligned} \quad (8.2)$$

De esta forma y considerando el conjunto de desigualdades en la ecuación (12.38) y la ecuación (12.37), podemos determinar las siguientes probabili-

dades a partir de una partición de una función de distribución dada:

$$\begin{aligned}
\mathbf{P}(y = 0|\mathbf{X}) &= \mathbf{P}(y^* \leq \mu_1|\mathbf{X}) \\
&= \mathbf{P}(\mathbf{X}\boldsymbol{\beta} + \varepsilon \leq \mu_1|\mathbf{X}) \\
&= \mathbf{P}(\varepsilon \leq \mu_1 - \mathbf{X}\boldsymbol{\beta}|\mathbf{X}) \\
&= F(\mu_1 - \mathbf{X}\boldsymbol{\beta})
\end{aligned}$$

$$\begin{aligned}
\mathbf{P}(y = 1|\mathbf{X}) &= \mathbf{P}(\mu_1 < y^* \leq \mu_2|\mathbf{X}) \\
&= \mathbf{P}(\mu_1 < \mathbf{X}\boldsymbol{\beta} + \varepsilon \leq \mu_2|\mathbf{X}) \\
&= \mathbf{P}(\mu_1 - \mathbf{X}\boldsymbol{\beta} < \varepsilon \leq \mu_2 - \mathbf{X}\boldsymbol{\beta}|\mathbf{X}) \\
&= F(\mu_2 - \mathbf{X}\boldsymbol{\beta}) - F(\mu_1 - \mathbf{X}\boldsymbol{\beta})
\end{aligned}$$

$\vdots$

$$\begin{aligned}
\mathbf{P}(y = J - 1|\mathbf{X}) &= \mathbf{P}(\mu_{J-1} < y^* \leq \mu_J|\mathbf{X}) \\
&= \mathbf{P}(\mu_{J-1} < \mathbf{X}\boldsymbol{\beta} + \varepsilon \leq \mu_J|\mathbf{X}) \\
&= \mathbf{P}(\mu_{J-1} - \mathbf{X}\boldsymbol{\beta} < \varepsilon \leq \mu_J - \mathbf{X}\boldsymbol{\beta}|\mathbf{X}) \\
&= F(\mu_J - \mathbf{X}\boldsymbol{\beta}) - F(\mu_{J-1} - \mathbf{X}\boldsymbol{\beta})
\end{aligned}$$

$$\begin{aligned}
\mathbf{P}(y = J|\mathbf{X}) &= \mathbf{P}(y^* > \mu_J|\mathbf{X}) \\
&= \mathbf{P}(\mathbf{X}\boldsymbol{\beta} + \varepsilon > \mu_J|\mathbf{X}) \\
&= \mathbf{P}(\varepsilon > \mu_J - \mathbf{X}\boldsymbol{\beta}|\mathbf{X}) \\
&= 1 - F(\mu_J - \mathbf{X}\boldsymbol{\beta})
\end{aligned}$$

Note que en este caso asumimos que $\mathbf{X}$ no tiene término constante, ya que la incorporamos mediante los umbrales μ_j , $j = 1, 2, \dots, J$. Un caso particular de esta modelación son los modelos de clasificación binarios en los que $J = 2$. En la figura 12.11 ilustramos la partición de la función de densidad $f(\cdot)$ que resultaría de las ecuaciones anteriores.




Figura 8.1: Probabilidades en un modelo de respuesta ordenada, considerando $J = 4$ (retomado de Greene (2012, 788) [Gre12])

De esta manera, los resultados de la estimación se pueden interpretar a través de sus efectos marginales dados por:

$$\frac{\partial \mathbf{P}(y = j|\mathbf{X})}{\partial x_k} = -\beta_k(f(\mu_j - \mathbf{X}\boldsymbol{\beta}) - f(\mu_{j-1} - \mathbf{X}\boldsymbol{\beta})) \text{ para } 0 < j < J \quad (8.3)$$

Así, este efecto se interpreta como la contribución que tiene la variable x_k a la probabilidad de que la variable y tome el valor de j

Aplicación al caso de videojuegos

En el caso de los videojuegos, podemos aplicar el modelo de respuesta ordenada asumiendo algunas cosas. Primero, F tendrá una forma de función logística, para facilitar el proceso computacional. Segundo, la variable y será particionada en rangos de ingresos obtenidos por los videojuegos en su primer año (y^*)—año de lanzamiento—, por ejemplo:

$$y^* = \mathbf{X}\boldsymbol{\beta} + \varepsilon, \varepsilon|\mathbf{X} \sim f(\varepsilon)$$

Where y^* is the revenue per year, $\mathbf{X}$ are the characteristics and other variables of video games, $\boldsymbol{\beta}$ are the coefficients and ε is the error term.

$$\begin{aligned} y = 0 & \quad \text{if} \quad y^* \leq 1\text{M USD} \\ y = 1 & \quad \text{if} \quad 1 \text{ MM USD} < y^* \leq 5 \text{ MM USD} \\ y = 2 & \quad \text{if} \quad 5 \text{ MM USD} < y^* \leq 20 \text{ MM USD} \\ y = 3 & \quad \text{if} \quad y^* > 20 \text{ MM USD} \end{aligned}$$

$$\begin{aligned} \mathbf{P}(y = 0|\mathbf{X}) &= \mathbf{P}(y^* \leq \mu_1|\mathbf{X}) \\ &= \mathbf{P}(\mathbf{X}\boldsymbol{\beta} + \varepsilon \leq \mu_1|\mathbf{X}) \\ &= \mathbf{P}(\varepsilon \leq \mu_1 - \mathbf{X}\boldsymbol{\beta}|\mathbf{X}) \\ &= F(\mu_1 - \mathbf{X}\boldsymbol{\beta}) \end{aligned}$$

$$\begin{aligned} \mathbf{P}(y = 1|\mathbf{X}) &= \mathbf{P}(\mu_1 < y^* \leq \mu_2|\mathbf{X}) \\ &= \mathbf{P}(\mu_1 < \mathbf{X}\boldsymbol{\beta} + \varepsilon \leq \mu_2|\mathbf{X}) \\ &= \mathbf{P}(\mu_1 - \mathbf{X}\boldsymbol{\beta} < \varepsilon \leq \mu_2 - \mathbf{X}\boldsymbol{\beta}|\mathbf{X}) \\ &= F(\mu_2 - \mathbf{X}\boldsymbol{\beta}) - F(\mu_1 - \mathbf{X}\boldsymbol{\beta}) \end{aligned}$$

$$\begin{aligned}
\mathbf{P}(y = 2|\mathbf{X}) &= \mathbf{P}(\mu_2 < y^* \leq \mu_3|\mathbf{X}) \\
&= \mathbf{P}(\mu_2 < \mathbf{X}\boldsymbol{\beta} + \varepsilon \leq \mu_3|\mathbf{X}) \\
&= \mathbf{P}(\mu_2 - \mathbf{X}\boldsymbol{\beta} < \varepsilon \leq \mu_3 - \mathbf{X}\boldsymbol{\beta}|\mathbf{X}) \\
&= F(\mu_3 - \mathbf{X}\boldsymbol{\beta}) - F(\mu_2 - \mathbf{X}\boldsymbol{\beta})
\end{aligned}$$

$$\begin{aligned}
\mathbf{P}(y = 3|\mathbf{X}) &= \mathbf{P}(y^* > \mu_3|\mathbf{X}) \\
&= \mathbf{P}(\mathbf{X}\boldsymbol{\beta} + \varepsilon > \mu_3|\mathbf{X}) \\
&= \mathbf{P}(\varepsilon > \mu_3 - \mathbf{X}\boldsymbol{\beta}|\mathbf{X}) \\
&= 1 - F(\mu_3 - \mathbf{X}\boldsymbol{\beta})
\end{aligned}$$

$$\mathbf{P}(y = 0|\mathbf{X}) = \mu_1 - \mathbf{X}\boldsymbol{\beta}$$

$$\mathbf{P}(y = 1|\mathbf{X}) = \mu_2 - \mathbf{X}\boldsymbol{\beta}$$

$$\mathbf{P}(y = 2|\mathbf{X}) = \mu_3 - \mathbf{X}\boldsymbol{\beta}$$

ε

Supongamos que tenemos n observaciones o, en este caso, videojuegos, los cuales son indexados con $i = 1, 2, 3, \dots, n$. Así, indexaremos a la variable de respuesta y como y_i , por lo que diremos que buscamos estimar las siguientes probabilidades:

$$\begin{aligned}
\mathbf{P}(\text{Revenue}_i \leq 1\text{M USD}|\mathbf{X}_i) &= \mathbf{P}(\varepsilon_i \leq \mu_1 - \mathbf{X}_i\boldsymbol{\beta}|\mathbf{X}_i) \\
&= F(\mu_1 - \mathbf{X}_i\boldsymbol{\beta})
\end{aligned}$$

$$\begin{aligned}
\mathbf{P}(1 \text{ MM USD} < \text{Revenue}_i \leq 5 \text{ MM USD}|\mathbf{X}_i) &= \mathbf{P}(\mu_1 - \mathbf{X}_i\boldsymbol{\beta} < \varepsilon_i \leq \mu_2 - \mathbf{X}_i\boldsymbol{\beta}|\mathbf{X}_i) \\
&= F(\mu_2 - \mathbf{X}_i\boldsymbol{\beta}) - F(\mu_1 - \mathbf{X}_i\boldsymbol{\beta})
\end{aligned}$$

$$\begin{aligned}
\mathbf{P}(5 \text{ MM USD} < \text{Revenue}_i \leq 20 \text{ MM USD} | \mathbf{X}_i) &= \mathbf{P}(\mu_2 - \mathbf{X}_i \boldsymbol{\beta} < \varepsilon_i \leq \mu_3 - \mathbf{X}_i \boldsymbol{\beta} | \mathbf{X}_i) \\
&= F(\mu_3 - \mathbf{X}_i \boldsymbol{\beta}) - F(\mu_2 - \mathbf{X}_i \boldsymbol{\beta})
\end{aligned}$$

$$\begin{aligned}
\mathbf{P}(\text{Revenue}_i > 20 \text{ MM USD} | \mathbf{X}_i) &= \mathbf{P}(\varepsilon_i > \mu_3 - \mathbf{X}_i \boldsymbol{\beta} | \mathbf{X}_i) \\
&= 1 - F(\mu_3 - \mathbf{X}_i \boldsymbol{\beta})
\end{aligned}$$

Donde, particularmente, F es una función logística. Nuestro objetivo es maximizar la función de verosimilitud (función que maximiza el valor de los parámetros μ_1 , μ_2 , μ_3 y $\boldsymbol{\beta}$ dada la información disponible):

$$\begin{aligned}
\mathbf{L}(\boldsymbol{\theta} | \text{Data}) &= \prod_{y_i=0} \mathbf{P}(\text{Revenue}_i \leq 1 \text{M USD} | \mathbf{X}_i) \\
&\quad \times \prod_{y_i=1} \mathbf{P}(1 \text{ MM USD} < \text{Revenue}_i \leq 5 \text{ MM USD} | \mathbf{X}_i) \\
&\quad \times \prod_{y_i=2} \mathbf{P}(5 \text{ MM USD} < \text{Revenue}_i \leq 20 \text{ MM USD} | \mathbf{X}_i) \\
&\quad \times \prod_{y_i=3} \mathbf{P}(\text{Revenue}_i > 20 \text{ MM USD} | \mathbf{X}_i) \\
&= \prod_{y_i=0} (F(\mu_1 - \mathbf{X}_i \boldsymbol{\beta})) \times \prod_{y_i=1} (F(\mu_2 - \mathbf{X}_i \boldsymbol{\beta}) - F(\mu_1 - \mathbf{X}_i \boldsymbol{\beta})) \\
&\quad \times \prod_{y_i=2} (F(\mu_3 - \mathbf{X}_i \boldsymbol{\beta}) - F(\mu_2 - \mathbf{X}_i \boldsymbol{\beta})) \times \prod_{y_i=3} (1 - F(\mu_3 - \mathbf{X}_i \boldsymbol{\beta}))
\end{aligned}$$

where:

$$\boldsymbol{\theta} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \\ \boldsymbol{\beta} \end{bmatrix}$$

Así, el problema consiste en resolver:

$$\begin{aligned}
\max_{\theta} \mathbf{L}(\theta|\text{Data}) = & \prod_{\text{Revenue}_i \leq 1\text{M USD}} (F(\mu_1 - \mathbf{X}_i\boldsymbol{\beta})) \\
& \times \prod_{1 \text{ MM USD} < \text{Revenue}_i \leq 5 \text{ MM USD} | \mathbf{X}_i} (F(\mu_2 - \mathbf{X}_i\boldsymbol{\beta}) - F(\mu_1 - \mathbf{X}_i\boldsymbol{\beta})) \\
& \times \prod_{5 \text{ MM USD} < \text{Revenue}_i \leq 20 \text{ MM USD}} (F(\mu_3 - \mathbf{X}_i\boldsymbol{\beta}) - F(\mu_2 - \mathbf{X}_i\boldsymbol{\beta})) \\
& \times \prod_{\text{Revenue}_i > 20 \text{ MM USD}} (1 - F(\mu_3 - \mathbf{X}_i\boldsymbol{\beta}))
\end{aligned}$$

Datos

Usamos como fuente: <https://games-stats.com/>, una descarga de datos de 2021. La tabla de datos originalmente descargada contenía información de 53,650 videojuegos para computadora de los últimos 40 años, acumulando 18.5 billones de dólares.

La tabla de datos de games-stats.com se utilizó como base de datos central debido a su tamaño y variables disponibles. Fue validado con otros datos encontrados en línea, y tenían un tamaño similar entre ellos. Se agregaron más variables con el propósito de enriquecer el análisis.

Hay una gran cantidad de etiquetas (tags) encontradas en la tabla de datos, por lo que resulta complicado clasificar un juego en una sola categoría. Sin embargo, el valor de la etiqueta radica en el hecho de que son los usuarios quienes etiquetan un juego. Esto nos dice cómo un usuario percibe un juego. En total ubicamos 417 tags distintas.

En este caso, requerimos una reducción de dimensionalidad. El modelo debía evaluar más de 450 etiquetas diferentes, algo inviable. Tener 450 etiquetas para evaluar reduce la simplicidad e interpretabilidad del modelo. Así, aplicamos un par de metodologías:

- Extreme Random Decision Tree method: Que es una metodología de Machine Learning que ayudará a considerar menos variables dada la relevancia para los ingresos.
- Spearman Correlation: que muestra la correlación con los ingresos de determinadas variables y muestra también la significación estadística basada en una prueba t. Así, la etiqueta de un jugador tiene la correlación significativa más alta con los ingresos.

Tags	Juegos	Tags	Juegos	Tags	Juegos	Tags	Juegos	Tags	Juegos	Tags	Juegos
Indie	36,782	Combat	3,866	Multiple Endings	2,065	Historical	1,313	Music	910	Demons	626
Action	25,650	Female Protagonist	3,857	Roguelike	2,054	Walking Simulator	1,312	Competitive	882	Destruction	616
Adventure	23,865	Violent	3,796	Puzzle Platformer	2,047	Resource Management	1,293	Dark Humor	881	Tactical RPG	616
Casual	23,618		3,677	War	1,994	Interactive Fiction	1,292	Aliens	880	Party-Based RPG	594
Singleplayer	23,597	Open World	3,604	Shoot 'Em Up	1,993	Memes	1,252	Clicker	872	Real-Time	589
2D	12,837	Sexual Content	3,598	Linear	1,849	Dungeon Crawler	1,240	Nature	866	2D Fighter	583
Strategy	11,854	Visual Novel	3,502	Character Customization	1,813	Score Attack	1,229	Driving	862	Automobile Sim	582
Simulation	11,569	Comedy	3,398	Hand-drawn	1,804	Dating Sim	1,225	Emotional	862	Match 3	581
RPG	11,097	Turn-Based	3,359	Old School	1,794	Surreal	1,212	Fight	857	Rhythm	571
Puzzle	9,354	Action-Adventure	3,342	Massively Multiplayer	1,738	Top-Down Shooter	1,212	Arena Shooter	846	Moddable	565
Multiplayer	8,185	Co-op	3,295	Procedural Generation	1,738	Experimental	1,204	Detective	846	Nonlinear	553
Atmospheric	8,117	Top-Down	3,289	Action RPG	1,735	Post-apocalyptic	1,201	Party	845	Modern	551
Early Access	7,604	Management	3,287	Turn-Based Strategy	1,734	Mod	1,181	1980s	837	Tutorial	543
Platformer	7,103	Third Person	3,240	Replay Value	1,706	RTS	1,167	Perma Death	836	Dystopian	541
Story Rich	6,711	Cartoon	3,210	Classic	1,672	Isometric	1,151	Immersive Sim	824	Parkour	539
3D	6,584	Gore	3,205	Local Co-Op	1,651	Stealth	1,146	Investigation	820	Comic Book	534
Shooter	6,181	FPS	3,100	Online Co-Op	1,641	Dark Fantasy	1,129	Precision Platformer	815	Thriller	534
Pixel Graphics	6,174	Sports	2,941	Survival Horror	1,598	Education	1,127	Economy	809	Alternate History	515
Fantasy	5,910	Mystery	2,704	Hidden Object	1,597	Narration	1,125	Beat 'em up	805	Artificial Intelligence	496
Colorful	5,629	Point & Click	2,671	Logic	1,586	1990's	1,112	NSFW	781	CRPG	490
Arcade	5,564	Psychological	2,660	Mature	1,582	Drama	1,104	Time Management	782	Grand Strategy	489
Horror	5,504	Stylized	2,659	Magic	1,575	Text-Based	1,095	Beautiful	767	Crime	487
Anime	5,424	Space	2,611	Roguelite	1,558	Base Building	1,089	Cinematic	728	Grid-Based Movement	484
Cute	5,417	Minimalist	2,591	3D Platformer	1,519	Card Game	1,077	Metroidvania	727	Space Sim	483
First-Person	5,351	Physics	2,573	Futuristic	1,518	Abstract	1,072	Team-Based	726	Lore-Rich	471
Funny	5,180	PVP	2,494	Fast-Paced	1,480	Hentai	1,051	City Builder	718	Mouse only	468
Soundtrack	4,886	Choices Matter	2,464	Turn-Based Combat	1,467	Fighting	1,033	Real Time Tactics	702	Supernatural	465
VR	4,862	Building	2,456	PVE	1,466	Third-Person Shooter	1,029	Strategy RPG	696	MMORPG	454
Exploration	4,806	Sandbox	2,415	Crafting	1,451	4 Player Local	1,005	Loot	677	Addictive	451
Retro	4,734	Cartoonish	2,389	Bullet Hell	1,447	Tower Defense	997	Psychodelic	672	Souls-like	448
Sci-Fi	4,601	2D Platformer	2,378	Short	1,428	2.5D	992	Character Action Game	669	Trading	448
Great Soundtrack	4,580	Psychological Horror	2,323	Medieval	1,424	Cyberpunk	986	Twin Stick Shooter	662	Split Screen	436
Free to Play	4,473	Tactical	2,317	JRPG	1,396	Military	979	Conversation	657	Dark Comedy	431
Difficult	4,445	Side Scroller	2,243	Romance	1,373	Robots	963	Tabletop	653	Open World Survival Craft	429
Survival	4,410	Realistic	2,220	Hack and Slash	1,365	Action Roguelike	942	Level Editor	651	Science	426
Family Friendly	4,231	Racing	2,198	Choose Your Own Adventure	1,325	Immersive	934	Runner	647	Metaphory	425
Dark	3,940	Controller	2,148	Turn-Based Tactics	1,325	Board Game	916	Life Sim	645	Inventory Management	413
Relaxing	3,924	Local Multiplayer	2,136	RPGMaker	1,317	LGRTQ+	913	Wargame	636	Philosophical	413

There is a large quantity of tags found in the database, thus it makes complicated to classify a game into a single category. However, tag's value lies in the fact that users are the ones who tag a game. It tells us how a user perceives a game.

There are 417 tags in the database with a particular category for each one in which a game can be.

Figura 8.2: En la tabla de datos ubicamos 417 tags distintas

8.3. Modelos de conteo y otras respuestas

Una variabe de conteo es una variable que toma valores enteros no negativos y que cumple con dos características:

1. No tienen, de forma natural, una cuota superior
2. El valor cero debe ser posible para algunos de los elementos de la muestra

Muchas variables que conocemos cumplen con estasn condiciones. Por ejemplo, el número de veces que un individuo es detenido al año, el número de cigarros que una persona fuma al día, el número de patentes que una empresa registra en un año, etc. Por el contrario, el número de hijos de una familia que se gradua de la universidad no cumple con la condición 1, ya que ese número está topado por el número de hijos que tiene una familia.

8.3.1. Modelos de conteo del tipo Poisson

En esta sección analizaremos sólo uno de los modelos de conteo, el mode de conteo basado en una función de distribución del tipo Poisson. Así, sea y una variable de conteo y $\mathbf{x}$ un vector de variables explicativas. De esta forma

estaremos interesados en la regresión poblacional dada por:

$$\mathbb{E}[y|\mathbf{x}] = \mu(\mathbf{x})$$

El modelo Poisson es el más utilizado por su simplicidad para implementar mediante un procedimiento de máxima verosimilitud. Los supuestos del modelo son los siguientes.

En primer lugar, asumiremos que existe una función de densidad para y , $f(y|\mathbf{x}) = f(y|x_1, x_2, \dots, x_K)$, que tiene la forma de Poisson:

$$f(y|\mathbf{x}) = \frac{e^{-\mu(\mathbf{x})} \cdot \mu(\mathbf{x})^y}{y!} \quad (8.4)$$

Donde $\mu(\mathbf{x}) = \mathbb{E}[y|\mathbf{x}]$ y $y = 0, 1, \dots$. En segundo lugar, asumiremos que:

$$\mu(\mathbf{x}) = e^{\mathbf{x}\boldsymbol{\beta}}$$

donde $\mathbf{x}$ es un vector de $1 \times K$ y $\boldsymbol{\beta}$ es un vector de $K \times 1$. Asumiremos que dada la muestra $\{(\mathbf{x}_i, y_i); i = 1, 2, \dots, N\}$ es factible estimar los parámetros $\boldsymbol{\beta}$ mediante un procedimiento de Máxima Verosimilitud.

Un tercer supuesto es que se cumple la propiedad de la distribución Poisson en la que:

$$Var(y|\mathbf{x}) = \mathbb{E}[y|\mathbf{x}] = \mu(\mathbf{x})$$

No obstante, es posible observar que planteamientos en los que asumimos que:

$$Var(y|\mathbf{x}) = \sigma^2 \mathbb{E}[y|\mathbf{x}]$$

Donde $\sigma^2 > 0$ es una razón media de la varianza para cual observamos dos casos:

- Si $\sigma^2 > 1$ entonces la varianza es más grande que la media, por lo que estaremos en el caso en que existe una sobredispersión
- Si $\sigma^2 < 1$ entonces la varianza es menor que la media, por lo que estaremos en el caso en que existe una subdispersión

Ahora plantearemos el proceso de estimación. Para lo cual requerimos establecer la función de verosimilitud a partir de la ecuación (8.4) para quedar de la siguiente forma:

$$L(\boldsymbol{\beta}) = \prod_{i=1}^n f(y_i|\mathbf{x}_i) = \frac{e^{-\mu(\mathbf{x}_i)} \cdot \mu(\mathbf{x}_i)^{y_i}}{y_i!} \quad (8.5)$$

Tomando el logaritmo tenemos:

$$\ln L(\boldsymbol{\beta}) = \sum_{i=1}^n \ln(f(y_i|\mathbf{x}_i)) = \sum_{i=1}^n -\mu(\mathbf{x}_i) + y_i \ln(\mu(\mathbf{x}_i)) - \ln(y_i!) \quad (8.6)$$

Donde $\mu(\mathbf{x}_i) = e^{\mathbf{x}_i \boldsymbol{\beta}}$. La estimación de los parámetros $\boldsymbol{\beta}$ serán resultado de igualar a cero y resolver la ecuación:

$$\frac{\partial \ln L(\boldsymbol{\beta})}{\partial \boldsymbol{\beta}} = \frac{\partial}{\partial \boldsymbol{\beta}} \sum_{i=1}^n -\mu(\mathbf{x}_i) + y_i \ln(\mu(\mathbf{x}_i)) - \ln(y_i!) \quad (8.7)$$

La varianza de los estimadores estará dada por:

$$\text{Var}(\boldsymbol{\beta}) = [-\mathbb{E}[H(\boldsymbol{\beta})]]^{-1} = \left[-\mathbb{E} \left[\frac{\partial^2 \ln L(\boldsymbol{\beta})}{\partial \boldsymbol{\beta} \partial \boldsymbol{\beta}'} \right] \right]^{-1} \quad (8.8)$$

Finalmente, de forma similar a los modelos de elección binaria, multinomial y múltiple ordenada, los resultados se interpretan en sus efectos marginales. Esos efectos, en el caso de una variable continua, serán:

$$EMg_j = \frac{\partial \mathbb{E}[y_i|\mathbf{x}_i]}{\partial x_{ij}} = e^{\mathbf{x}_i \boldsymbol{\beta}} \cdot \beta_j$$

En el caso de variables dicótomicas:

$$EMg_j = \mathbb{E}[y_i|\mathbf{x}_i, x_{ij} = 1] - \mathbb{E}[y_i|\mathbf{x}_i, x_{ij} = 0]$$

9

Modelos con datos truncados, censurados, con endogeneidad por selección de muestra y otros casos

En esta sección discutiremos dos casos generales conocidos como de truncamiento y censura de datos. Ambos casos dan pie a casos particulares como los modelos Tobit y de selección de muestra, en el cual el ejemplo más conocido es el ejemplo de Heckman.

Decimos que existe truncamiento cuando hacemos inferencia sobre una población a partir de una muestra que fue tomada de una sección de dicha población. Por otro lado, censura es una condición más común de los datos. Esta situación se presenta como un defecto de los datos, presumiblemente, si los datos no estuvieran censurados estos deberían ser posiblemente observados mediante muestreos de la población de interés. Analicemos primero una forma de truncamiento y luego una de censura.

9.1. Truncamiento

Truncamiento es una condición observada cuando se toma una muestra a partir de una población que ha sido restringida o truncada. Para resolver este tipo de problemas requerimos del uso de funciones de distribución truncadas. Las cuales son una parte por encima o por debajo de algún valor específico





Figura 9.1: ¿Talento y la belleza están negativamente correlacionados?

en el soporte de la función original. Por ejemplo, cuando analizamos la distribución del ingreso de las personas para aquellos individuos que ganan más de una cierta cantidad dada.

Tomemos un ejemplo más retomado de Cunningham (2021) [Cun21]. Una publicación de blog de CNN de 2009 informó que Megan Fox, quien protagonizó la película *Transformers*, fue votada como la peor y más atractiva actriz de 2009 en una encuesta sobre estrellas de cine. La publicación infería que había una implicación de que el talento y la belleza están negativamente correlacionados. ¿Pero lo son? ¿Y por qué podrían serlo? ¿Qué pasa si en realidad son independientes entre sí pero están correlacionados negativamente en una muestra de estrellas de cine debido al sesgo del colisionador? Es ¿eso es posible? Un diagrama que ilustra la situación anterior es el mostrado en la figura 9.1.

En la figura 9.2 muestra una simulación de la situación. El panel inferior izquierdo muestra el diagrama de dispersión entre talento y belleza. Observe que las dos variables son extracciones aleatorias e independientes de la distribución normal estándar, lo que crea una nube de datos alargada. Pero debido a que “estrella de cine” se encuentra en el percentil 85 superior de la distribución de una combinación lineal de talento y belleza, la muestra consta de personas cuya puntuación combinada se encuentra en la parte superior derecha de la distribución conjunta. Esta frontera tiene una pendiente negativa y se encuentra en la parte superior derecha de la nube de datos, lo que crea una correlación negativa entre las observaciones en la muestra de estrellas de cine. Sin embargo, sabemos que, de hecho, no hay relación entre las dos variables. Este tipo de selección de muestras crea correlaciones espurias. Una muestra aleatoria de la población completa sería suficiente para mostrar que no existe relación entre las dos variables, pero al dividir la muestra en estrellas de cine únicamente, introducimos correlaciones espurias entre las dos variables de interés.

Figura 9.2: Relación entre belleza y talento, retomado de [Cun21].



Demos un poco de formalidad el problema. Digamos que la función de densidad truncada sera aquella función continua de la variable x dada por $f(x)$ y que dada una constante a , la definiremos como:

$$f(x|x > a) = \frac{f(x)}{P(x > a)} \quad (9.1)$$

En estos casos, la condición más común es emplear una función de densidad normal truncada. Así, si x tiene una distribución normal con media μ y desviación estándar σ , entonces:

$$P(x > a) = \int_{-\infty}^a \frac{1}{\sqrt{2\pi\sigma^2}} e^{\frac{x-\mu}{\sigma^2}} dx = 1 - \Phi\left(\frac{a-\mu}{\sigma}\right) = 1 - \Phi(\alpha)$$

Donde $\Phi(\cdot)$ es la función de probabilidad acumulada de la distribución normal estándar. De esta forma, podemos construir la función de densidad

truncada como:

$$\begin{aligned}
f(x|x > a) &= \frac{f(x)}{1 - \Phi(\alpha)} \\
&= \frac{\frac{1}{\sqrt{2\pi}\sigma^2} e^{-\frac{1}{2}\left(\frac{a-\mu}{\sigma}\right)^2}}{1 - \Phi(\alpha)} \\
&= \frac{\frac{1}{\sigma} \cdot \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{a-\mu}{\sigma}\right)^2}}{1 - \Phi(\alpha)} \\
&= \frac{\frac{1}{\sigma} \cdot \phi(\alpha)}{1 - \Phi(\alpha)} \tag{9.2}
\end{aligned}$$

Donde $\phi(\cdot)$ es la función de densidad de probabilidad de una normal estándar, lo cual es cierto dado el Teorema del Límite Central.

Dado lo anterior podemos plantear el concepto de regresión truncada. Para lo cual asumiremos que tenemos una ecuación de regresión del tipo:

$$y_i = \mathbf{x}_i \boldsymbol{\beta} + \varepsilon_i$$

Donde, de forma convencional, $\mathbf{x}_i$ es un vector de variables explicativas de $1 \times K$ y $\boldsymbol{\beta}$ es un vector de parámetros de $K \times 1$, y

$$\varepsilon_i | \mathbf{x}_i \sim N(0, \sigma^2)$$

Así:

$$y_i | \mathbf{x}_i \sim N(\mathbf{x}_i \boldsymbol{\beta}, \sigma^2)$$

En este caso estamos interesados en la distribución de y_i dado que y_i es más grande que el punto de truncamiento a . Así, diremos que estamos interesados en la recta de regresión que estará dada por:

$$\mathbb{E}[y_i | y_i > a] = \mathbf{x}_i \boldsymbol{\beta} + \sigma \frac{\phi\left(\frac{a - \mathbf{x}_i \boldsymbol{\beta}}{\sigma}\right)}{1 - \Phi\left(\frac{a - \mathbf{x}_i \boldsymbol{\beta}}{\sigma}\right)} \tag{9.3}$$

De esta forma la media condicional es una función no lineal de a , σ , $\mathbf{x}_i$ y $\boldsymbol{\beta}$. Digamos que tenemos:

$$\mathbb{E}[y_i | y_i > a] = \mathbf{x}_i \boldsymbol{\beta} + \sigma \lambda(\alpha_i) \tag{9.4}$$

Donde $\alpha_i = \left(\frac{a - \mathbf{x}_i}{\sigma}\right)$. Por simplicidad utilizaremos la siguiente notación: $\lambda_i = \lambda(\alpha_i)$ y $\delta_i = \delta(\alpha_i)$. De esta forma planteamos la ecuación a estimar será:

$$\begin{aligned} y_i | y_i > a &= \mathbb{E}[y_i | y_i > a] + \varepsilon_i \\ &= \mathbf{x}_i \boldsymbol{\beta} + \sigma \lambda_i + \varepsilon_i \end{aligned}$$

Donde:

$$Var(\varepsilon_i) = \sigma^2(1 - \lambda_i^2 + \lambda_i \alpha_i) = \sigma^2(1 - \delta_i)$$

De forma similar:

$$Var(y_i | y_i > a) = \sigma^2(1 - \delta_i)$$

Es decir, una regresión truncada tiene errores heterocedásticos. La estimación de este tipo de modelos es por un procedimiento de máxima verosimilitud.

Ahora platearemos los efectos marginales como:

$$\begin{aligned} \frac{\partial \mathbb{E}[y_i | y_i > a]}{\partial \mathbf{x}_i} &= \boldsymbol{\beta} + \sigma^2 \frac{\partial \lambda_i}{\partial \alpha_i} \frac{\partial \alpha_i}{\partial \mathbf{x}_i} \\ &= \boldsymbol{\beta} + \sigma^2 (\lambda_i^2 - \alpha_i \lambda_i) - \frac{\boldsymbol{\beta}}{\sigma} \\ &= \boldsymbol{\beta} (1 - \lambda_i^2 + \alpha_i \lambda_i) \\ &= \boldsymbol{\beta} (1 - \delta_i) \end{aligned}$$

Ahora veamos un caso particular del truncamiento, particularmente el caso de truncamiento incidental. Supongamos que tenemos dos variables aleatorias y y z , las cuales tienen una distribución conjunta bivariada con una coeficiente de correlación ρ . En estos casos estamos interesados en la distribución de y dado que z excede un valor particular.

La intuición sugiere que si y y z están correlacionadas positivamente, entonces el truncamiento de z debería desplazar la distribución de y a la derecha. Así, estamos ininteresados en:

1. La forma del truncamiento incidental
2. La media y varianza del truncamiento incidental

En estos casos la función de densidad conjunta de y y z estará dada por:

$$f(y, z | z > a) = \frac{f(y, z)}{P(z > a)}$$

Si y y z tienen una distribución normal conjunta bivarada con medias μ_y y μ_z ; desviaciones estándar σ_y y σ_z , y un coeficiente de correlación ρ , entonces la media será:

$$\mathbb{E}[y|z > a] = \mu_y + \rho\sigma_y\lambda$$

Donde:

$$\lambda = \frac{\phi\left(\frac{a-\mu_z}{\sigma_z}\right)}{1 - \Phi\left(\frac{a-\mu_z}{\sigma_z}\right)}$$

Por su parte la varianza será:

$$\text{Var}(y|z > a) = \sigma_y^2[1 - \sigma^2\delta(\alpha_z)]$$

Donde:

$$\delta = \frac{\lambda}{\lambda - \left(\frac{a-\mu_z}{\sigma_z}\right)}$$

Como mencionamos anteriormente, la media condicional está desplazada en el sentido de la correlación entre las variables aleatorias y y z . En su caso el desplazamiento dependerá de si la correlación es positiva o negativa.

Adicionalmente, supongamos un modelo lineal subyacente:

$$z_i^* = \mathbf{w}_i\boldsymbol{\gamma} + u_i$$

y un proceso lineal dado por:

$$y_i = \mathbf{x}_i\boldsymbol{\beta} + \varepsilon_i$$

Dado lo anterior, podemos establecer la regla de selección de muestra como y_i es observada siempe que z_i^* es más grande que cero. De esta forma planteamos la ecuación de regresión como:

$$\begin{aligned} \mathbb{E}[y_i|y_i \text{ es observada}] &= \mathbb{E}[y_i|z_i^* > 0] \\ &= \mathbb{E}[y_i|\mathbf{w}_i\boldsymbol{\gamma} + u_i > 0] \\ &= \mathbb{E}[y_i|u_i > -\mathbf{w}_i\boldsymbol{\gamma}] \\ &= \mathbb{E}[\mathbf{x}_i\boldsymbol{\beta} + \varepsilon_i|u_i > -\mathbf{w}_i\boldsymbol{\gamma}] \\ &= \mathbf{x}_i\boldsymbol{\beta} + \mathbb{E}[\varepsilon_i|u_i > -\mathbf{w}_i\boldsymbol{\gamma}] \\ &= \mathbf{x}_i\boldsymbol{\beta} + \rho\sigma_\varepsilon\lambda_i \\ &= \mathbf{x}_i\boldsymbol{\beta} + \beta_\lambda\lambda_i \end{aligned}$$

Donde:

$$\lambda_i = \frac{\phi\left(\frac{\mathbf{w}_i\boldsymbol{\gamma}}{\sigma_u}\right)}{\Phi\left(\frac{\mathbf{w}_i\boldsymbol{\gamma}}{\sigma_u}\right)}$$

Así, podemos plantear el modelo como:

$$\begin{aligned} y_i|z_i^* > 0 &= \mathbb{E}[y_i|\mathbf{w}_i\boldsymbol{\gamma} + u_i > 0] + v_i \\ &= \mathbf{x}_i\boldsymbol{\beta} + \beta_\lambda\lambda_i + v_i \end{aligned}$$

Dicho lo anterior podemos representar el problema como, un modelo subyacente:

$$z_i^* = \mathbf{w}_i\boldsymbol{\gamma} + u_i$$

De forma que:

$$\begin{aligned} z_i^* &= 1 \text{ si } z_i > 0 \\ z_i^* &= 0 \text{ si } z_i \leq 0 \end{aligned}$$

Lo cual vamos a representar como:

$$\begin{aligned} P(z_i = 1|\mathbf{w}_i) &= \Phi(\mathbf{w}_i\boldsymbol{\gamma}) \\ P(z_i = 0|\mathbf{w}_i) &= 1 - \Phi(\mathbf{w}_i\boldsymbol{\gamma}) \end{aligned}$$

Junto con la ecuación lineal:

$$y_i = \mathbf{x}_i\boldsymbol{\beta} + \varepsilon_i \text{ sólo si } z_i = 1$$

Donde:

$$\begin{pmatrix} u_i \\ v_i \end{pmatrix} \sim \text{BivariateNormal}(0, 0, 1, \sigma_\varepsilon, \rho)$$

Con estos ajustes podemos llegar a:

$$\mathbb{E}[y_i|z_i = 1, \mathbf{x}_i, \mathbf{w}_i] = \mathbf{x}_i\boldsymbol{\beta} + \beta_\lambda\lambda_i$$

Donde:

$$\lambda_i = \frac{\phi(\mathbf{w}_i\boldsymbol{\gamma})}{\Phi(\mathbf{w}_i\boldsymbol{\gamma})}$$

Este modelo se le conoce como de Heckman (1979), el cual se estima en dos etapas:

1. Estimar el probit asociado para obtener $\hat{\gamma}$ y

$$\hat{\lambda}_i = \frac{\phi(\mathbf{w}_i \hat{\gamma})}{\Phi(\mathbf{w}_i \hat{\gamma})}$$

$$\hat{\delta}_i = \hat{\lambda}_i(\hat{\lambda}_i + \mathbf{w}_i \hat{\gamma})$$

2. Estimamos $\hat{\beta}, \hat{\beta}_\lambda = \rho \hat{\sigma}_\varepsilon$

9.2. Datos con censura

La censura es una condición más común que el truncamiento, ya que este último ocurre muchas veces por decisión del investigador. La censura es un problema observado en la distribución de la variable dependiente. Por ejemplo, es común encontrar variables que tienen un número considerable de valores cero: gasto en ciertos bienes, variables que no son de la preferencia de todos los consumidores, etc. No obstante, existe censura en cualquier parte de la distribución.

En este tipo de modelos asumiremos un modelo subyacente dado por:

$$\begin{aligned} y_i &= 0 \text{ si } y_i^* \leq b \\ y_i &= y_i^* \text{ si } y_i^* > b \end{aligned}$$

Donde b es una constante a partir de la cual se observa la censura y donde la ecuación del modelo subyacente es de la forma lineal:

$$y_i^* = \mathbf{x}_i \boldsymbol{\beta} + \varepsilon_i$$

En este caso analizamos el problema con el modelo de regresión de Tobin (1958), denominado Tobit, en alusión a Tobit y al uso de la función de densidad normal como función de distribución de la variable dependiente. En este modelo la forma del valor esperado de y_i estará dada por:

$$\mathbb{E}[y_i | \mathbf{x}_i] \neq \mathbf{x}_i \boldsymbol{\beta} \quad (9.5)$$

Lo cierto, es que a diferencia de la ecuación (9.5) el valor esperado de y_i^* sí es de una forma lineal como:

$$\mathbb{E}[y_i^* | \mathbf{x}_i] = \mathbf{x}_i \boldsymbol{\beta} \quad (9.6)$$

De esta manera, el valor esperado de y_i deberá ser ajustado para quedar como:

$$\mathbb{E}[y_i|\mathbf{x}_i] = \Phi\left(\frac{\mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right) (\mathbf{x}_i\boldsymbol{\beta} + \sigma\lambda_i) \quad (9.7)$$

Donde σ es la desviación estándar de y_i y:

$$\begin{aligned} \lambda_i &= \frac{\phi\left(\frac{b-\mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right)}{1 - \Phi\left(\frac{b-\mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right)} \\ &= \frac{\phi\left(\frac{0-\mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right)}{1 - \Phi\left(\frac{0-\mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right)} \\ &= \frac{\phi\left(\frac{\mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right)}{\Phi\left(\frac{\mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right)} \end{aligned}$$

Donde $\phi(\cdot)$ y $\Phi(\cdot)$ son las funciones de densidad y acumulada de la normal estándar. Además de que hemos asumido que la constante b es absorbida por la constante contenida en el vector $\boldsymbol{\beta}$

Dicho lo anterior, los efectos marginales de la ecuación (9.7) ahora serán:

$$\frac{\partial \mathbb{E}[y_i|\mathbf{x}_i]}{\partial x_k} = \beta_k \Phi\left(\frac{\mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right) \quad (9.8)$$

De forma particular, para la ecuación (9.6) el efecto marginal será dado por:

$$\frac{\partial \mathbb{E}[y_i^*|\mathbf{x}_i]}{\partial x_k} = \beta_k \quad (9.9)$$

Finalmente, en el caso de estimación, este es un caso más que se suele estimar por un proceso de máxima verosimilitud. Partamos de establecer la ecuación de verosimilitud como:

$$\begin{aligned} L(\boldsymbol{\beta}, \sigma) &= \prod_{y_i > 0} f(y_i^*|\mathbf{x}_i) \prod_{y_i = 0} P(y_i^* \leq 0) \\ &= \prod_{y_i > 0} \frac{1}{\sqrt{2\pi}\sigma^2} e^{-\frac{1}{2}\left(\frac{y_i - \mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right)^2} \prod_{y_i = 0} \Phi\left(-\frac{\mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right) \\ &= \prod_{y_i > 0} \frac{1}{\sqrt{2\pi}\sigma^2} e^{-\frac{1}{2}\left(\frac{y_i - \mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right)^2} \prod_{y_i = 0} \left(1 - \Phi\left(\frac{\mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right)\right) \end{aligned}$$

En su versión logaritmica, la ecuación de verosimilitud quedará como:

$$\begin{aligned} \ln L(\boldsymbol{\beta}, \sigma) &= \sum_{y_i > 0} \left[-\frac{1}{2} \ln(2\pi\sigma^2) - \frac{1}{2} \left(\frac{y_i - \mathbf{x}_i \boldsymbol{\beta}}{\sigma} \right)^2 \right] \\ &\quad + \sum_{y_i = 0} \left(1 - \Phi \left(\frac{\mathbf{x}_i \boldsymbol{\beta}}{\sigma} \right) \right) \end{aligned}$$

De esta última expresión podemos obtener las condiciones de primer orden para determinar un estimador para $\boldsymbol{\theta}' = (\boldsymbol{\beta}, \sigma)$, así como la matriz Hesiana (H) para determinar la varianza de estos estimadores.

$$\frac{\partial \ln L(\boldsymbol{\beta}, \sigma)}{\partial \boldsymbol{\theta}} = 0 \quad (9.10)$$

$$\frac{\partial^2 \ln L(\boldsymbol{\beta}, \sigma)}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}'} = H(\boldsymbol{\theta}) \quad (9.11)$$

$$\text{Var}(\hat{\boldsymbol{\theta}}) = [-\mathbb{E}[H(\boldsymbol{\theta})]]^{-1} \quad (9.12)$$

Otro caso similar de

10

Introducción a inferencia causal

10.1. Estimación de modelos para determinar efectos de tratamiento

10.1.1. Motivación del procedimiento Difference - in - Differences (DiD)

La técnica de Differences-in-Differences (DiD) es una de las más populares en ciencias sociales para estimar efectos causales en conjuntos no experimentales. Los diseños de DiD son una estrategia cuasi-experimental para estimar, entre otras cosas, efectos causales. DiD es la técnica más popular en la investigación en ciencias sociales cuantitativas. En general, todos los buenos diseños DiD están basados en algún tipo de experimento natural.

La historia es famosa y atribuida a John Snow (1855)—a continuación retomamos la narración del caso en el libro de Cunningham (2021) [Cun21]. Snow analizó las causas de una serie de olas de la pandemia de cólera en Londres en el siglo XIX. El cólera es una enfermedad que ataca a sus víctimas de forma repentina con síntomas como vómito y diarrea. En el siglo XIX el cólera en Londres era una enfermedad mortal y que, inicialmente, se creía que se transmitía de forma aeróbica.

Snow era un médico en la época en que Londres enfrentó 3 olas de pandemia de cólera que enfermó y mató a decenas de miles de personas y que, en su momento, se consideró como una enfermedad misteriosa.

En aquel momento en el siglo XIX, los doctores no podían ayudar a las víctimas de la enfermedad, ya que no estaban equivocados sobre el mecanismo

que causaba la cólera y que facilitaba el esparcimiento de la enfermedad. Los médicos creían que la cólera se esparcía mediante el aiete por causa de partículas microscópicas. De esta forma, la forma en que los médicos abordaron el problema fue poner en cuarentena a las personas infectadas o potencialmente infectadas con el objeto de disminuir la plaga. Algo que hoy día sabemos era ineficiente.

Snow, inicialmente, creía en la teoría de que la enfermedad se esparcía o transmitía de forma aeróbica. No obstante, con el paso del tiempo, Snow desarrolló una nueva teoría sobre la forma en que se transmitía el cólera, desechando la teoría de la transmisión aeróbica. Snow concluyó que la causa de la enfermedad era un microorganismo que ingresaba al cuerpo humano mediante el consumo de agua y alimentos.

Snow encontró que el principal medio de transmisión del cólera era el agua consumida por la población y que se multiplicaba por el hecho de que los desechos sanitarios se depositaban en la principal fuente de agua de la época, el río Támesis.

La forma en que Snow detectó la fuente principal y mediante la cual construyó su teoría fue una serie de anécdotas similares a las siguientes. Por ejemplo, notó que la transmisión del cólera solía seguir los patrones de comercio. En un caso de la llegada de un barco mercante a un puerto que tenía reportes de infecciones notó que la tripulación enfermaba sólo después de desembarcar, ya que la que no lo hacía no solía enfermarse. En otro caso notó que dos construcciones que tenían fuentes de agua distintas (origen del líquido distinto) tenían patrones de enfermedad distinta, en una había notablemente menos infecciones que en la otra.

Estas observaciones no eran consistentes con la teoría de la transmisión aeróbica. Así, Snow continuó recabando información. Un experimento natural ocurrió cuando notó que había el caso en dos proveedores de agua que tomaban agua de puntos distintos del Támesis, uno después del punto de desagüe del drenaje y otro más desde un punto anterior. Con esta información, Snow recabó información de los lugares que eran atendidos por las empresas y encontró que el número de casos de cólera por cada 10,000 habitantes era como se muestra en el Cuadro 10.1 y la Figura 10.1.

10.1.2. Estrategia de estimación

En la literatura se ha discutido algunos principios básicos que se deben cumplir en el caso de data sets en los que se puede implementar el

Cuadro 10.1: Tabla XII de Snow (1854)–Casos de cólera en Londres por cada 10,000 habitantes según proveedor de agua, retomado de Cunningham(2021, p. 472) [Cun21]

Nombre de la compañía	1849	1854
Southwark and Vauxhall	135	147
Lambert	85	19

DiD.[Rot+23] A estos principios se les puede denominar como el modelo canónico del DiD, donde solo existen dos periodos de tiempo disponibles, existe una población tratada por única vez a partir de que inicia el segundo periodo.

Otra forma de verlo es responder a estas preguntas:

1. ¿Todas las observaciones son tratadas al mismo tiempo?
2. ¿Está seguro de que se puede suponer que las tendencias entre todos los individuos son paralelas?
3. ¿Son suficientemente grandes los conjuntos de datos tratados y no tratados?

En esta sección describimos la forma en que estimaremos el modelo de DiD. La metodología DiD es una técnica utilizada en Econometría para medir el efecto sobre una variable dependiente o de respuesta cuantitativa y debido a un tratamiento o cambio, en un determinado período en el tiempo. Para tal efecto estimamos una ecuación como la siguiente:

$$y_{it} = \beta_1 + \beta_2 T_t + \beta_3 D_t + \theta T_t \times D_t + \boldsymbol{\gamma} \mathbf{X}_{it} + \varepsilon_{it} \quad (10.1)$$

Donde y_{it} es la variable sobre la cual queremos evaluar el efecto de un tratamiento, $\mathbf{X}_{it}$ es un conjunto de variables de control, que incluye a las variables de efectos fijos (temporales, de individuos o del tipo que se decida) y, en su caso, una tendencia, entre otras. Finalmente, las variables T_t y D_i son variables dicotómicas que identifican con el valor de 1 el momento a partir del cual se observa el tratamiento y con 0 en cualquier otro caso, y con 1 los individuos que fueron tratados y con 0 en cualquier otro caso, respectivamente.




Figura 10.1: Comparación de los casos de cólera según proveedor de agua en Londres.

De esta forma, el producto $T_t \times D_t$ sería una variable dicotómica que indicaría con un 1 a aquellos individuos que fueron tratados a partir del momento en que se implementó el tratamiento y con 0 en cualquier otro caso. Bajo este escenario, θ es un coeficiente que captura el efecto del tratamiento, condicional a que se ha controlado por una serie de factores.

Otra forma de ver lo que se indica en la ecuación (10.1) es como la comparación de la diferencia en diferencia descrita por:

$$E = [(\bar{y}_{exit}|treatment) - (\bar{y}_{baseline}|treatment)] - [(\bar{y}_{exit}|placebo) - (\bar{y}_{baseline}|placebo)] \quad (10.2)$$

La expresión (10.2) cuantifica el efecto que tiene el tratamiento como la diferencia de medias de dos grupos: un grupo tratado y otro no tratado. Dentro de los cuales se ha comparado las medias de respecto de una línea base. Podemos plantear esto desde esta otra perspectiva. Pensemos que solo tenemos dos periodos $t = 1, 2$, en el cual en 1 no ha ocurrido el tratamiento y en 2 ya ha ocurrido. Así, el cambio en la variable de respuesta para los individuos

tratados será (suponiendo que omitimos la matriz $\mathbf{X}_{it}$ en la ecuación (10.1)):

$$\begin{aligned}\mathbb{E}[y_{i2}|D_i = 1] - \mathbb{E}[y_{i1}|D_i = 1] &= (\beta_1 + \beta_2 + \beta_3 + \theta) - (\beta_1 + \beta_3 + \theta) \\ &= \beta_2 + \theta\end{aligned}\tag{10.3}$$

Ahora, sobre los no tratados:

$$\begin{aligned}\mathbb{E}[y_{i2}|D_i = 0] - \mathbb{E}[y_{i1}|D_i = 0] &= (\beta_1 + \beta_2) - (\beta_1) \\ &= \beta_2\end{aligned}\tag{10.4}$$

Así, la diferencia en diferencia restulata de restar la ecuación (10.4) a la ecuación (10.3):

$$\begin{aligned}(\mathbb{E}[y_{i2}|D_i = 1] - \mathbb{E}[y_{i1}|D_i = 1]) - (\mathbb{E}[y_{i2}|D_i = 0] - \mathbb{E}[y_{i1}|D_i = 0]) \\ = \theta\end{aligned}\tag{10.5}$$

10.2. Control Sintético

10.2.1. Motivación

En esta sección utilizaremos como base el trabajo de Abadie (2021) [Aba21]. Por lo anterior pondremos énfasis en la factibilidad, los requerimientos de los datos, los requerimientos de contexto y algunos problemas metodológicos asociados a la palicación empírica del control sintético. Particularmente, nos enfocaremos en la importancia que tiene las características que hacen posible la implementación del control sintético.

Susan Athey y Guido Imbens en 2017 describieron al proceso de control sintéticos como la innovación más importante en la evaluación de políticas públicas en los últimos 15 años (Athey y Imbebs (2017) [AI17]). En los últimos años, el control sintético ha sido aplicado a diversos dominios: migración, conexiones políticas y cumplimiento de leyes, impuestos, crimen organizado y terrorismo, salario mínimo, entre otros. El uso de controles sintéticos no se limita a las ciencias sociales. También ha sido aplicado en ingeniería y ciencias biomédicas, por ejemplo.

Los métodos de control sintético fueron propuestos originalmente por Abadie y Gardeazabal (2003) y Abadie, Diamond y Hainmueller (2010) con el propósito de estimar los efectos de intervenciones agregadas –intervenciones que son implementadas a un nivle agregado afectando a un pequeño número

de unidades de in conjunto amplio de unidades como ciudades, regiones o países– en algún resultado agregado que sea de interés.

Consideremos una situación en la que una unidad agregada, tal como un estado o municipio, es expuesto a un evento o intervención de interés. En estos casos, los análisis tradicionales de regresión requieren muestras grandes y muchas observaciones dentro del los casos afectados por el evento. En un caso similar, el uso de series de tiempo para la evaluación de una política pública requiere de observaciones por muchos períodos para realiar un análisis adecuadamente.

El método de controles sintéticos está basado en la idea de que, cuando las unidades de observación son un número pequeño de entidades agregadas, una caombinación de unidades no afectadas podrían proveer una comparación más apropiada que una simple unidad observada de forma individual.

Esta técnica tiene múltiples aplicaciones que van desde la cuantificación de los efectos económicos de conflictos como el terrorista en el País Vasco (Abadie Gardeazabal, 2003), la implementación de regulación en el consumo de tabaco en el estado de California, Estados Unidos (Abadie et al., 2010), hasta la cancelación de infraestructura, como en el caso del Nuevo Aeropuerto Internacional de la Ciudad de México (NAIM) (Woo Mora, 2022).

El primer caso trata de una cuantificación de los efectos económicos del conflicto terrorista en el País Vasco. La observación que motivó el estudio fue que, tras el estallido del terrorismo a finales de la década de 1960, el PIB per cápita en el País Vasco disminuyó unos 10 puntos porcentuales en comparación con las regiones sin terrorismo. Al inicio de la actividad terrorista, a principios de la década de 1970, el País Vasco era una de las regiones más ricas de España, ocupando el tercer puesto en PIB per cápita (de 17 regiones). A finales de la década de 1990, tras 30 años de conflicto terrorista y político, el País Vasco había descendido al sexto puesto en PIB per cápita. Además, la tregua que ocurrió entre 1998 y 1999, considerada como un experimento natural, mostró que las empresas en el País Vasco durante este período reportaron un desempeño relativamente positivo cuando la tregua se hizo creíble y un rendimiento relativamente negativo al final de la tregua (Abadie Gardeazabal, 2003).

En este tipo de casos, un análisis puramente basado en series de tiempo es complejo de implementar, dado i) la gravedad del terrorismo y ii) la evolución de la economía que se vio afectada por la recesión económica que sufrió España durante la segunda mitad de la década de 1970 y la primera mitad de la de 1980, en el auge de la actividad terrorista. De esta forma, una

simple comparación de la evolución de la economía vasca con la del resto de España no solo reflejaría el efecto del terrorismo, sino también el efecto de las diferencias pre-terroristas en los determinantes del crecimiento económico (Abadie Gardeazabal, 2003).

De esta forma, lo, autores del estudio plantearon que la solución estaba en utilizar una combinación de otras regiones españolas (pool donador) para construir una región de control sintética que refleje las características económicas relevantes del País Vasco antes del inicio del terrorismo político vasco a finales de la década de 1960. De esta forma, se plantea construir un escenario alternativo sintético de la evolución económica posterior de este País Vasco sin terrorismo. Para finalmente, comparar la experiencia real del País Vasco con el contrafactual sintético. Un segundo caso se ubica en el estudio de los efectos de la Proposición 99, un programa a gran escala de control del tabaco implementado en California, Estados Unidos, en 1988. De acuerdo con este estudio, tras la Proposición 99, el consumo de tabaco disminuyó notablemente en California en comparación con una región comparable de control sintético—construida a partir del pool de donadores formado por otros estados en donde no se observó una intervención similar—. Las estimaciones señalan que, para el año 2000, las ventas anuales de cigarrillos per cápita en California eran aproximadamente 26 paquetes inferiores a las que habrían sido en ausencia de la Proposición 99 (Abadie et al., 2010).

Finalmente, el tercer caso es un análisis de las consecuencias derivadas de la cancelación de la construcción del NAIM. En este caso, la técnica de control sintético mostró que el efecto de la cancelación del NAIM sobre el PIB fue de -3

10.2.2. Planteamiento del método de estimación

Supongamos que tenemos datos para $J + 1$ unidades, es decir, observamos $j = 1, 2, \dots, J + 1$. Sin pérdida de generalidad, asumiremos que la primera unidad ($j = 1$) es la unidad que ha sido tratada, esto es, la unidad afectada por la intervención de política pública. El "donor pool." conjunto de donadores que se constituye por el conjunto de potenciales unidades de comparación, $j = 2, \dots, J + 1$, es una colección de unidades no tratadas o no afectadas por la intervención.

Asumiremos que nuestros datos son de una duración de T periodos y que los primeros T_0 periodos son previos a la intervención. Para cada unidad, j , y tiempo, t , observamos el resultado de interés, Y_{jt} . Para cada unidad, j , obser-

vamos un conjunto de k predictores del resultado observado, $X_{1j}, \dots, X_{kj}$ el cual podría incluir los valores de la variable analizada, Y_{jt} , pero en periodos previos y los cuales son en sí mismos no afectados por la intervención.

Los $K \times 1$ vectores $\mathbf{X}_1, \dots, \mathbf{X}_{J+1}$ contienen los valores de los predictores de las unidades $j = 1, \dots, J+1$, respectivamente. La matriz $k \times J$, $\mathbf{X}_0 = [\mathbf{X}_2, \dots, \mathbf{X}_{J+1}]$ contiene los valores de los predictores de las J unidades no correlacionadas. Para cada unidad j y periodo de tiempo t definimos Y_{jt}^N como la respuesta potencial que se hubiera observado sin la intervención. Para la unidad afectada por la intervención $j = 1$ y para el periodo postintervención $t > T_0$ definimos Y_{1t}^I como la respuesta potencial bajo la intervención.

De esta forma, el efecto de la intervención de interés para el periodo t afectado ($t > T_0$) estará dado por:

$$\tau_{1t} = Y_{1t}^I - Y_{1t}^N \quad (10.6)$$

De esta forma, el reto de la evaluación de política pública es estimar Y_{1t}^N para $t > T_0$. Esto es, construir el contrafactual.

Un control sintético es definido como el promedio ponderado de las unidades en el conjunto de donadores. Formalmente, un control sintético puede ser representado por un vector $J \times 1$ de pesos $\mathbf{W} = (w_2, \dots, w_{J+1})$. Dado el conjunto de pesos $\mathbf{W}$ los estimadores del control sintético de Y_{1t}^N y de τ_{1t} son:

$$\hat{Y}_{1t}^N = \sum_{j=2}^{J+1} w_j Y_{jt} \quad (10.7)$$

$$\hat{\tau}_{1t} = Y_{1t} - \hat{Y}_{1t}^N \quad (10.8)$$

Para evitar un escenario en el que la estimación sea explosiva, restringimos los pesos a que no sean negativos y que su suma sea 1. Note que también se debe considerar que el control sintético requiere que las variables en el data set sean rescaladas correctamente para considerar las diferencias por las unidades (por ejemplo, ingreso per cápita) o si la corrección no es necesaria puesto que las variables en los datos no se requieren rescalar por tamaño (por ejemplo, precios).

De esta forma, el control sintético se reduce a la pregunta de cómo deben ser los pesos $w_2, \dots, w_{J+1}$. Dado un conjunto de constantes $v_1, \dots, v_k$, podemos proponer la elección del control sintético $\mathbf{W}^* = (w_2^*, \dots, w_{J+1}^*)'$ que

minimiza:

$$\|\mathbf{X}_1 - \mathbf{X}_0\| = \left(\sum_{h=1}^k v_h (X_{h1} - w_2 X_{h2} - \dots - w_{J+1} X_{hJ+1})^2 \right)^{1/2} \quad (10.9)$$

Sujeto a que $w_j > 0$ y que $w_2 + \dots + w_{J+1} = 1$.

De esta forma, la estimación del efecto derivado del tratamiento en la unidad tratada en el momento $t = T_0 + 1, \dots, T$ es:

$$\hat{\tau} = Y_{1t} + \sum_{j=2}^{J+1} w_j^* Y_{jt} \quad (10.10)$$

Las constantes no negativas $\mathbf{V} = v_1, \dots, v_k$ en la ecuación (10.9) reflejan la importancia relativa en el control sintético los valores de los k predictores para la unidad de tratamiento $X_{11}, X_{21}, \dots, X_{k1}$. Así, la pregunta que queda por responder es cómo determinar $\mathbf{V}$. Una forma muy sencilla de determinar ese vecto es elegir cada v_h es la inversa de la varianza de $X_{h1}, \dots, X_{hJ+1}$, $h = 1, \dots, k$, lo que resulta en un efecto de rescalamiento de todos los renglones de $[\mathbf{X}_0 : \mathbf{X}_1]$ a una varianza unitaria.

10.2.3. ¿Por qué usar el control sintérico?

En principio consideremos que mediante el estimador de una refresión lineal es posible determinar el efecto del tratamiento facilmente mediante la construcción de un panel. Sea $\mathbf{Y}_0$ la matriz $(T - T_0) \times J$ de una resultado post-intervención para las unidades del conjunto de donadores. Sea $\bar{\mathbf{X}}_1$ y $\bar{\mathbf{X}}_0$ el resultado de agregar a las matrices $\mathbf{X}_1$ y $\mathbf{X}_0$, respectivamente, un vector de unos (1's). Para una matriz no singular $\bar{\mathbf{X}}_0 \bar{\mathbf{X}}_0'$, un estimador basado en una regresión del contrafactual Y_{1t}^N para $t > T_0$ es $\hat{\mathbf{B}}' \bar{\mathbf{X}}_1$, donde

$$\hat{\mathbf{B}} = (\bar{\mathbf{X}}_0 \bar{\mathbf{X}}_0')^{-1} \bar{\mathbf{X}}_0 \mathbf{Y}_0'$$

Lo cual es un estimador de regresión de $\bar{\mathbf{X}}_1$ en $\bar{\mathbf{X}}_0$.

También el control sintético evita los resultados explotativos, ya que los pesos en el control sintético son no negativos y suman 1.

Otra ventaja del control sintético es que existe transparencia en el proceso de estimación y en la construcción del contrafactual.

En cuanto a los requerimientos, el control sintético requiere la disponibilidad de datos para las unidades tratadas y para las no tratadas.

Finalmente, respecto de las extensiones, múltiples estudios han discutido estimaciones e inferencia con controles sintéticos para casos donde existen múltiples unidades tratadas. En este caso se pueden crear problemas de estimación.

11

Estimación de modelos de duración

12

Introducción al Aprendizaje Estadístico

12.1. Motivación, introducción y Notación en el análisis de regresión

Iniciemos con un ejemplo. Pensemos la regresión como un proceso de formalizar un gráfico de dispersión (scatter plot). Como ejemplo, considere la Figura 12.1 en la que se muestra el scatter plot entre los años de educación y el salario. Una hipótesis sensata es pensar que la relación es positiva e, incluso, lineal: a más años de estudio, más salario.

Este planteamiento, como se puede ver, se centra en la creación de una **hipótesis**. Es decir, hacer regresión lineal es asumir la hipótesis de que existe una relación entre las variables que puede ser capturada por un modelo analítico que llamamos ecuación de regresión.

En primer lugar, estableceremos un poco de notación. En el análisis de regresión, siempre partimos de una representación de una ecuación lineal o hipótesis (h) como:

$$y_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \dots + \beta_K x_{iK} + \varepsilon_i = h(x_{i1}, x_{i2}, \dots, x_{iK}) + \varepsilon_i \quad (12.1)$$

Donde cada una de las variables y_i , x_{ik} y ε_i se observan para $i = 1, 2, 3, \dots, N$ y $k = 1, 2, \dots, K$. Al conjunto de las variables x_{ik} se les llama características y a y_i se le suele decir variable objetivo, la cual estamos tratando de predecir. En este curso, al par (y_i, x_{ik}) le llamaremos ejemplo de entrenamiento, del cual tenemos N casos.




Figura 12.1: ¿Qué relación hay entre años de educación y el salario?, retomado de: <https://wol.iza.org/articles/using-linear-regression-to-establish-empirical-relationships/lang/es>

Por lo general, la hipótesis representada por la ecuación de regresión la representaremos para cada i de la forma matricial:

$$\begin{aligned}
 y_i &= \begin{pmatrix} x_{i1} & x_{i2} & \dots & x_{iK} \end{pmatrix} \begin{pmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_K \end{pmatrix} + \varepsilon_i \\
 &= \mathbf{X}'_i \boldsymbol{\beta} + \varepsilon_i \\
 &= h(\mathbf{X}'_i) + \varepsilon_i
 \end{aligned} \tag{12.2}$$

En este sentido, de forma relacionada, podemos definir la función de costos:

$$\begin{aligned}
 J(\boldsymbol{\beta}) &= \frac{1}{2} \sum_{i=1}^N (h(\mathbf{X}'_i) - y_i)^2 \\
 &= \frac{1}{2} \sum_{i=1}^N (\mathbf{X}'_i \boldsymbol{\beta} - y_i)^2
 \end{aligned} \tag{12.3}$$

12.2. Modelos no lineales

¿Qué pasa cuando la relación observada entre las variables no es lineal? Casi siempre pasa eso. A continuación discutiremos tres casos de ecuaciones que nos ayudarán a describir una relación no lineal mediante una transformación que hace a las relaciones lineales. Cada uno responde a condiciones o características que la experiencia del investigador tiene que solventar.

Cada una de las ecuaciones se distingue por la tasa de cambio de la variable y en relación a los cambios de la variable x . Partamos de que la forma más simple de una relación lineal está dada por la ecuación (12.4). Note que hemos eliminado los subíndices para indicar que la ecuación se cumple para cada uno de los elementos en la muestra, $i = 1, 2, \dots, n$. Sin pérdida de generalidad, digamos que en lugar de β_1 y β_2 empleamos a y b como constantes, como una forma de ilustrar cada uno de los fenómenos que discutimos a continuación.

$$y = a + bx \tag{12.4}$$

Esta ecuación (12.4) tiene la característica de que tiene una tasa de va-

riación constante para y en relación a x , de esta forma:

$$\frac{dy}{dx} = b \iff dy = bdx \iff \int dy = \int bdx \iff y = a + bx$$

Los siguientes modelos no lineales tienen una motivación similar, dependen de la forma en que se asuma la variación de y en función de la variación de x .

12.2.1. Regresión exponencial

Supongamos que y depende de x y que los cambios en y derivados de x son proporcionales a y , es decir:

$$\frac{dy}{dx} = by$$

Donde b es una constante. De esta forma podemos encontrar que:

$$\frac{dy}{dx} = by \iff \frac{dy}{y} = bdx \iff \int \frac{dy}{y} = \int bdx \iff \ln(y) = a + bx$$

De esta forma, tenemos que:

$$y = e^{bx} e^a \iff y = ke^{bx}$$

Por lo tanto, cuando estimamos una relación: $\ln(y) = a + bx$ estamos asumiendo que existe la siguiente relación: $\frac{dy}{dx} = by$. A este tipo de ecuaciones se les conoce como log-lineales. En la Figura 12.2 se ilustra la relación log-lineal - exponencial.

12.2.2. Regresión logarítmica

En este caso suponemos que los cambios en y por causa de cambios en x son proporcionales a la razón que guardan y y x , es decir:

$$\frac{dy}{dx} = b \frac{y}{x}$$

Por lo que podemos establecer:

$$\frac{dy}{dx} = b \frac{y}{x} \iff \frac{dy}{y} = b \frac{dx}{x} \iff \int \frac{dy}{y} = \int b \frac{dx}{x} \iff \ln(y) = a + \ln(x)$$




Figura 12.2: Funciones exponenciales, Retomado de Larsen y Marx (2012, p. 532) [LARSEN]

Así, podemos establecer que la forma funcional de la relación de y y x es como sigue y como se muestra en la Figura 12.3.

$$y = kx^b$$

12.2.3. Funciones logísticas

Este tipo de ecuaciones tienen la característica de que permiten modelar crecimientos poblacionales, aceptación de políticas públicas, aceptación de tecnologías, epidemias, etc. En este caso suponemos que enfrentamos que los cambios en y dados los cambios en x son proporcionales a y y a la distancia que y tiene respecto de un factor de saturación L (límite superior o punto de saturación poblacional, cobertura universal, infecciones en el total de la población, etc.).

En este caso suponemos que la variación estará dada por:

$$\frac{dy}{dx} = ky(L - y)$$

Donde k y L son constantes. Una vez solucionada la ecuación diferencial anterior, encontraremos que, si $L = 1$, entonces la solución será como sigue, la Figura 12.4 ilustra ecuaciones como la siguiente:

$$y = \frac{1}{1 + e^{a+bx}} \quad (12.5)$$




Figura 12.3: Funciones logarítmicas, Retomado de Larsen y Marx (2012, p. 536) [LARSEN]




Figura 12.4: Funciones logísticas, Retomado de Larsen y Marx (2012, p. 540) [LARSEN]

Ahora mostremos como llegar a la solución de la ecuación logística:

$$\begin{aligned}
 \frac{dy}{dx} &= ky(L-y) \iff \frac{dy}{y(L-y)} = kdx \iff \left(\frac{\frac{1}{L}}{y} + \frac{\frac{1}{L}}{(L-y)} \right) dy = kdx \\
 &\iff \frac{1}{L} \left(\frac{dy}{y} + \frac{dy}{(L-y)} \right) = kdx \iff \int \frac{1}{L} \left(\frac{dy}{y} + \frac{dy}{(L-y)} \right) = \int kdx \\
 &\iff \left(\int \frac{dy}{y} + \int \frac{dy}{(L-y)} \right) = \int Lkdx \iff (\ln(y) - \ln(L-y)) = Lkx + C \\
 &\iff (\ln(L-y) - \ln(y)) = -LC - Lkx \iff \ln \left(\frac{L-y}{y} \right) = -LC - Lkx \\
 &\iff \left(\frac{L-y}{y} \right) = e^{-LC-Lkx} \iff y = \frac{L}{1 + e^{-LC-Lkx}}
 \end{aligned}$$

Por lo tanto, la solución general de la ecuación será:

$$y = \frac{L}{1 + e^{a+bx}}$$

Donde asumimos que la forma lineal de la ecuación logística es:

$$\ln \left(\frac{L-y}{y} \right) = a + bx$$

12.2.4. Funciones polinomiales

Otro tipo de ecuaciones o funciones se asocian con una relación entre y y x del tipo no lineal, pero que puede describirse bajo una formulación de un polinomio de algún grado l . Este tipo de ecuaciones tienen la característica de que permiten modelar crecimientos poblacionales, aceptación de políticas públicas, aceptación de tecnologías, epidemias, etc., mediante una especificación menos compleja en términos matemáticos.

En muchas aplicaciones, una simple transformación logarítmica de la variable x ya no puede ser suficiente para lograr un ajuste satisfactorio. Una forma sencilla de obtener más flexibilidad es utilizar la regresión polinomial.




Figura 12.5: Funciones polinomiales, retomado de <https://discdown.org/flexregression/smoothreg.html>

Normalmente, se prefieren polinomios de bajo grado l . En la práctica, rara vez utilizamos polinomios de grado superior a $l = 3$, ya que las estimaciones pueden volverse bastante inestables con una alta variabilidad en los límites del dominio de variables. Además, pueden surgir inestabilidades numéricas en grados muy altos, en cuyo caso se requiere de re-escalar los datos.

En general, partamos de ecuaciones como:

$$y = a + b_1x^1 + b_2x^2 + \dots + b_lx^l \quad (12.6)$$

La figura 12.5 ilustra diferentes escenarios de ecuaciones como 12.6 con diferentes grados l .

12.3. Aprendizaje Estadístico

El aprendizaje estadístico juega un rol esencial en muchas áreas de la ciencia, finanzas y la industria. Algunos ejemplos son:

1. Predecir si un paciente—que se encuentra hospitalizado debido a un ataque al corazón—tendrá un segundo ataque. La predicción estará basada en métricas demográficas, de la dieta y de registros clínicos.
2. Predecir el precio de una acción en los siguientes 6 meses; considerando la base de las medidas de desempeño de la compañía y de otros datos económicos.
3. Identificar los números en la digitalización de formas escritas a mano.
4. Identificar los factores de riesgo para el cáncer de próstata, basados en datos clínicos y de otras variables demográficas.

El aprendizaje estadístico comprende a un conjunto de herramientas para modelar y entender conjuntos de datos complejos. También se le conoce como Machine Learning (ML), el cual conjuga el desarrollo reciente en el área de la estadística junto con el crecimiento en paralelo de la computación.

El aprendizaje estadístico considera muchos métodos convencionales y de uso amplio como análisis de regresión, clasificación, árboles de decisión, etc. También se refiere a una amplia gama de herramientas para entender o interpretar datos clasificadas como supervisadas y no supervisadas.

- El aprendizaje estadístico supervisado involucra la construcción de un modelo estadístico para predecir o estimar un resultado (o variable que se puede supervisar) basado en uno o más variables explicativas.
- El aprendizaje no supervisado considera variables explicativas, pero los resultados observados no son una variable explicada que sea susceptible de supervisión.

Ahora introduzcamos un poco de notación. Denotaremos a una variable independiente o explicativa con x_{ij} , si dicha variable es un conjunto de variables acomodadas en un vector utilizaremos $\mathbf{X}_i$; en estos casos denotaremos a un elemento o variable del vector $\mathbf{X}_i$ como x_{ik} , donde $i = 1, 2, \dots, n$ denota a los individuos en la muestra y $k = 1, 2, \dots, K$ denota al número de variables. Por convención diremos que $x_{i1} = 1$ para todo $i = 1, 2, \dots, n$, ya que en dicha variable consideraremos al término constante en la regresión.

Por su parte, los resultados, variables dependientes o variables de respuesta se denotarán como:

- y_i denotará una respuesta que es una cantidad continua

- g_i denotará una respuesta cualitativa, discreta o de grupo

Así, con $\mathbf{X}$, y $\mathbf{Y}$ y $\mathbf{G}$ denotaremos a la matriz y vector columna que contiene a todos los valores de las variables dependientes y de respuesta apiladas para cada uno de los elementos en la muestra indexados con i .

Usaremos mayúsculas como X , Y o G para representar a los aspectos genéricos de las variables. De esta forma, debe ser claro que las letras minúsculas serán empleadas para representar a valores observados de las variables, así el valor observado de la variable k -ésima para el elemento de la muestra i -ésimo en $\mathbf{X}$ será representado como x_{ij} . Finalmente, con la notación $\hat{Y}$ o $\hat{G}$ representaremos a los valores estimados o predichos.

El aprendizaje estadístico parte del establecimiento de que una variable dependiente Y es una función de un conjunto de variables explicativas $\mathbf{X} = [X_1, X_2, \dots, X_p]$. De esta forma plantearemos:

$$Y = f(\mathbf{X}) + \varepsilon \quad (12.7)$$

Así, el aprendizaje estadístico se trata de un conjunto de aproximaciones para f . ¿Para qué estimar f ? La respuesta es para hacer predicciones y para hacer inferencia. La más común de ambas razones es la predicción, con una predicción de Y podríamos establecer:

$$\hat{Y} = \hat{f}(\mathbf{X}) \quad (12.8)$$

12.3.1. Ajuste y separación del conjunto de datos

Supongamos la variable objetivo Y , un vector de variables explicativas o variables 'input' X y un modelo predictivo $\hat{f}(X)$ que es estimado a partir de un conjunto de entrenamiento τ .

Definiremos la función de pérdida derivada de la estimación y capturada por los errores entre Y y $\hat{f}(X)$ estará dada por:

$$L(Y, \hat{f}(X)) = \begin{cases} (Y - \hat{f}(X))^2 & \text{error cuadrático} \\ |Y - \hat{f}(X)| & \text{error absoluto} \end{cases} \quad (12.9)$$

De esta forma, podemos establecer un error cuadrático como:

$$\begin{aligned} \mathbb{E}[Y - \hat{Y}]^2 &= \mathbb{E}[f(X) + \varepsilon - \hat{f}(X)]^2 \\ &= \mathbb{E}[f(X) - \hat{f}(X)]^2 + Var(\varepsilon) \end{aligned}$$



Figura 12.6: División del conjunto de datos, retomado de Hastie, Tibshirani, y Friedman (2017, p. 222) [HTF17]

Donde $\mathbb{E}[f(X) - \hat{f}(X)]^2$ es el único componente reducible. Para hacer predicciones requerimos de un conjunto de datos de entrenamiento y otro más de prueba –en el primero estimamos $f(\cdot)$ y en el segundo hacemos predicciones–.

Finalmente, la condición de inferencia nos permite construir pruebas de hipótesis, estimadores que cumplen ciertas propiedades, intervalos de confianza, etc. Así, dividiremos al conjunto de datos conforme se describe en la Figura 12.6.

Para proporcionar una comprensión precisa de la generalización de nuestro modelo óptimo final, se suele dividir nuestros datos sólo en dos conjuntos de datos: de entrenamiento y de prueba.

- Conjunto de entrenamiento: estos datos se utilizan para desarrollar conjuntos de características, entrenar nuestros algoritmos, ajustar hiperparámetros, comparar modelos y todas las demás actividades necesarias para elegir un modelo final (por ejemplo, el modelo que queremos poner en producción).
- Conjunto de pruebas: una vez elegido un modelo final, estos datos se utilizan para estimar una evaluación insesgada del rendimiento del modelo, a lo que nos referimos como error de generalización.

Acá unos recursos:

<https://mlu-explain.github.io/train-test-validation/>

12.3.2. Método de regresiones restringidas (Shrinkage methods).

Este tipo de métodos permiten:

1. Restringir los posibles valores de las estimaciones del parámetro β a un subconjunto, y
2. Seleccionar variables o regresores dentro de un conjunto de candidatos.

Véamos dos casos particulares: i) una regresión de cresta restringida (ridge regression) y ii) la regresión Lasso (least absolute shrinkage and selection operator).

Regresión Ridge.

La regresión de ridge restringe los coeficientes de la regresión mediante la imposición de una penalización en su magnitud. Los coeficientes estimados por este método resultan de resolver el problema de minimizar los residuales al cuadrado sujeto a que los coeficientes sumen un valor dado. Es decir:

$$\hat{\beta}^{Ridge} = \min_{\beta} \left[\sum_{i=1}^N (y_i - \mathbf{X}_i' \beta)^2 + \lambda \sum_{k=2}^K \beta_k^2 \right] \quad (12.10)$$

Donde $\lambda \geq 0$ y suponemos que β_1 es el término constante de la regresión, el cual no se optimiza.

La idea de la penalización de los parámetros se deriva de que la forma equivalente del problema en la ecuación (12.10) es:

$$\hat{\beta}^{Ridge} = \min_{\beta} \left[\sum_{i=1}^n (y_i - \mathbf{X}_i \beta)^2 \right]$$

Sujeto a:

$$\sum_{k=2}^K \beta_k^2 \leq t$$

Note que la penalización no aplica al término constante, ¿por qué?, para garantizar que la estimación del hiperplano asociado pasa por la media de Y y no por el cero (0).

¿Qué implicaciones tiene para la estimación? Es posible estimar el modelo de la ecuación (12.10) pero ajustando las variables incluidas con la resta de la media. Esto, ya que el término constante se puede estimar considerando que este toma el valor de la media de Y dado por:

$$\bar{Y} = \frac{\sum_{i=1}^n y_i}{n}$$

Para los restantes coeficientes los determinaremos mediante un procedimiento dado por:

$$\min_{\beta_R, \lambda} [(\mathbf{Y} - \mathbf{X}\beta_R)'(\mathbf{Y} - \mathbf{X}\beta_R) + \lambda \beta_R' \beta_R] \quad (12.11)$$

Donde β_R contiene sólo las pendientes. Para determinar un valor estimado debemos resolver el problema descrito en la ecuación (12.11):

$$\begin{aligned}\frac{\partial}{\partial \beta_R} S(\beta_R) &= \frac{\partial}{\partial \beta_R} ((\mathbf{Y} - \mathbf{X}\beta_R)'(\mathbf{Y} - \mathbf{X}\beta_R) + \lambda \beta_R' \beta_R) \\ &= \frac{\partial}{\partial \beta_R} (\mathbf{Y}'\mathbf{Y} - 2\mathbf{Y}'\mathbf{X}\beta_R + \beta_R' \mathbf{X}'\mathbf{X}\beta_R + \lambda \beta_R' \beta_R) \\ &= -2\mathbf{X}'\mathbf{Y} + 2\mathbf{X}'\mathbf{X}\beta_R + 2\lambda \beta_R\end{aligned}$$

Determinando el mínimo:

$$\begin{aligned}-2\mathbf{X}'\mathbf{Y} + 2\mathbf{X}'\mathbf{X}\hat{\beta}_R^{Ridge} + 2\lambda \hat{\beta}_R^{Ridge} &= 0 \\ -\mathbf{X}'\mathbf{Y} + (\mathbf{X}'\mathbf{X} + \lambda \mathbb{I}_{K-1})\hat{\beta}_R^{Ridge} &= 0\end{aligned}$$

Por lo tanto, el estimador estará dado por:

$$\hat{\beta}_R^{Ridge} = (\mathbf{X}'\mathbf{X} + \lambda \mathbb{I}_{K-1})^{-1} \mathbf{X}'\mathbf{Y} \quad (12.12)$$

Así, el problema de la estimación es que tiene 1 grado de libertad, λ , que es un valor de penalización y que resultta arbitrario—determinado de forma iterativa hasta alcanzar uno que minimice la ecuación (12.10).

Regresión Lasso (Least Absolute Shrinkage and Selection Operator).

La regresión Lasso se define por la solución al problema:

$$\hat{\beta}^{Lasso} = \min_{\beta} \left[\sum_{i=1}^n (y_i - \mathbf{X}_i\beta)^2 \right] \quad (12.13)$$

Sujeto a:

$$\sum_{k=2}^K |\beta_k| \leq t$$

Donde $\lambda \geq 0$ y suponemos que β_1 es el término constante de la regresión. El término constante se estima considerando que este toma el valor de la media de Y dado por:

$$\bar{Y} = \frac{\sum_{i=1}^n y_i}{n}$$

La idea de la penalización de los parámetros se deriva de la forma equivalente del problema en la ecuación (12.13) es:

$$\hat{\beta}^{Lasso} = \min_{\beta} \left[\sum_{i=1}^n (y_i - \mathbf{X}_i \beta)^2 + \lambda \sum_{k=2}^K |\beta_k| \right] \quad (12.14)$$

12.4. Aplicación de modelos clasificación mediante clustering.

En esta sección abordaremos el caso del clústerin, el cual es un problema que podemos enunciar de esta forma. Supongamos que tenemos un conjunto de entrenamiento $\{x_1, x_2, \dots, x_n\}$ de características respecto del cual queremos construir un grupo o grupos de datos cohesivos denominados clústeres. En este caso, para cada una de las x_i características no tenemos una etiqueta y_i . Esta situación de inexistencia de etiquetas es lo que le da el nombre de aprendizaje no supervisado.

Ahora, analicemos diferentes técnicas de aprendizaje no supervisado.

12.4.1. Análisis de Componentes Principales

El análisis de componentes principales (PCA, por sus siglas en inglés) es una herramienta importante y útil de aprendizaje no supervisado para la reducción de dimensiones. También lo podemos ver como un método para identificar un subespacio en el cual los datos se pueden representar, puesto que hay información redundante. El PCA se puede utilizar como una herramienta para el preprocesamiento de datos antes de que se apliquen técnicas de aprendizaje supervisado. El PCA produce una representación de baja dimensión de un conjunto de datos. Encuentra secuencialmente un conjunto de combinaciones lineales de los predictores que tienen una varianza máxima y son ortogonales entre sí.

El análisis de componentes principales asume que las variables individuales pueden ser descritas por una combinación lineal de factores; es decir, esos factores representan completamente la varianza de las variables. El primer componente principal de un conjunto de características denominadas como $X_1, X_2, \dots, X_K$ es la combinación lineal de las características o predictores X :

$$Z_1 = \phi_{11}X_1 + \phi_{21}X_2 + \dots + \phi_{K1}X_K \quad (12.15)$$

que tiene la mayor varianza, donde ϕ_{j1} satisface:

$$\sum_{j=1}^K \phi_{j1}^2 = 1 \quad (12.16)$$

Los coeficientes ϕ_{ji} se llaman cargas y se pueden encontrar utilizando una descomposición en valores singulares de la matriz X de dimensión $n \times K$. El segundo componente principal es la combinación lineal de $X_1, \dots, X_K$ que tiene máxima varianza entre todas las combinaciones lineales que son ortogonales con Z_1 . Así, el segundo componente sería:

$$Z_2 = \phi_{12}X_1 + \phi_{22}X_2 + \dots + \phi_{K2}X_K \quad (12.17)$$

donde el coeficiente ϕ_2 es el vector de carga del segundo componente principal, satisfaciendo $\phi_1 \cdot \phi_2 = 0$, es decir, $\phi_1 \perp \phi_2$. Este proceso continúa hasta que se encuentren todos los componentes principales $K^* = \min(n - 1, K)$. Aquí, los productos internos $\phi_i \cdot \phi_j = 0$ y $Z_i \cdot Z_j = 0$ para todos $i \neq j$.

El significado de las cargas se puede interpretar de la siguiente manera:

1. El vector de carga ϕ_1 con elementos $\phi_{11}, \phi_{21}, \dots, \phi_{K1}$ define una dirección en el espacio de características a lo largo de la cual los datos varían más.
2. Las direcciones de los componentes principales $\phi_1, \phi_2, \dots, \phi_K$ son la secuencia ordenada de vectores singulares derechos de la matriz X , y las varianzas de los componentes son $1/n$ veces los cuadrados de los valores singulares.
3. El vector de carga ϕ_1 define la línea en el espacio K -dimensional que está más cerca de las n observaciones en términos de distancia euclidiana cuadrada media.

Asumiendo que las variables han sido centradas para tener media cero, la varianza total observada es:

$$\sum_{j=1}^K \text{Var}(X_j) = \sum_{j=1}^K \frac{1}{n} \sum_{i=1}^n x_{ij}^2. \quad (12.18)$$

y la varianza explicada por el m -ésimo componente principal es:

$$\text{Var}(Z_m) = \frac{1}{n} \sum_{i=1}^n z_{im}^2. \quad (12.19)$$

Por lo tanto, la varianza proporcional explicada por el m -ésimo componente principal se da por la cantidad positiva entre 0 y 1.

$$\frac{\sum_{i=1}^n z_{im}^2}{\sum_{j=1}^K \sum_{i=1}^n x_{ij}^2}. \quad (12.20)$$

Una de las desventajas de usar PCA es que las características transformadas Z no son tan intuitivas como las medidas originales X ; reduciendo las posibilidades de interpretación.

12.4.2. Análisis Factorial

El análisis factorial o análisis de factores usa la correlación entre los artículos o elementos individuales para reducirlos a un número pequeño de dimensiones independientes o factores, sin suponer la unidimensionalidad de la escala. La matriz de correlación de los elementos indica cuales exhiben patrones similares de respuesta. Esos elementos son agrupados en factores.

En contraste con el análisis de componentes principales, el análisis de factores o factorial asume que la varianza de la variable puede ser separada en 2 partes. La primera está determinada por la varianza conjunta de todas las variables incluidas en el análisis. La otra parte está determinada por la varianza específica de la variable en cuestion. Bajo el enfoque de análisis de factores, los factores explican solo el primer componente de la varianza.

Después de checar la

12.4.3. Clúster

El término clúster refiere a un grupo de individuos u objetos que convergen alrededor de cierto punto y son relativamente cercanos en su posición. En astronomía, existen clústeres de estrellas; en química hay clústeres de átomos. En el campo de la economía en ocasiones se refiere a técnicas que consideran grupos dentro del total de la población. Por ejemplo, las empresas que buscan analizar un grupo de potenciales clientes podrían buscar dividir el total de consumidores en segmentos o clústeres.

El proposito del análisis de clúster es identificar clústeres homogéneos dentro de un conjunto de individuos u objetos heterogéneos. No obstante, hay un mal entendido muy común en el análisis de clúster. Este es la creencia de que existe sólo un tipo de técnica de análisis de clúster. En la realidad, existen muchas técnicas de clustering. Esto se deriva de que existen una amplia variedad de métricas de distancia y algoritmos de agrupamiento que pueden ser usados.

En general, se pueden identificar 2 tipos generales de métodos de clúster:

1. Análisis de agrupamiento del tipo k -Means
2. Análisis de clúster jerárquico

El agrupamiento o clustering se refiere a un conjunto muy amplio de técnicas para encontrar subgrupos, o clústeres, en un conjunto de datos. El objetivo del agrupamiento es encontrar una partición de los datos en grupos distintos de modo que las observaciones dentro de cada grupo sean bastante similares entre sí en algún sentido. Tal sentido de similitud a menudo es una consideración específica del dominio que debe realizarse con base en el conocimiento de los datos que se estudian. La similitud debe estar relacionada con algún resultado vago o posibles múltiples resultados/propósitos.

En las bibliotecas, organizamos los libros por diferentes categorías y subcategorías, mientras que tales selecciones de categorías y subcategorías se basan en las necesidades de los clientes que a menudo no están claramente definidas. En casa, organizamos nuestras cosas en ropa, zapatos, utensilios de cocina y otros para conveniencia cuando los usamos. Por lo tanto, el agrupamiento debe tener algunos propósitos que son difíciles de caracterizar usando una medida de resultado simple. Por esta razón, el aprendizaje supervisado no es aplicable al problema.

Un buen ejemplo de agrupamiento en el comercio sería el agrupamiento para la segmentación del mercado. Supongamos que tenemos acceso a grandes datos (por ejemplo, ingreso medio del hogar, ocupación, distancia desde el área urbana más cercana) de un gran número de personas que pueden o no ser nuestros clientes existentes. Nuestro objetivo es identificar subgrupos de personas que podrían ser más receptivas a una forma particular de publicidad, o agruparlos (en términos de datos) de acuerdo con la probabilidad de comprar un producto en particular.

A diferencia del PCA, que busca una representación de baja dimensión




Figura 12.7: US Arrest Hierarchical Clustering, retomado de Chang (2020, p 216) [Cha20]

de las observaciones que explica una buena fracción de la varianza, el agrupamiento busca subgrupos homogéneos entre las observaciones.

Hay dos métodos de agrupamiento comúnmente utilizados: el agrupamiento K-medias y el agrupamiento jerárquico. En el agrupamiento K-medias, buscamos particionar las observaciones en un número preespecificado de clústeres, mientras que en el agrupamiento jerárquico no sabemos de antemano cuántos clústeres queremos. En cambio, el agrupamiento jerárquico terminará con una representación visual en forma de árbol de las observaciones, llamada dendrograma, que nos permite ver de una vez el agrupamiento obtenido para cada número posible de clústeres (Figura 12.7). d

K-Means Clustering

Algoritmo K-Means

El clústering K-Means es un método de análisis que agrupa observaciones en clústeres. Las principales diferencias entre k-means y el clústering

jerárquico es que los usuarios de k-means deciden el número de clústeres desde el inicio. Es decir, desde un inicio, determinamos una partición inicial que asumimos.

El algoritmo de k-means tiene los siguientes requerimientos:

1. Conocimiento sobre el mejor número de clústeres.
2. Las variables deberían estar transformadas como con la transformación z .

El algoritmo K-medias es uno de los métodos de agrupamiento más simples y populares. Sea $X = \{x_i; i = 1, \dots, n\}$ y el clúster $C = \{c_j; j = 1, \dots, k\}$. Para un k dado, el objetivo del agrupamiento es encontrar C , tal que

$$\min_{c_j; j} \sum_{i=1}^n ||x_i - c_j|| \quad (12.21)$$

El algoritmo K-medias se describe de la siguiente manera:

1. Escoger aleatoriamente k puntos de datos de X como el clúster inicial C .
2. Reasignar todos $x_i \in X$ al promedio de clúster más cercano c_j .
3. Actualizar todos $c_j \in C$ con la media de sus clústeres correspondientes.
4. Repetir los pasos 2 y 3 hasta que las asignaciones de clúster no cambien.

La convergencia del algoritmo está garantizada en un número finito de iteraciones. Sin embargo, cuando la distancia $\sum_{i=1}^n ||x_i - c_j||$ es una función no convexa, la convergencia puede llevar a un óptimo local. El algoritmo también es sensible a los valores atípicos y podría llevar a algunos clústeres vacíos. Aquí hemos asumido que k es fijo. El problema de agrupamiento con k variable es muy desafiante desde el punto de vista del cálculo.

El agrupamiento K-medias (k-medoids) ajusta exactamente k clústeres como se especifica y la asignación final de clústeres depende de los centros de clústeres iniciales elegidos y del clúster final asignado. La Figura 12.8 ilustra este proceso o algoritmo de determinación de centriodes.




Figura 12.8: K-Means algorithm, retomado de Ng (2023, p 146) [NG]

Clustering Jerárquico

El agrupamiento jerárquico busca construir una jerarquía de clústeres. Las estrategias para el agrupamiento jerárquico pueden ser aglomerativas o divisivas. Una estrategia aglomerativa es un enfoque de abajo hacia arriba, es decir, cada observación comienza en su propio clúster, y pares de clústeres se fusionan a medida que se asciende en la jerarquía. Una estrategia divisiva es un enfoque de arriba hacia abajo, es decir, todas las observaciones comienzan en un clúster, y se realizan divisiones de forma recursiva a medida que se desciende en la jerarquía. Por su parte, el agrupamiento divisivo con una búsqueda exhaustiva tiene una complejidad de $O(2^n)$, pero es común utilizar heurísticas más rápidas para elegir las divisiones, como K-Medias. Los resultados del agrupamiento jerárquico generalmente se presentan en un dendrograma.

Para decidir qué clústeres se deben combinar (estrategia aglomerativa) o dónde se debe dividir un clúster (estrategia divisiva), se requiere una medida de disimilitud o similitud entre conjuntos de observaciones, como distancia o enlace entre pares de observaciones. La distancia puede ser Euclidiana, Euclidiana al cuadrado, Manhattan, máxima, Mahalanobis, entre otras. El criterio de enlace puede ser agrupamiento de enlace completo, $\max\{d(a, b); a \in$




Figura 12.9: Agglomerative Clustering Algorithm and Dendrogram, retomado de Chang (2020, p 219) [Cha20]

$A, b \in B\}$, agrupamiento de enlace simple, $\min\{d(a, b); a \in A, b \in B\}$, o agrupamiento de enlace promedio, $\frac{1}{|A| \cdot |B|} \sum_{a \in A} \sum_{b \in B} d(a, b)$. El enlace simple sufre de encadenamiento porque para fusionar dos grupos, solo se necesita que un par de puntos esté cerca, independientemente de todos los demás. Por lo tanto, los clústeres pueden estar demasiado dispersos. En contraste, el enlace completo evita el encadenamiento, pero sufre de hacinamiento. El enlace promedio intenta, utilizando la disimilitud promedio por pares, establecer un equilibrio.

Una lección importante que la experiencia ha mostrado es que las medidas de distancia en el análisis de clúster deben basarse en unidades comparables de medida. Si las características consideradas en el análisis de clúster están en unidades distintas, las variables podrían pasarse por una de las posibles técnicas de unificación de medida. Usualmente, esto se logra mediante la aplicación de la transformación z de todas las variables con el objetivo de estandarizarlas.

Existen 5 métodos de vinculación para clústering jerárquico aglomerativo:

1. Método simple de vinculación que usa la cercanía de 2 observaciones de 2 clústeres como la base de la medida de distancia.
2. Método de vinculación completa que, en contraste, usa las 2 observaciones de 2 clústeres más lejanos como la base de la distancia.

3. Método de vinculación del centroide que calcula el punto medio para cada clúster de sus observaciones.
4. Método de vinculación promedio que determina la media de la distancia entre las observaciones de 3 clústeres.
5. Método de Ward (propuesto por Joe H. Ward en 1963) que vincula clústeres que optimizan un criterio específico: la suma de los errores al cuadrado. Este criterio minimiza la varianza total dentro del clúster. Al igual que otros métodos jerárquicos, este inicia mirando cada observación como si fuera en sí mismo un clúster. En este caso, la suma de errores al cuadrado asume el valor de cero, como la media de cada observación. Para calcular la suma de errores para todas las posibles combinaciones de siguientes vínculos se elige los clústeres que tienden a incrementar poco la suma de errores.

12.4.4. Agrupamiento de datos de series temporales

Las observaciones reales de series temporales se pueden agrupar, así como las características extraídas de las mismas, en clusters. Las características se extraen en los dominios de tiempo, frecuencia y ondículas.

La agrupación mediante características del dominio temporal son autocorrelaciones, autocorrelaciones parciales y correlaciones cruzadas. Mientras que, en el dominio de la frecuencia, se extraen características como el periodograma y las ordenadas espectrales y cepstrales. Por último, las características extraídas en el dominio de wavelets son las transformadas discretas de ondículas, las varianzas de ondículas y las correlaciones de ondículas.

Medidas de Distancia

En muchos casos, se utiliza el análisis de clustering tradicional, es decir, el clustering jerárquico, para agrupar series temporales. En este caso, primero se define una medida de distancia adecuada que hereda las características dinámicas de la serie temporal para comparar series temporales, y luego se aplica un análisis de clustering jerárquico estándar utilizando la distancia definida.

Sea $\mathbf{X} = \{x_{ij} : i = 1, \dots, I; j = 1, \dots, J\} = \{\mathbf{x}_i = (x_{i1}, \dots, x_{ij}, \dots, x_{iJ})' : i = 1, \dots, I\}$ la matriz de datos donde x_{ij} representa la j -ésima variable observada en el i -ésimo elemento y $\mathbf{x}_i$ representa el vector de la i -ésima observación.

La clase más común de medida de distancia utilizada en el análisis de clusters es la clase de distancia de Minkowski.

$${}_r d_{il} = \left[\sum_{j=1}^J |x_{ij} - x_{lj}|^r \right]^{\frac{1}{r}}, \quad r \geq 1. \quad (12.22)$$

Para $r = 1$, tenemos la distancia Manhattan:

$${}_1 d_{il} = \sum_{j=1}^J |x_{ij} - x_{lj}| \quad (12.23)$$

y para $r = 2$, tenemos la distancia Euclidiana:

$${}_2 d_{il} = \left[\sum_{j=1}^J (x_{ij} - x_{lj})^2 \right]^{\frac{1}{2}} \quad (12.24)$$

Las versiones ponderadas de las anteriores distancias de clase Minkowski son:

$${}_r \tilde{d}_{il} = \left[\sum_{j=1}^J w_j^r |x_{ij} - x_{lj}|^r \right]^{\frac{1}{r}}, \quad r \geq 1 \quad (12.25)$$

y entonces,

$$\begin{aligned} {}_1 \tilde{d}_{il} &= \sum_{j=1}^J w_j^1 |x_{ij} - x_{lj}| \quad (r = 1) \quad (\text{distancia Manhattan ponderada}) \\ {}_2 \tilde{d}_{il} &= \left[\sum_{j=1}^J w_j^2 (x_{ij} - x_{lj})^2 \right]^{\frac{1}{2}} \quad (r = 2) \quad (\text{distancia Euclidiana ponderada}) \end{aligned} \quad (12.26)$$

dónde w_j ($j = 1, \dots, J$) representa una ponderación adecuada para la j -ésima variable.

Para utilizar las medidas de distancia en clustering jerárquico es útil obtener las distancias para cada par de unidades en forma de una matriz cuadrada. La matriz de distancia Minkowski puede ser representada de la siguiente manera:

$${}_r\mathbf{D} = \left\{ {}_r d_{il} = \left[\sum_{j=1}^J |x_{ij} - x_{lj}|^r \right]^{\frac{1}{r}} : i, l = 1, \dots, I \right\}, \quad r \geq 1 \quad (12.27)$$

Clustering Jerárquico Aglomerativo

Los métodos aglomerativos producen una serie de particiones de los datos: el primero consiste en un cluster I de un solo miembro; el último consiste en un solo cluster que contiene todas las unidades I . El clustering aglomerativo comienza con I clusters, donde cada uno incluye exactamente un punto de los datos. Posteriormente, sucede una serie de operaciones de unión que eventualmente fuerza a todos los objetos en un mismo grupo. El clustering aglomerativo general puede ser resumido por el siguiente procedimiento:

1. Empieza con I clusters únicos (singleton). Calcula la matriz de distancias para los I clusters;
2. En la matriz de distancia, busca la mínima distancia $d(C_p, C_q) = \min_{\substack{1 \leq p, q \leq I \\ p \neq q}} d(C_p, C_q)$, donde $d(\cdot, \cdot)$ es la función de distancia, y por último combina los cluster C_c y $C_{c'}$ para formar el nuevo cluster $C_{cc'}$;
3. Actualiza la matriz de distancia calculando las distancias entre el cluster $C_{cc'}$ y los demás clusters;
4. Repite los pasos 2 y 3 hasta que solo quede un cluster.

La unión de un par de clusters, o la formación de un nuevo cluster depende de como esté definida la función de distancia entre dos clusters. A continuación se presentan de forma breve algunas formas de definir la función de distancia.

- *Método de enlace simple*: La distancia entre un par de clusters está determinada por las dos unidades más cercanas a los diferentes clusters.

El clustering por enlace simple tiende a generar clusters alargados, lo que causa el efecto de encadenamiento. Como resultado, dos clusters con propiedades muy diferentes pueden estar conectados debido a la existencia de perturbaciones. Sin embargo, si los cluster están muy separados, el método de enlace simple funciona bien.

- *Método de enlace completo*: A diferencia del enlace simple, el método de enlace completo utiliza la distancia más lejana de un par de objetos para definir la distancia entre grupos.
- *Método de enlace de promedios grupales*: La distancia entre dos clusters se define como el promedio de las distancias entre todos los pares de puntos de datos, cada uno de los cuales proviene de un cluster diferente.
- *Método de enlace de promedios ponderados*: Similar a los promedios grupales, el enlace promedio también se utiliza para calcular la distancia entre dos clusters. La diferencia radica en que las distancias entre el cluster recién formado y el resto se ponderan en función del número de puntos de datos en cada cluster.
- *Método de enlace de centroides*: Dos clusters se unen según la distancia de sus centroides (media).
- *Método de Ward o de la mínima varianza*: El objetivo del método de Ward es minimizar el aumento de la suma intraclase de los errores cuadrados.

Clustering No Jerárquico

A diferencia del clustering jerárquico, que genera un nivel sucesivo de clusters mediante fusiones o divisiones iterativas, el clustering no jerárquico o por particiones asigna un conjunto de puntos de datos en c clusters sin ninguna estructura jerárquica. Este proceso suele acompañar la optimización de una función criterio, normalmente la minimización de una función objetivo que representa la variabilidad interna de los clusters.

Método de clustering por c-Medias

También conocido como k-Medias, el método c-Medias busca una partición óptima de los datos minimizando el criterio de suma de errores al cuadrado con un procedimiento de optimización iterativo, que pertenece a la

categoría de algoritmos hill-climbing. El procedimiento básico de clustering de c-Medias se resume de la siguiente manera:

1. Inicie con c particiones aleatorias o basadas en algún conocimiento previo. Calcule los prototipos de clusters (centroides o medias), es decir, calcule la media de cada cluster considerando solo las observaciones que pertenecen a cada cluster.
2. Asigne cada unidad del conjunto de datos al grupo más cercano utilizando una medida de distancia adecuada entre cada par de unidades y centroides.
3. Recalcular los prototipos de clusters (centroides o medias) en función de la partición actual.
4. Repita los pasos 2 y 3 hasta que no haya cambios para cada cluster.

El método de c-Medias formalizado matemáticamente es de la siguiente forma:

$$\text{mín} : \sum_{i=1}^I \sum_{c=1}^C u_{ic} d_{ic}^2 = \sum_{i=1}^I \sum_{c=1}^C u_{ic} \|\mathbf{x}_i - \mathbf{h}_c\|^2, \quad (12.28)$$

$$\sum_{c=1}^C u_{ic} = 1, \quad u_{ic} \geq 0, \quad u_{ic} \in \{0, 1\} \quad (12.29)$$

donde u_{ic} indica el grado de pertenencia de la unidad i -ésima al clúster c -ésimo; $u_{ic} \in \{0, 1\}$, es decir, $u_{ic} = 1$ cuando la unidad i -ésima pertenece al clúster c -ésimo; $u_{ic} = 0$ en caso contrario; $d_{ic}^2 = \|\mathbf{x}_i - \mathbf{h}_c\|^2$ indica la distancia euclidiana al cuadrado entre el objeto i -ésimo y el centroide del clúster c -ésimo.

Método de clustering por c-Medoides.

Las unidades se clasifican en clusters representados por uno de los puntos de datos del cluster. Estos puntos de datos son los prototipos, los llamados medoides. Cada medoide sintetiza la información del cluster y representa las características prototípicas de los clusters, y luego sintetiza las características de las unidades pertenecientes a cada cluster. Siguiendo el método de agrupamiento de c-medoides, minimizamos la función objetivo representada por la

suma de la disimilitud de las unidades con sus unidades representativas más cercanas. El método de clustering por c-medoides primero calcula un conjunto de unidades representativas, los medoides. Tras encontrar el conjunto de medoides, cada unidad del conjunto de datos se asigna a las unidades medoides más cercanas. El algoritmo sugerido por Kaufman y Rousseeuw (1990) para el método de clustering por c-medoides se desarrolla en dos fases:

Fase 1 (*CONSTRUCCIÓN*): Esta fase selecciona secuencialmente c unidades “centralmente localizadas” para ser utilizadas como medoides iniciales.

Fase 2 (*INTERCAMBIO*): Si la función objetivo puede reducirse intercambiando una unidad seleccionada con una no seleccionada, entonces se realiza el intercambio. Esto se repite hasta que la función objetivo ya no pueda ser disminuida. Luego, considerando un conjunto de I unidades representado por $\mathbf{X}$ (conjunto de las observaciones) y un subconjunto de $\mathbf{X}$ con C unidades representado por $\tilde{\mathbf{X}}$ (conjunto de los medoides), donde $C \ll I$, podemos formalizar el modelo de la siguiente manera:

$$\text{mín} : \sum_{i=1}^I \sum_{c=1}^C u_{ic} \tilde{d}_{ic}^2 = \sum_{i=1}^I \sum_{c=1}^C u_{ic} \|\mathbf{x}_i - \tilde{\mathbf{x}}_c\|^2, \quad (12.30)$$

$$\sum_{c=1}^C u_{ic} = 1, \quad u_{ic} \geq 0, \quad u_{ic} \in \{0, 1\} \quad (12.31)$$

donde u_{ic} indica el grado de pertenencia de la unidad i -ésima al cluster c -ésimo; $u_{ic} \in \{0, 1\}$, es decir, $u_{ic} = 1$ cuando la unidad i -ésima pertenece al cluster c -ésimo; $u_{ic} = 0$ en caso contrario; $\tilde{d}_{ic}^2 = \|\mathbf{x}_i - \tilde{\mathbf{x}}_c\|^2$ indica la distancia euclidiana al cuadrado entre el objeto i -ésimo y el medoide del clúster c -ésimo.

Algunos criterios útiles de validez para determinar el número de clusters son los siguientes:

Criterio de Calinski y Harabasz

Calinski y Harabasz (1974) sugieren tomar el valor de g , el número de clústeres, el cual corresponde al valor máximo de CH_C :

$$CH_C = \frac{\text{trace}(\mathbf{B})}{(C-1)} : \frac{\text{trace}(\mathbf{W})}{(I-C)}.$$

donde $\mathbf{B}$ es la matriz de dispersión entre grupos y $\mathbf{W}$ es la matriz de dispersión dentro de los grupos. La evaluación de este criterio en un número dado de grupos, C , requiere conocer la pertenencia a los grupos para determinar las matrices $\mathbf{B}$ y $\mathbf{W}$. En general, el número de grupos elegido depende del método de clúster utilizado.

Criterio de la silueta

Este criterio fue propuesto por Rousseeuw (1987). Considere una unidad $i \in (1, \dots, I)$ perteneciente al cluster $p \in (1, \dots, C)$. Por ejemplo, mediante un algoritmo de clustering *c-Medias*, esto significa que la unidad i -ésima está más cerca del centroide del cluster p -ésimo que de cualquier otro centroide.

Sea la distancia promedio (euclidiana al cuadrado) de la unidad i -ésima a todas las demás unidades que pertenecen al clúster p denotada por a_{ip} . Asimismo, sea la distancia promedio de esta unidad a todas las unidades que pertenecen a otro clúster q , $q \neq p$, llamada d_{iq} .

Finalmente, sea b_{ip} el mínimo d_{iq} calculado sobre $q = 1, \dots, C$, $q \neq p$, lo cual representa la disimilitud de la unidad i -ésima con respecto a su cluster vecino más cercano.

Entonces, la silueta del objeto i -ésimo se define de la siguiente manera:

$$S_i = \frac{b_{ip} - a_{ip}}{\max\{a_{ip}, b_{ip}\}} \quad (12.32)$$

donde el denominador es un término de normalización. Mientras mayor sea el valor de S_i , mejor es la asignación de la unidad i -ésima al cluster c -ésimo. La silueta, definida como el promedio de S_i para $i = 1, \dots, I$, es:

$$SIL = \frac{1}{I} \sum_{i=1}^I S_i \quad (12.33)$$

La mejor partición se logra cuando la silueta se maximiza, lo cual implica minimizar la distancia intra-cluster (a_{ip}) mientras se maximiza la distancia inter-cluster (b_{ip}).

12.5. Aplicación de modelos de regresión de respuesta binaria

12.5.1. Modelos de respuesta binaria

Planteamiento general. En el caso de modelos de respuesta binaria, asumiremos que y_i es una variable aleatoria que toma sólo valores de 0 y 1. Los ejemplos pueden ser amplios. Decisiones sobre consumir o no, pagar o no, ir a una escuela determinada A o B, viajar por tierra o aire. En general, diremos que 1 es éxito y 0 es fracaso.

Como en el caso de modelos lineales, diremos que y_i es la variable dependiente y $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{iK})$ un vector de variables independientes o explicativas. Así, en los modelos no lineales de respuesta binaria estaremos interesados en las probabilidades:

$$P(y_i = 1|\mathbf{x}_i) = P(y_i = 1|x_{i1}, x_{i2}, \dots, x_{iK})$$

Notemos que, en este caso, hemos planteado una nueva hipótesis de cómo se puede modelar el comportamiento de y_i . Es decir, estamos asumiendo que la respuesta 0 o 1 se puede modelar como el resultado de un modelo probabilístico.

Dicho lo anterior, y de forma similar al de la regresión lineal, podemos establecer el efecto marginal para el caso de una variable independiente x_j continua:

$$EMg_j = \frac{\partial}{\partial x_j} P(y_i = 1|x_{i1}, x_{i2}, \dots, x_{iK})$$

Cuando la variable independiente es una variable dummy:

$$\begin{aligned} EMg_j &= P(y_i = 1|x_{i1}, x_{i2}, \dots, x_{ij} = 1, \dots, x_{iK}) - \\ &\quad P(y_i = 1|x_{i1}, x_{i2}, \dots, x_{ij} = 0, \dots, x_{iK}) \end{aligned}$$

Este tipo de modelos se basan en el modelo básico de Bernoulli, cuya función de densidad de probabilidad condicional y podemos plantearlo como:

$$\begin{aligned} P(y_i = 1|\mathbf{x}_i) &= p(x) \\ P(y_i = 0|\mathbf{x}_i) &= 1 - p(x) \\ Var(y_i|\mathbf{x}_i) &= p(x) \cdot (1 - p(x)) \end{aligned}$$

Algunos planteamientos adicionales

Cuando la variable dependiente es binaria (0 y 1) no se puede implementar una ecuación lineal de la forma tradicional, ya que no es posible determinar una ecuación:

$$y_i = \mathbf{x}_i\boldsymbol{\beta} + \varepsilon_i$$

Por otro lado, tambien enfrentaremos el mismo problema con modelos de probabilidad lineal:

$$P(y_i = 1|\mathbf{x}_i) = \mathbf{x}_i\boldsymbol{\beta} + \varepsilon_i$$

Y:

$$P(y_i = 0|\mathbf{x}_i) = \mathbf{x}_i\boldsymbol{\beta} + \varepsilon_i$$

En ambos casos es difícil lograr la estimación.

Modelos Logit y Probit

Este tipo de modelos suponen que existe una variable latente que se puede expresar como una ecuación lineal dada por:

$$y_i^* = \mathbf{x}_i\boldsymbol{\beta} + \varepsilon_i$$

Donde ε_i es una variable aleatoria con función de densidad con media cero y distribución simétrica alrededor de cero. Dado lo anterior, para nosotros sólo es visible que:

$$y_i = \begin{cases} 1 & \text{si } y_i^* > 0 \\ 0 & \text{si } y_i^* < 0 \end{cases}$$

De esta forma, tenemos una estructura de la probabilidad dada por:

$$\begin{aligned} P(y_i = 1|\mathbf{x}_i) &= P(\mathbf{x}_i\boldsymbol{\beta} + \varepsilon_i > 0) = P(\varepsilon_i > -\mathbf{x}_i\boldsymbol{\beta}) = G(\mathbf{x}_i\boldsymbol{\beta}) \\ P(y_i = 0|\mathbf{x}_i) &= P(\mathbf{x}_i\boldsymbol{\beta} + \varepsilon_i < 0) = P(\varepsilon_i < -\mathbf{x}_i\boldsymbol{\beta}) = 1 - G(\mathbf{x}_i\boldsymbol{\beta}) \end{aligned}$$

Donde $\mathbf{x}_i$ es un vector de dimensión $K \times 1$ que contiene al menos el término constante y $\boldsymbol{\beta}$ es un vector de parámetros a estimar, de forma que asumiremos:

$$\mathbf{x}_i\boldsymbol{\beta} = \beta_1 + x_{i2}\beta_2 + \dots + x_{iK}\beta_K$$

Asumiremos que $G(\cdot)$ es una función de densidad acumulada de forma que:

$$0 < G(\mathbf{x}_i\boldsymbol{\beta}) < 1, \forall \mathbf{x}_i\boldsymbol{\beta} \in \mathbb{R}$$

En este caso, utilizaremos dos modelos que dependen de la forma funcional de $G(\cdot)$ que está determinada por la distribución de ε_i . De esta forma, tendremos dos modelos: Probit y Logit.

1. **Modelo Probit**, cuando la función de distribución de probabilidad es una normal:

$$G(\mathbf{x}_i\boldsymbol{\beta}) = \Phi(\mathbf{x}_i\boldsymbol{\beta}) = \int_{-\infty}^{\mathbf{x}_i\boldsymbol{\beta}} \phi(\nu) d\nu$$

Donde $\phi(\cdot)$ es la densidad de probabilidad normal estándar:

$$\phi(\mathbf{x}_i\boldsymbol{\beta}) = \frac{1}{\sqrt{2\pi}} e^{-1/2\phi(\mathbf{x}_i\boldsymbol{\beta})}$$

2. **Modelo Logit**, cuando la función de distribución tiene forma analítica cerrada del tipo:

$$G(\mathbf{x}_i\boldsymbol{\beta}) = \Lambda(\mathbf{x}_i\boldsymbol{\beta}) = \frac{e^{\mathbf{x}_i\boldsymbol{\beta}}}{1 + e^{\mathbf{x}_i\boldsymbol{\beta}}} = \frac{1}{1 + e^{-\mathbf{x}_i\boldsymbol{\beta}}}$$

Donde $\lambda(\cdot)$ es la función de densidad acumulada logística. Esta función tiene más aplicaciones relacionadas con la función sigmoide que usaremos en redes neuronales.

Sin importar el modelo que estemos ocupando, la forma de interpretar el modelo es mediante el efecto marginal, cuando x_j sea una variable continua:

$$EMg_j = \frac{\partial}{\partial x_j} P(y = 1|\mathbf{x}_i) = \frac{\partial}{\partial x_j} G(\mathbf{x}_i\boldsymbol{\beta}) = g(\mathbf{x}_i\boldsymbol{\beta})\beta_j$$

Por su parte, cuando x_j sea una variable dicotómica:

$$\begin{aligned} EMg_j &= P(y = 1|\mathbf{x}_i, x_j = 1) - P(y = 1|\mathbf{x}_i, x_j = 0) \\ &= G(\mathbf{x}_i\boldsymbol{\beta}|x_j = 1) - G(\mathbf{x}_i\boldsymbol{\beta}|x_j = 0) \\ &= G(\beta_1 + x_2\beta_2 + \dots + \beta_j + \dots + x_K\beta_K) \\ &\quad - G(\beta_1 + x_2\beta_2 + \dots + 0 + \dots + x_K\beta_K) \end{aligned}$$

Estimación

Supongamos n observaciones de una variable aleatoria o una muestra de variables independientes e idénticamente distribuidas. En estos casos, la función de densidad para cada y_i , $i = 1, 2, \dots, n$, estará dada por:

$$f(y_i|\mathbf{x}_i; \boldsymbol{\beta}) = [G(\mathbf{x}_i\boldsymbol{\beta})]^{y_i} [1 - G(\mathbf{x}_i\boldsymbol{\beta})]^{1-y_i}, \text{ donde } y_i = 0, 1$$

En estos términos, la función de verosimilitud estará dada por:

$$\begin{aligned} L(\boldsymbol{\beta}) &= \prod_{i=1}^n f(y_i|\mathbf{x}_i; \boldsymbol{\beta}) \\ &= \prod_{i=1}^n [G(\mathbf{x}_i\boldsymbol{\beta})]^{y_i} [1 - G(\mathbf{x}_i\boldsymbol{\beta})]^{1-y_i} \end{aligned}$$

En versión logarítmica:

$$\begin{aligned} \ln L(\boldsymbol{\beta}) &= \sum_{i=1}^n \ln(f(y_i|\mathbf{x}_i; \boldsymbol{\beta})) \\ &= \sum_{i=1}^n y_i \ln[G(\mathbf{x}_i\boldsymbol{\beta})] + \sum_{i=1}^n (1 - y_i) \ln[1 - G(\mathbf{x}_i\boldsymbol{\beta})] \end{aligned}$$

Las condiciones de primer orden serán:

$$\frac{\partial}{\partial \boldsymbol{\beta}} \ln L(\boldsymbol{\beta}) = \sum_{i=1}^n y_i \frac{g(\mathbf{x}_i\boldsymbol{\beta})}{G(\mathbf{x}_i\boldsymbol{\beta})} \mathbf{x}_i' - \sum_{i=1}^n (1 - y_i) \frac{g(\mathbf{x}_i\boldsymbol{\beta})}{1 - G(\mathbf{x}_i\boldsymbol{\beta})} \mathbf{x}_i'$$

Finalmente, las condiciones de segundo orden y varianza estará dada por:

$$\begin{aligned} \frac{\partial^2}{\partial \boldsymbol{\beta} \partial \boldsymbol{\beta}'} \ln L(\boldsymbol{\beta}) &= - \sum_{i=1}^n \frac{y_i g(\mathbf{x}_i\boldsymbol{\beta})^2}{G(\mathbf{x}_i\boldsymbol{\beta}) [1 - G(\mathbf{x}_i\boldsymbol{\beta})]} \mathbf{x}_i' \mathbf{x}_i \\ &= H(\boldsymbol{\beta}) \end{aligned}$$

Por lo tanto:

$$\begin{aligned} \text{Var}(\hat{\boldsymbol{\beta}}) &= [-\mathbb{E}[H(\boldsymbol{\beta})]]^{-1} \\ &= \left[\sum_{i=1}^n \frac{y_i g(\mathbf{x}_i\boldsymbol{\beta})^2}{G(\mathbf{x}_i\boldsymbol{\beta}) [1 - G(\mathbf{x}_i\boldsymbol{\beta})]} \mathbf{x}_i' \mathbf{x}_i \right]^{-1} \end{aligned}$$

12.5.2. Modelos de respuesta multinomial y ordenada

En esta sección, analizaremos modelos de respuesta discreta con más de 2 resultados posibles, los cuales se dividen en:

1. Modelos de respuesta multinomial (o no ordenada): son modelos conocidos como de respuesta nominal, donde los valores de los distintos resultados son arbitrarios y no tienen un efecto en la estimación. Ejemplos de estos modelos son casos de selección de seguro, lugar de hospedaje, clasificación de correos o documentos, etc.
2. Modelos de respuesta ordenada: en estos modelos se asigna a cada nivel o tipo de respuesta un valor no arbitrario. Por ejemplo, modelos de calificación de crédito, modelos de preferencia de bienes, clasificación de respuestas abiertas en encuestas, etc.

Modelos de respuesta multinomial

Logit multinomial

Este primer modelo aplica en situaciones en las que la unidad de respuesta o elección depende de las características individuales de los elementos de la muestra, pero no de los atributos de la elección.

Dado lo anterior, definiremos el modelo en términos de variables aleatorias que representan a la población subyacente. Sea y_i una variable aleatoria que toma valores en un conjunto $\{0, 1, 2, \dots, J\}$. Sea $\mathbf{x}_i$ un conjunto de valores o regresores para $i = 1, 2, \dots, n$.

Como en el modelo de respuesta binaria, estimaremos el efecto de una variable en la probabilidad de ocurrencia de uno de los valores de respuesta. Dichas variables de respuesta estarán dados por:

$$P(y_i = j | \mathbf{x}_i), \text{ para } j = 1, 2, \dots, J$$

Dado que la suma de probabilidades debe ser 1, se suele tomar como práctica estimar $P(y_i = 0 | \mathbf{x}_i)$ como diferencia del resto de los casos $j = \{1, 2, \dots, J\}$. Así, sea $\mathbf{x}_i$ un vector de dimensión $1 \times K$. De esta forma, el modelo Logit tendrá como probabilidad de cada una de las respuestas a:

$$P(y_i = j | \mathbf{x}_i) = \frac{e^{\mathbf{x}_i \beta_j}}{1 + e^{\mathbf{x}_i \beta_1} + e^{\mathbf{x}_i \beta_2} + \dots + e^{\mathbf{x}_i \beta_J}}$$

Donde cada una de las β_j , $j = 1, \dots, J$ es de dimensión $K \times 1$. A esta forma funcional de probabilidad también se le conoce como función *softmax*. Es facil observar que si la suma de probabilidades es 1, entonces, la probabilidad de $y = 0|\mathbf{x}_i$ estará dada por:

$$\begin{aligned} P(y_i = 0|\mathbf{x}_i) &= \frac{e^0}{1 + e^{\mathbf{x}_i\beta_1} + e^{\mathbf{x}_i\beta_2} + \dots + e^{\mathbf{x}_i\beta_J}} \\ &= \frac{1}{1 + e^{\mathbf{x}_i\beta_1} + e^{\mathbf{x}_i\beta_2} + \dots + e^{\mathbf{x}_i\beta_J}} \end{aligned}$$

De esta forma, tenemos:

$$\begin{aligned} 1 &= \sum_{j=0}^J P(y_i = j|\mathbf{x}_i) \\ &= \frac{1}{1 + e^{\mathbf{x}_i\beta_1} + e^{\mathbf{x}_i\beta_2} + \dots + e^{\mathbf{x}_i\beta_J}} \\ &\quad + \frac{e^{\mathbf{x}_i\beta_1}}{1 + e^{\mathbf{x}_i\beta_1} + e^{\mathbf{x}_i\beta_2} + \dots + e^{\mathbf{x}_i\beta_J}} \\ &\quad + \dots + \\ &\quad + \frac{e^{\mathbf{x}_i\beta_J}}{1 + e^{\mathbf{x}_i\beta_1} + e^{\mathbf{x}_i\beta_2} + \dots + e^{\mathbf{x}_i\beta_J}} \end{aligned}$$

Para el proceso de estimación, consideraremos la función de verosimilitud dada por:

$$\begin{aligned} L(\beta_1, \beta_2, \dots, \beta_J) &= \prod_{i=1}^n [(P(j = 0|\mathbf{x}_i))^{I(0)} \cdot (P(j = 1|\mathbf{x}_i))^{I(1)} \\ &\quad \dots (P(j = J|\mathbf{x}_i))^{I(J)}] \end{aligned}$$

Donde $I(j)$ es la función indicadora que toma el valor de 1 o 0 dependiendo de cual de las opciones posibles $j = 0, 1, 2, \dots, J$ es cierta para cada individuo $i = 1, 2, \dots, n$. De forma similar al caso de respuesta binaria en los modelos Logit Multinomiales se interpretan en sus efectos marginales y no de forma directa en los coeficientes β_j .

Para una variable x_{ik} continua y para cada opción $j = 0, 1, 2, \dots, J$ el efecto marginal será:

$$\begin{aligned} EMg_k &= \frac{\partial P(y_i = j|\mathbf{x}_i)}{\partial x_{ik}} \\ &= P(y_i = j|\mathbf{x}_i) \cdot \left[\beta_{jk} - \frac{\sum_{h=1}^J \beta_{hk} \cdot e^{\mathbf{x}_i\beta_h}}{1 + e^{\mathbf{x}_i\beta_1} + e^{\mathbf{x}_i\beta_2} + \dots + e^{\mathbf{x}_i\beta_J}} \right] \end{aligned}$$

Donde β_{hk} es el k -ésimo elemento del vector β_h . En el caso de que x_{ik} se una variable dicotómica (o categórica) y para cada opción $j = 0, 1, 2, \dots, J$ el efecto marginal será:

$$EMg_k = P(y_i = j | \mathbf{x}_i, x_{ik} = 1) - P(y_i = j | \mathbf{x}_i, x_{ik} = 0)$$

Modelos de respuesta ordenada: Logit y Probit Ordinal

Sea y_i una variable que representa una respuesta ordenada que toma los valores de $\{0, 1, 2, \dots, J\}$. En estos casos, en que importa el orden de la respuesta, existen dos mecanismos de estimación: el Modelo Probit y el Modelo Logit.

Modelo Probit Ordinal. Este modelo se puede derivar de forma similar al modelo probit de dos respuestas 0 y 1, probit binario. Así, partimos de una variable latente y_i^* definida como:

$$y_i^* = \mathbf{x}_i \beta + \varepsilon_i; \quad \varepsilon_i \sim N(0, 1)$$

Donde β es un vector $(K - 1) \times 1$ ya que en este caso asumiremos que no se considera un término constante, por las razones que mostramos más adelante. Sean $\alpha_1, \alpha_2, \dots, \alpha_J$ un conjunto de umbrales que particionan la probabilidad de la siguiente forma:

$$\begin{aligned} y_i = 0 & \quad \text{si} \quad y_i^* \leq \alpha_1 \\ y_i = 1 & \quad \text{si} \quad \alpha_1 < y_i^* \leq \alpha_2 \\ & \quad \vdots \\ y_i = j & \quad \text{si} \quad \alpha_j < y_i^* \leq \alpha_{j+1} \\ & \quad \vdots \\ y_i = J & \quad \text{si} \quad \alpha_J < y_i^* \end{aligned}$$

Dado que ε_i tiene una distribución normal estándar, para cada uno de

los casos anteriores podemos establecer:

$$\begin{aligned}
P(y_i = 0|\mathbf{x}_i) &= P(y_i^* \leq \alpha_1|\mathbf{x}_i) = P(\mathbf{x}_i\boldsymbol{\beta} + \boldsymbol{\varepsilon}_i \leq \alpha_1|\mathbf{x}_i) \\
P(y_i = 1|\mathbf{x}_i) &= P(\alpha_1 < y_i^* \leq \alpha_2|\mathbf{x}_i) = P(\alpha_1 < \mathbf{x}_i\boldsymbol{\beta} + \boldsymbol{\varepsilon}_i \leq \alpha_2|\mathbf{x}_i) \\
&\vdots \\
P(y_i = j|\mathbf{x}_i) &= P(\alpha_j < y_i^* \leq \alpha_{j+1}|\mathbf{x}_i) = P(\alpha_j < \mathbf{x}_i\boldsymbol{\beta} + \boldsymbol{\varepsilon}_i \leq \alpha_{j+1}|\mathbf{x}_i) \\
&\vdots \\
P(y_i = J|\mathbf{x}_i) &= P(\alpha_J < y_i^*|\mathbf{x}_i) = P(\alpha_J < \mathbf{x}_i\boldsymbol{\beta} + \boldsymbol{\varepsilon}_i|\mathbf{x}_i)
\end{aligned}$$

Desarrollando las ecuaciones anteriores, tenemos para el caso de $y_i = 0$:

$$\begin{aligned}
P(y_i = 0|\mathbf{x}_i) &= P(\mathbf{x}_i\boldsymbol{\beta} + \boldsymbol{\varepsilon}_i \leq \alpha_1|\mathbf{x}_i) \\
&= P(\boldsymbol{\varepsilon}_i \leq \alpha_1 - \mathbf{x}_i\boldsymbol{\beta}|\mathbf{x}_i) \\
&= \Phi(\alpha_1 - \mathbf{x}_i\boldsymbol{\beta})
\end{aligned}$$

En el caso de $y_i = j$, $j = 1, 2, \dots, J - 1$:

$$\begin{aligned}
P(y_i = j|\mathbf{x}_i) &= P(\alpha_j < \mathbf{x}_i\boldsymbol{\beta} + \boldsymbol{\varepsilon}_i \leq \alpha_{j+1}|\mathbf{x}_i) \\
&= P(\alpha_j - \mathbf{x}_i\boldsymbol{\beta} < \boldsymbol{\varepsilon}_i \leq \alpha_{j+1} - \mathbf{x}_i\boldsymbol{\beta}|\mathbf{x}_i) \\
&= P(\boldsymbol{\varepsilon}_i \leq \alpha_{j+1} - \mathbf{x}_i\boldsymbol{\beta}|\mathbf{x}_i) - P(\boldsymbol{\varepsilon}_i < \alpha_j - \mathbf{x}_i\boldsymbol{\beta}|\mathbf{x}_i) \\
&= \Phi(\alpha_{j+1} - \mathbf{x}_i\boldsymbol{\beta}) - \Phi(\alpha_j - \mathbf{x}_i\boldsymbol{\beta})
\end{aligned}$$

Finalmente, para el caso $y_i = J$:

$$\begin{aligned}
P(y_i = J|\mathbf{x}_i) &= P(\alpha_J < \mathbf{x}_i\boldsymbol{\beta} + \boldsymbol{\varepsilon}_i|\mathbf{x}_i) \\
&= P(\alpha_J - \mathbf{x}_i\boldsymbol{\beta} < \boldsymbol{\varepsilon}_i|\mathbf{x}_i) \\
&= 1 - P(\boldsymbol{\varepsilon}_i < \alpha_J - \mathbf{x}_i\boldsymbol{\beta}|\mathbf{x}_i) \\
&= 1 - \Phi(\alpha_J - \mathbf{x}_i\boldsymbol{\beta})
\end{aligned}$$

Es sencillo observar y analizar que:

$$1 = \sum_{j=0}^J P(y_i = j|\mathbf{x}_i)$$

Notemos que en este modelo los cambios en la probabilidad no serán determinados por $\mathbf{x}_i$, ya que lo que determina el cambio es el umbral α_j ,

$j = 0, 1, \dots, J$. También en este caso los coeficientes no se interpretan de forma directa, en cambio se utiliza el efecto marginal que tiene expresiones similares al del probit bivariado como más adelante mostraremos.

Modelo Logit Ordinal. Este modelo se puede derivar de forma similar al modelo Probit Ordinal con una variable latente y_i^* , también con $\boldsymbol{\beta}$ es un vector $(K - 1) \times 1$ ya que en este caso asumiremos que no se considera un término constante, por las razones que hemos mostrado anteriormente. Igualmente, sean $\alpha_1, \alpha_2, \dots, \alpha_J$ un conjunto de umbrales que particionan la probabilidad considerando una función logística $\Lambda(\cdot)$ de la siguiente forma:

$$\varepsilon_i \sim \Lambda(\cdot)$$

$$P(y_i = J | \mathbf{x}_i) = P(\alpha_J < y_i^* | \mathbf{x}_i) = P(\alpha_J < \mathbf{x}_i \boldsymbol{\beta} + \varepsilon_i | \mathbf{x}_i)$$

Desarrollando las ecuaciones de probabilidad de forma similar al Probit Multinomial tenemos para el caso de $y_i = 0$:

$$\begin{aligned} P(y_i = 0 | \mathbf{x}_i) &= P(y_i^* \leq \alpha_1 | \mathbf{x}_i) \\ &= P(\mathbf{x}_i \boldsymbol{\beta} + \varepsilon_i \leq \alpha_1 | \mathbf{x}_i) \\ &= P(\varepsilon_i \leq \alpha_1 - \mathbf{x}_i \boldsymbol{\beta} | \mathbf{x}_i) \\ &= \Lambda(\alpha_1 - \mathbf{x}_i \boldsymbol{\beta}) \end{aligned}$$

En el caso de $y_i = j$, $j = 1, 2, \dots, J - 1$:

$$\begin{aligned} P(y_i = j | \mathbf{x}_i) &= P(\alpha_j < y_i^* \leq \alpha_{j+1} | \mathbf{x}_i) \\ &= P(\alpha_j < \mathbf{x}_i \boldsymbol{\beta} + \varepsilon_i \leq \alpha_{j+1} | \mathbf{x}_i) \\ &= P(\alpha_j - \mathbf{x}_i \boldsymbol{\beta} < \varepsilon_i \leq \alpha_{j+1} - \mathbf{x}_i \boldsymbol{\beta} | \mathbf{x}_i) \\ &= P(\varepsilon_i \leq \alpha_{j+1} - \mathbf{x}_i \boldsymbol{\beta} | \mathbf{x}_i) - P(\varepsilon_i < \alpha_j - \mathbf{x}_i \boldsymbol{\beta} | \mathbf{x}_i) \\ &= \Lambda(\alpha_{j+1} - \mathbf{x}_i \boldsymbol{\beta}) - \Lambda(\alpha_j - \mathbf{x}_i \boldsymbol{\beta}) \end{aligned}$$

Finalmente, para el caso $y_i = J$:

$$\begin{aligned} P(y_i = J | \mathbf{x}_i) &= P(\alpha_J < y_i^* | \mathbf{x}_i) \\ &= P(\alpha_J < \mathbf{x}_i \boldsymbol{\beta} + \varepsilon_i | \mathbf{x}_i) \\ &= P(\alpha_J - \mathbf{x}_i \boldsymbol{\beta} < \varepsilon_i | \mathbf{x}_i) \\ &= 1 - P(\varepsilon_i < \alpha_J - \mathbf{x}_i \boldsymbol{\beta} | \mathbf{x}_i) \\ &= 1 - \Lambda(\alpha_J - \mathbf{x}_i \boldsymbol{\beta}) \end{aligned}$$

También, es sencillo observar y analizar que en los Logit Multinomiales:

$$1 = \sum_{j=0}^J P(y_i = j | \mathbf{x}_i)$$

Notemos que en este modelo los cambios en la probabilidad no serán determinados por $\mathbf{x}_i$, ya que lo que determina el cambio es el umbral α_j , $j = 0, 1, \dots, J$. También en este caso los coeficientes no se interpretan de forma directa, en cambio se utiliza el efecto marginal que tiene expresiones similares al del probit bivariado como más adelante mostraremos.

Estimación de modelos Probit y Logit Ordinal. Para la estimación implementaremos un proceso de maximización de la siguiente función de verosimilitud:

$$L(\alpha, \beta) = \prod_{i=1}^n P(y_i = 0 | \mathbf{x}_i)^{I(0)} \cdot P(y_i = 1 | \mathbf{x}_i)^{I(1)} \dots P(y_i = J | \mathbf{x}_i)^{I(J)}$$

Donde $I(j)$ es la función indicadora que toma el valor de 0 y 1 si el individuo i -ésimo tiene como respuesta alguno de los posibles valores de $j = 0, 1, \dots, J$. La función es válida sin importar la función $\Phi(\cdot)$ o $\Lambda(\cdot)$ que utilicemos para determinar la $P(y_i = j | \mathbf{x}_i)$, para $j = 1, 2, \dots, J$. Por lo cual simbolizaremos indistintamente estas funciones como $G(\cdot)$.

Finalmente, sin importar el modelo que estemos ocupando, Probit o Logit ordinal, la forma de interpretar el modelo es mediante el efecto marginal, cuando x_k sea una variable continua:

$$EMg_k = \frac{\partial}{\partial x_k} P(y_i = j | \mathbf{x}_i) = \frac{\partial}{\partial x_k} G(\alpha_j - \mathbf{x}_i \beta) = -\beta_k \cdot g(\alpha_j - \mathbf{x}_i \beta)$$

Por su parte, cuando x_j sea una variable dicotómica:

$$\begin{aligned} EMg_k &= P(y_i = j | \mathbf{x}_i, x_{ik} = 1) - P(y_i = j | \mathbf{x}_i, x_{ik} = 0) \\ &= G(\alpha_j - \mathbf{x}_i \beta | \mathbf{x}_i, x_{ik} = 1) - G(\alpha_j - \mathbf{x}_i \beta | \mathbf{x}_i, x_{ik} = 0) \\ &= G(\alpha_j - (\beta_1 + x_2 \beta_2 + \dots + \beta_k + \dots + x_K \beta_K)) \\ &\quad - G(\alpha_j - (\beta_1 + x_2 \beta_2 + \dots + 0 + \dots + x_K \beta_K)) \end{aligned}$$

También es posible hacer un efecto marginal intra respuestas, es decir, para cambios entre una respuesta j y una $j + h$, la cual será:

$$EMg_{j-h} = \beta_k \cdot [g(\alpha_h - \mathbf{x}_i \beta) - g(\alpha_j - \mathbf{x}_i \beta)], \text{ con } h < j$$

Donde $k = 1, 2, \dots, K - 1$ y $j = 0, 1, \dots, J$.



Figura 12.10: División del conjunto de datos, retomado de Hastie, Tibshirani, y Friedman (2017, p. 222) [HTF17]

Ajuste y separación del conjunto de datos

De forma similar al caso de regresión, dividiremos al conjunto de datos conforme se describe en la Figura 12.10.

Evaluando los modelos de aprendizaje supervisado

Matriz de confusión

Una vez que se entrena un problema de aprendizaje automatizado supervisado en un conjunto de datos históricos, se prueba el modelo obtenido mediante el uso de datos del conjunto de entrenamiento. De esta forma, es posible comparar las predicciones del modelo entrenado con los valores reales de la variable sujeta de análisis. La matriz de confusión proporciona un medio para evaluar el éxito de un problema de clasificación y dónde se cometen errores (es decir, dónde se vuelve 'confuso').

En el Cuadro 12.1 se muestra un ejemplo de la forma en que se suele mostrar una matriz de confusión.

		Predicciones	
		Positivas (1)	Negativas (0)
Real	Positivas (1)	True Positive (TP)	False Negative (FN)
	Negativas (0)	False Positive (FP)	True Negative (TN)

Cuadro 12.1: Matriz de Confusión

Con base en la matriz de confusión en el Cuadro 12.1, se pueden construir métricas que se calculan de la siguiente manera:

$$Precision = \frac{TP}{TP + FP} \quad (12.34)$$

$$Recuperacion = \frac{TP}{TP + FN} \quad (12.35)$$

$$F1 = 2 \times \frac{Precision \times Recuperacion}{Precision + Recuperacion} \quad (12.36)$$

La medida $F1$ o $F1 - score$ combina precisión y recuperación mediante la media armónica de los dos valores. De esta forma, siempre se ubicará entre ambos indicadores.

12.5.3. Regresión logística con información de videojuegos.

Planteamiento del caso

Supuestos y necesidades del caso:

1. Determinar cuáles son las features/características/steam tags que se asocian con videojuegos para PC exitosos.
2. Hay varias tiendas de videojuegos (Steam, itch, etc.) que utilizan estas tags para clasificar los video juegos.

Propuesta: Usar un modelo de respuesta ordenada

Sea y una variable que representa una respuesta ordenada que toma valores $\{0, 1, 2, \dots, J\} \in \mathbb{Z}$. El modelo de respuesta ordenada (conocido como Probit o Logit ordenado) para y (condicional en un vector de variables explicativas $\mathbf{X}$ —features, características, tags, etc.—) es derivado a partir de un modelo de variable latente y^* , el cual se puede escribir como:

$$y^* = \mathbf{X}\boldsymbol{\beta} + \varepsilon, \varepsilon|\mathbf{X} \sim f(\varepsilon) \quad (12.37)$$

Donde $f(\cdot)$ es una función de densidad de probabilidad simétrica cuya función de densidad acumulada será denotada por $F(\cdot)$, $\boldsymbol{\beta}$ es un vector de dimensión $K \times 1$ y, por razones que más adelante explicamos, $\mathbf{X}$ no tiene término constante. Por otro lado, sean $\mu_1 < \mu_2 < \dots < \mu_J$ puntos de corte o parámetros umbrales que definen lo siguiente:

$$\begin{aligned} y = 0 & \quad \text{si} \quad y^* \leq \mu_1 \\ y = 1 & \quad \text{si} \quad \mu_1 < y^* \leq \mu_2 \\ & \quad \vdots \\ y = J & \quad \text{si} \quad y^* > \mu_J \end{aligned} \quad (12.38)$$

De esta forma, y considerando el conjunto de desigualdades en la ecuación (12.38) y la ecuación (12.37), podemos determinar las siguientes probabilidades a partir de una partición de una función de distribución dada:

$$\begin{aligned}
\mathbf{P}(y = 0|\mathbf{X}) &= \mathbf{P}(y^* \leq \mu_1|\mathbf{X}) \\
&= \mathbf{P}(\mathbf{X}\boldsymbol{\beta} + \varepsilon \leq \mu_1|\mathbf{X}) \\
&= \mathbf{P}(\varepsilon \leq \mu_1 - \mathbf{X}\boldsymbol{\beta}|\mathbf{X}) \\
&= F(\mu_1 - \mathbf{X}\boldsymbol{\beta})
\end{aligned}$$

$$\begin{aligned}
\mathbf{P}(y = 1|\mathbf{X}) &= \mathbf{P}(\mu_1 < y^* \leq \mu_2|\mathbf{X}) \\
&= \mathbf{P}(\mu_1 < \mathbf{X}\boldsymbol{\beta} + \varepsilon \leq \mu_2|\mathbf{X}) \\
&= \mathbf{P}(\mu_1 - \mathbf{X}\boldsymbol{\beta} < \varepsilon \leq \mu_2 - \mathbf{X}\boldsymbol{\beta}|\mathbf{X}) \\
&= F(\mu_2 - \mathbf{X}\boldsymbol{\beta}) - F(\mu_1 - \mathbf{X}\boldsymbol{\beta})
\end{aligned}$$

$\vdots$

$$\begin{aligned}
\mathbf{P}(y = J - 1|\mathbf{X}) &= \mathbf{P}(\mu_{J-1} < y^* \leq \mu_J|\mathbf{X}) \\
&= \mathbf{P}(\mu_{J-1} < \mathbf{X}\boldsymbol{\beta} + \varepsilon \leq \mu_J|\mathbf{X}) \\
&= \mathbf{P}(\mu_{J-1} - \mathbf{X}\boldsymbol{\beta} < \varepsilon \leq \mu_J - \mathbf{X}\boldsymbol{\beta}|\mathbf{X}) \\
&= F(\mu_J - \mathbf{X}\boldsymbol{\beta}) - F(\mu_{J-1} - \mathbf{X}\boldsymbol{\beta})
\end{aligned}$$

$$\begin{aligned}
\mathbf{P}(y = J|\mathbf{X}) &= \mathbf{P}(y^* > \mu_J|\mathbf{X}) \\
&= \mathbf{P}(\mathbf{X}\boldsymbol{\beta} + \varepsilon > \mu_J|\mathbf{X}) \\
&= \mathbf{P}(\varepsilon > \mu_J - \mathbf{X}\boldsymbol{\beta}|\mathbf{X}) \\
&= 1 - F(\mu_J - \mathbf{X}\boldsymbol{\beta})
\end{aligned}$$

Note que en este caso asumimos que $\mathbf{X}$ no tiene término constante, ya que la incorporamos mediante los umbrales μ_j , $j = 1, 2, \dots, J$. Un caso particular de esta modelación son los modelos de clasificación binarios en los que $J = 1$. En la figura 12.11 ilustramos la partición de la función de densidad $f(\cdot)$ que resultaría de las ecuaciones anteriore.




Figura 12.11: Probabilidades en un modelo de respuesta ordenada, considerando $J = 4$ (retomado de Greene (2012, 788) [Gre12])

De esta manera, los resultados de la estimación se pueden interpretar a través de sus efectos marginales dados por:

$$\frac{\partial \mathbf{P}(y = j|\mathbf{X})}{\partial x_k} = -\beta_k(f(\mu_j - \mathbf{X}\beta) - f(\mu_{j-1} - \mathbf{X}\beta)) \text{ para } 0 < j < J \quad (12.39)$$

Así, este efecto se interpreta como la contribución que tiene la variable x_k a la probabilidad de que la variable y tome el valor de j

Aplicación al caso de videojuegos

En el caso de los videojuegos, podemos aplicar el modelo de respuesta ordenada asumiendo algunas cosas. Primero, F tendrá una forma de función logística, para facilitar el proceso computacional. Segundo, la variable y será particionada en rangos de ingresos obtenidos por los videojuegos en su primer año (y^*)–año de lanzamiento–, por ejemplo:

$$y^* = \mathbf{X}\beta + \varepsilon, \varepsilon|\mathbf{X} \sim f(\varepsilon)$$

Where y^* is the revenue per year, $\mathbf{X}$ are the characteristics and other variables of video games, β are the coefficients and ε is the error term.

$$\begin{aligned} y = 0 & \quad \text{if} \quad y^* \leq 1\text{M USD} \\ y = 1 & \quad \text{if} \quad 1 \text{ MM USD} < y^* \leq 5 \text{ MM USD} \\ y = 2 & \quad \text{if} \quad 5 \text{ MM USD} < y^* \leq 20 \text{ MM USD} \\ y = 3 & \quad \text{if} \quad y^* > 20 \text{ MM USD} \end{aligned}$$

$$\begin{aligned} \mathbf{P}(y = 0|\mathbf{X}) &= \mathbf{P}(y^* \leq \mu_1|\mathbf{X}) \\ &= \mathbf{P}(\mathbf{X}\beta + \varepsilon \leq \mu_1|\mathbf{X}) \\ &= \mathbf{P}(\varepsilon \leq \mu_1 - \mathbf{X}\beta|\mathbf{X}) \\ &= F(\mu_1 - \mathbf{X}\beta) \end{aligned}$$

$$\begin{aligned} \mathbf{P}(y = 1|\mathbf{X}) &= \mathbf{P}(\mu_1 < y^* \leq \mu_2|\mathbf{X}) \\ &= \mathbf{P}(\mu_1 < \mathbf{X}\beta + \varepsilon \leq \mu_2|\mathbf{X}) \\ &= \mathbf{P}(\mu_1 - \mathbf{X}\beta < \varepsilon \leq \mu_2 - \mathbf{X}\beta|\mathbf{X}) \\ &= F(\mu_2 - \mathbf{X}\beta) - F(\mu_1 - \mathbf{X}\beta) \end{aligned}$$

$$\begin{aligned}
\mathbf{P}(y = 2|\mathbf{X}) &= \mathbf{P}(\mu_2 < y^* \leq \mu_3|\mathbf{X}) \\
&= \mathbf{P}(\mu_2 < \mathbf{X}\boldsymbol{\beta} + \varepsilon \leq \mu_3|\mathbf{X}) \\
&= \mathbf{P}(\mu_2 - \mathbf{X}\boldsymbol{\beta} < \varepsilon \leq \mu_3 - \mathbf{X}\boldsymbol{\beta}|\mathbf{X}) \\
&= F(\mu_3 - \mathbf{X}\boldsymbol{\beta}) - F(\mu_2 - \mathbf{X}\boldsymbol{\beta})
\end{aligned}$$

$$\begin{aligned}
\mathbf{P}(y = 3|\mathbf{X}) &= \mathbf{P}(y^* > \mu_3|\mathbf{X}) \\
&= \mathbf{P}(\mathbf{X}\boldsymbol{\beta} + \varepsilon > \mu_3|\mathbf{X}) \\
&= \mathbf{P}(\varepsilon > \mu_3 - \mathbf{X}\boldsymbol{\beta}|\mathbf{X}) \\
&= 1 - F(\mu_3 - \mathbf{X}\boldsymbol{\beta})
\end{aligned}$$

$$\mathbf{P}(y = 0|\mathbf{X}) = \mu_1 - \mathbf{X}\boldsymbol{\beta}$$

$$\mathbf{P}(y = 1|\mathbf{X}) = \mu_2 - \mathbf{X}\boldsymbol{\beta}$$

$$\mathbf{P}(y = 2|\mathbf{X}) = \mu_3 - \mathbf{X}\boldsymbol{\beta}$$

ε

Supongamos que tenemos n observaciones o, en este caso, videojuegos, los cuales son indexados con $i = 1, 2, 3, \dots, n$. Así, indexaremos a la variable de respuesta y como y_i , por lo que diremos que buscamos estimar las siguientes probabilidades:

$$\begin{aligned}
\mathbf{P}(\text{Revenue}_i \leq 1\text{M USD}|\mathbf{X}_i) &= \mathbf{P}(\varepsilon_i \leq \mu_1 - \mathbf{X}_i\boldsymbol{\beta}|\mathbf{X}_i) \\
&= F(\mu_1 - \mathbf{X}_i\boldsymbol{\beta})
\end{aligned}$$

$$\begin{aligned}
\mathbf{P}(1 \text{ MM USD} < \text{Revenue}_i \leq 5 \text{ MM USD}|\mathbf{X}_i) &= \mathbf{P}(\mu_1 - \mathbf{X}_i\boldsymbol{\beta} < \varepsilon_i \leq \mu_2 - \mathbf{X}_i\boldsymbol{\beta}|\mathbf{X}_i) \\
&= F(\mu_2 - \mathbf{X}_i\boldsymbol{\beta}) - F(\mu_1 - \mathbf{X}_i\boldsymbol{\beta})
\end{aligned}$$

$$\begin{aligned}
\mathbf{P}(5 \text{ MM USD} < \text{Revenue}_i \leq 20 \text{ MM USD} | \mathbf{X}_i) &= \mathbf{P}(\mu_2 - \mathbf{X}_i \boldsymbol{\beta} < \varepsilon_i \leq \mu_3 - \mathbf{X}_i \boldsymbol{\beta} | \mathbf{X}_i) \\
&= F(\mu_3 - \mathbf{X}_i \boldsymbol{\beta}) - F(\mu_2 - \mathbf{X}_i \boldsymbol{\beta})
\end{aligned}$$

$$\begin{aligned}
\mathbf{P}(\text{Revenue}_i > 20 \text{ MM USD} | \mathbf{X}_i) &= \mathbf{P}(\varepsilon_i > \mu_3 - \mathbf{X}_i \boldsymbol{\beta} | \mathbf{X}_i) \\
&= 1 - F(\mu_3 - \mathbf{X}_i \boldsymbol{\beta})
\end{aligned}$$

Donde, particularmente, F es una función logística. Nuestro objetivo es maximizar la función de verosimilitud (función que maximiza el valor de los parámetros μ_1 , μ_2 , μ_3 y $\boldsymbol{\beta}$ dada la información disponible):

$$\begin{aligned}
\mathbf{L}(\boldsymbol{\theta} | \text{Data}) &= \prod_{y_i=0} \mathbf{P}(\text{Revenue}_i \leq 1 \text{M USD} | \mathbf{X}_i) \\
&\times \prod_{y_i=1} \mathbf{P}(1 \text{ MM USD} < \text{Revenue}_i \leq 5 \text{ MM USD} | \mathbf{X}_i) \\
&\times \prod_{y_i=2} \mathbf{P}(5 \text{ MM USD} < \text{Revenue}_i \leq 20 \text{ MM USD} | \mathbf{X}_i) \\
&\times \prod_{y_i=3} \mathbf{P}(\text{Revenue}_i > 20 \text{ MM USD} | \mathbf{X}_i) \\
&= \prod_{y_i=0} (F(\mu_1 - \mathbf{X}_i \boldsymbol{\beta})) \times \prod_{y_i=1} (F(\mu_2 - \mathbf{X}_i \boldsymbol{\beta}) - F(\mu_1 - \mathbf{X}_i \boldsymbol{\beta})) \\
&\times \prod_{y_i=2} (F(\mu_3 - \mathbf{X}_i \boldsymbol{\beta}) - F(\mu_2 - \mathbf{X}_i \boldsymbol{\beta})) \times \prod_{y_i=3} (1 - F(\mu_3 - \mathbf{X}_i \boldsymbol{\beta}))
\end{aligned}$$

Donde:

$$\boldsymbol{\theta} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \\ \boldsymbol{\beta} \end{bmatrix}$$

Así, el problema consiste en resolver:

$$\begin{aligned}
\max_{\theta} \mathbf{L}(\theta | \text{Data}) = & \prod_{\text{Revenue}_i \leq 1 \text{M USD}} (F(\mu_1 - \mathbf{X}_i \boldsymbol{\beta})) \\
& \times \prod_{1 \text{ MM USD} < \text{Revenue}_i \leq 5 \text{ MM USD} | \mathbf{X}_i} (F(\mu_2 - \mathbf{X}_i \boldsymbol{\beta}) - F(\mu_1 - \mathbf{X}_i \boldsymbol{\beta})) \\
& \times \prod_{5 \text{ MM USD} < \text{Revenue}_i \leq 20 \text{ MM USD}} (F(\mu_3 - \mathbf{X}_i \boldsymbol{\beta}) - F(\mu_2 - \mathbf{X}_i \boldsymbol{\beta})) \\
& \times \prod_{\text{Revenue}_i > 20 \text{ MM USD}} (1 - F(\mu_3 - \mathbf{X}_i \boldsymbol{\beta}))
\end{aligned}$$

Datos

Usamos como fuente: <https://games-stats.com/>, una descarga de datos de 2021. La tabla de datos originalmente descargada contenía información de 53,650 videojuegos para computadora de los últimos 40 años, acumulando 18.5 billones de dólares.

La tabla de datos de games-stats.com se utilizó como base de datos central debido a su tamaño y variables disponibles. Fue validado con otros datos encontrados en línea, y tenían un tamaño similar entre ellos. Se agregaron más variables con el propósito de enriquecer el análisis.

Hay una gran cantidad de etiquetas (tags) encontradas en la tabla de datos, por lo que resulta complicado clasificar un juego en una sola categoría. Sin embargo, el valor de la etiqueta radica en el hecho de que son los usuarios quienes etiquetan un juego. Esto nos dice cómo un usuario percibe un juego. En total ubicamos 417 tags distintas.

En este caso, queremos una reducción de dimensionalidad. El modelo debía evaluar más de 450 etiquetas diferentes, algo inviable. Tener 450 etiquetas para evaluar reduce la simplicidad e interpretabilidad del modelo. Así, aplicamos un par de metodologías:

- Extreme Random Decision Tree method: Que es una metodología de Machine Learning que ayudará a considerar menos variables dada la relevancia para los ingresos.
- Spearman Correlation: que muestra la correlación con los ingresos de determinadas variables y muestra también la significación estadística basada en una prueba t. Así, la etiqueta de un jugador tiene la correlación significativa más alta con los ingresos.

Tags	Jugos	Taps	Jugos	Taps	Jugos	Taps	Jugos	Taps	Jugos	Taps	
Indie	36,782	Combat	3,866	Multiple Endings	2,065	Historical	1,313	Magic	910	Demons	626
Action	25,650	Female Protagonist	3,857	Roguelike	2,054	Walking Simulator	1,312	Competitive	883	Deconstruction	616
Adventure	23,887	Violent	3,786	Puzzle Platformer	1,984	Resource Management	1,293	Tactical RPG	880	Strategy	604
Casual	23,618		3,677	War	1,994	Interactive Fiction	1,292	Aliens	880	Party Social	594
Strategy	23,397	Open World	3,604	Shoot 'em Up	1,933	Memes	1,252	Chick	872	Real-Time	582
Shooting	22,987	Isometric Combat	3,598	War	1,897	Dungeon Crawler	1,240	Heist	869	2D Fighting	589
Singleplayer	21,854	Visual Novel	3,502	Character Customization	1,813	Score Attack	1,229	Diving	862	Automobile Sim	589
Simulation	11,569	Comedy	3,398	Hard-Drawn	1,804	Dating Sim	1,225	Emotional	862	Match 3	581
RPG	11,097	Turn-Based	3,359	Old School	1,794	Survival	1,212	Fighting	857	Rhythm	571
3D	9,342	3D	3,342	Massively Multiplayer	1,786	Top-Down Shooter	1,212	Area Shooter	856	Modable	574
Multiplayer	8,185	Co-op	3,295	Procedural Generation	1,738	Experimental	1,204	Detective	846	Nonlinear	553
Atmospheric	8,137	Top-Down	3,289	Action RPG	1,735	Post-apocalyptic	1,201	Party	845	Modern	551
Early Access	7,650	Management	3,287	Turn-Based Strategy	1,734	18th	1,181	Shrubs	837	2D Platformer	543
Platformer	7,103	Third Person	3,240	Replay Value	1,706	RTS	1,157	Pierre Death	836	Disruption	541
Story Rich	7,111	Cartoon	3,210	Classic	1,672	Isometric	1,151	Immersive Sim	824	Parkour	539
3D	6,584	Gore	3,205	Local Co-Op	1,651	Sci-Fi	1,146	Investigation	820	Comic Book	534
Shooter	6,390	FPS	3,190	Online Co-Op	1,641	Dark Fantasy	1,139	Precision Platformer	816	Thriller	534
Pixel Graphics	6,174	Sports	3,243	Survival Horror	1,586	Education	1,127	Economy	809	Alternate History	515
Fantasy	5,950	Mystery	3,204	Hidden Object	1,597	Narration	1,125	Best 'em up	805	Critical Intelligence	496
Colorful	5,614	Click & Drag	3,171	Logic	1,586	1990's	1,112	NSFW	781	CPU	496
Arcade	5,564	Psychological	2,660	Mature	1,582	Dance	1,104	Time Management	782	Grand Strategy	489
Horror	5,504	Stylized	2,659	Magic	1,575	Text-Based	1,095	Chemical	767	Crime	487
Anime	5,424	Sci-Fi	2,611	Roguelike	1,558	Battle Building	1,089	Ones	728	Grid-Based Movement	487
Shooter	5,417	Minimalist	2,591	3D Platformer	1,539	Card Game	1,077	Metroidvania	727	Space Sim	481
First-Person	5,351	Physics	2,515	Future Sci-Fi	1,518	Abstract	1,072	Team-Based	726	Lore Rich	471
Funny	5,160	PVP	2,494	Fatals	1,480	Handmade	1,051	City Builder	718	Moose only	471
Soundtrack	4,484	Choices Matter	2,464	Turn-Based Combat	1,487	Fighting	1,033	Real Time Tactics	692	Supernatural	465
VR	4,862	Building	2,456	PVE	1,466	Third Person Shooter	1,029	Strategy RPG	696	MMORPG	454
Exploration	4,486	Sandbox	2,415	Crafting	1,451	4 Player Local	1,005	Lot	677	Active	451
Shooter	4,274	Cartoon	2,389	Bullet Hell	1,447	Tower Defense	997	Snake-like	672	Snake-like	451
Sci-Fi	4,601	2D Platformer	2,378	Short	1,428	2D	952	Character Action Game	669	Trading	448
Great Soundtrack	4,586	Psychological Horror	2,329	Memorable	1,424	Cyberpunk	986	2D Side Shooter	662	Split Screen	429
Free to Play	4,473	Tactical	2,317	RPG	1,396	Military	979	Conversion	657	Dark Comedy	421
Difficult	4,446	Side Scroller	2,243	Remorse	1,371	Robots	963	Tabletop	650	Open World Survival Craft	420
Survival	4,410	Realistic	2,220	Hack and Slash	1,365	Action Roguelike	942	Level Editor	651	Science	426
Family Friendly	4,231	Racing	2,138	Open Your Own Adventure	1,325	Immersive	934	Runner	647	Mythology	425
Shooter	3,940	Cartoon	2,148	Turn-Based Tactics	1,323	16-Bit Game Sim	916	Game Sim	641	Inventory Management	421
Relaxing	3,924	Local Multiplayer	2,136	RPG/Maker	1,317	LGBTQ+	913	Wargame	636	Philosophical	413

There are 417 tags in the database with a particular category for each one in which a game can be.

12.6. Modelos de árboles de decisión y bosques aleatorios.

En esta sección discutiremos los métodos basados en árboles para regresión y clasificación. Estos métodos implican estratificar o segmentar el espacio de los predictores en un número J de regiones. Podemos ver el ejemplo de la Figura 12.13.

Bases de los árboles de decisión. Estos pueden aplicar a casos de regresión y clasificación. Una forma simple de verlo es como se muestra en la Figura 12.13 muestra el proceso de segmentación a través de un árbol.

1. Dividimos los predictores $(X_1, X_2, \dots, X_p)$ en J regiones distinguibles, que denominamos $R_1, R_2, \dots, R_J$.




FIGURE 8.2. The three-region partition for the **Hitters** data set from the regression tree illustrated in Figure 8.1.

Figura 12.13: Ejemplo de regiones. Retomado de Hastie et al (2017, 305)

2. Para cada observación i que se ubique dentro de cada región R_j hacemos la misma predicción, la cual puede ser simplemente la media de los valores de la variable explicada en el conjunto de entrenamiento.

Pero ¿cómo construimos las regiones? La respuesta es responder a encontrar el valor mínimo o minimizar la suma de errores al cuadrado (RSS, por sus siglas en inglés) dadas las $R_1, R_2, \dots, R_J$:

$$RSS = \sum_{j=1}^J \sum_{i \in R_j} (y_i - \hat{y}_{R_j})^2 \quad (12.40)$$

Donde $\hat{y}_{R_j}$ es la media de las observaciones o variable explicada de entrenamiento dentro de cada región j -ésima. La implementación se puede ver como el siguiente proceso de 'división binaria recursiva':

- Seleccionamos el predictor X_j que se parte en las regiones: $\{X | X_j < s\}$ y $\{X | X_j \geq s\}$
- Corremos este análisis para todos los predictores $X_1, X_2, \dots, X_p$ y para cada cuota s para cada predictor y región R_j .




Figura 12.14: Ejemplo de árbol. Retomado de Hastie et al (2017, 304)

12.7. Modelos de redes neuronales.

12.7.1. Introducción y Motivación

El procedimiento de estimación mediante redes neuronales es un método que puede ser usado tanto para clasificación como para predicción. En ocasiones, este es considerado como una caja negra en términos de la interpretación de los parámetros estimados.

Quizá la principal ventaja de este método es que tiene una amplia exactitud o capacidad predictiva. Por esta razón se suele considerar que las redes neuronales son una herramienta computacional fundamental.

Las redes neuronales (también denominadas redes neuronales artificiales) están basadas en el funcionamiento biológico del cerebro, donde las neuronas están interconectadas y aprenden de la experiencia.

El origen de la técnica se ubica en el trabajo de McCulloch - Pitts (1943), en el cual se propone un modelo simplificado de una neurona basada en el funcionamiento biológico de las neuronas con el objetivo de establecer un resultado en términos de una proposición lógica.

Su estructura soporta/captura relaciones altamente complejas entre las variables usadas como predictores y la variable objetivo o explicada. Situación que no siempre es posible con otros métodos.

El uso moderno de las redes neuronales es llamado aprendizaje profundo (deep learning), ya que las redes modernas son profundas (deep), es decir, que tienen múltiples capas ocultas.

12.7.2. Algunos conceptos relevantes

En comparación con un proceso de regresión, las redes neuronales no requieren que los usuarios/analistas determinen una forma funcional o forma específica de la relación entre los predictores y la variable objetivo. En cambio, las redes neuronales tratan de aproximar/inferir/determinar la relación a partir de los datos.

De hecho, la regresión lineal y logística son un caso particular de las redes neuronales en la que solo hay una capa que conjunta a los inputs y los outputs, y no hay capas ocultas. Las capas ocultas son aquellas que se ubican entre la capa de input y la capa de output. La Figura 12.15 ilustra esta estructura de capas.

Otros conceptos relevantes son los nodos input y output. Si tenemos p




Figura 12.15: Ejemplo de redes neuronales. Retomado de Shmueli et al (2019, 285) [Shm+19]

predictores, la capa de input usualmente incluía p -nodos. Así, las capas ocultas tienen como su input al output de la capa input, y así sucesivamente. **Unidades neuronales - neurona.** En su corazón, una unidad neuronal (neurona) toma la suma ponderada de sus inputs con un término adicional (término de sesgo), θ_j .

Dado un conjunto de inputs $\{x_1, x_2, \dots, x_p\}$, una unidad toma un conjunto de pesos $\theta_j, w_{1j}, w_{2j}, \dots, w_{pj}$. Para computar el output de una capa de nodos oculta calculamos la suma ponderada de los input y aplicamos una función de activación a ellos. Es decir, dado un conjunto de valores input $\{x_1, x_2, \dots, x_p\}$ calculamos el output del nodo $j = 1, 2, \dots, J$:

$$Z_j = \theta_j + \sum_{i=1}^p w_{ij}x_i = \theta_j + \mathbf{W}_j \cdot \mathbf{X} \quad (12.41)$$

Donde los pesos $\theta_j, w_{1j}, w_{2j}, \dots, w_{pj}$ se obtienen mediante el aprendizaje. Adicionalmente, θ_j también es conocido como el sesgo del nodo j , es una constante que controla el nivel de la contribución del nodo j .

Finalmente, aplicamos una función que denominaremos como función de activación para una unidad a . Así, podemos implementar una función de activación para el nodo j del cual obtenemos el output:

$$Output_j = a = f(Z_j) \quad (12.42)$$




Figure 7.1 The sigmoid function takes a real value and maps it to the range (0,1). It is nearly linear around 0 but outlier values get squashed toward 0 or 1.

Figura 12.16: Ejemplo de la función de activación Sigmoide. Retomado de Jurafsky, et al (2024, Cap. 7, p.2) [JM23]

Función que puede ser, por ejemplo, una función logística:

$$Output_j = f(\theta_j + \mathbf{W}_j \cdot \mathbf{X}) = \frac{1}{e^{-(\theta_j + \sum_{i=1}^p w_{ij}x_i)}} = \frac{1}{e^{-(\theta_j + \mathbf{W}_j \cdot \mathbf{X})}} \quad (12.43)$$

En este punto debemos observar que el proceso de determinación de los pesos $\theta_j, w_{1j}, w_{2j}, \dots, w_{pj}$ es iterativo y suele considerar como valores iniciales a valores pequeños aleatorios. Para simplificar asumiremos que el término de sesgo, θ_j , está contenido como uno de los predictores $\mathbf{X}$ y se determina como parte de los pesos $\mathbf{W}_j$, de esta forma:

$$Z_j = \sum_{i=0}^p w_{ij}x_i = \mathbf{W}_j \cdot \mathbf{X} \quad (12.44)$$

Donde, el predictor ubicado en la posición $i = 0$ será un uno 1.

En relación a la función de activación, en la práctica se suele hacer uso de 3:

1. Sigmoide, la cual se ilustra en la Figura 12.16.

$$y = \sigma(Z) = \frac{1}{1 + e^{-Z}} \quad (12.45)$$

2. tanh, la cual se ilustra en la Figura 12.17.

$$y = \tanh(Z) = \frac{e^Z - e^{-Z}}{e^Z + e^{-Z}} \quad (12.46)$$




Figure 7.3 The tanh and ReLU activation functions.

Figura 12.17: Ejemplo de la función de activación $\tanh$. Retomado de Jurafsky, et al (2024, Cap. 7, p.4) [JM23]

3. ReLU (Rectified Linear Unit), la cual se ilustra en la Figura 12.17.

$$y = \text{ReLU}(Z) = \max Z, 0 \quad (12.47)$$

Tomemos el siguiente ejemplo. Supongamos los valores para un nodo j :

$$\mathbf{W}_j = [0.5 \quad 0.2 \quad 0.3 \quad 0.9]$$

$$\mathbf{X} = \begin{bmatrix} 1 \\ 0.5 \\ 0.6 \\ 0.1 \end{bmatrix}$$

$$\begin{aligned} y &= \sigma(\mathbf{W}_j \cdot \mathbf{X}) \\ &= \frac{1}{1 + e^{-(\mathbf{W}_j \cdot \mathbf{X})}} \\ &= \frac{1}{1 + e^{-(0.5+0.2 \times 0.5+0.3 \times 0.6+0.9 \times 0.1)}} \\ &= \frac{1}{1 + e^{-(0.87)}} \\ &= 0.7 \end{aligned}$$




Figure 7.2 A neural unit, taking 3 inputs x_1 , x_2 , and x_3 (and a bias b that we represent as a weight for an input clamped at +1) and producing an output y . We include some convenient intermediate variables: the output of the summation, z , and the output of the sigmoid, a . In this case the output of the unit y is the same as a , but in deeper networks we'll reserve y to mean the final output of the entire network, leaving a as the activation of an individual node.

Figura 12.18: Ilustración de una unidad neuronal. Retomado de Jurafsky, et al (2024, Cap. 7, p.3) [JM23]




Figure 7.9 Replacing the bias node (shown in a) with x_0 (b).

Figura 12.19: Ilustración de una red neuronal con 1 capa oculta. Retomado de Jurafsky, et al (2024, Cap. 7, p.1) [JM23]

En terminos simples, este proceso aplica para cada uno de los casos en las Figuras 12.18 y 12.19.

Una unidad neuronal muy simple es conocida como el perceptron, el cual tiene como salida una respuesta binaria:

$$y = \begin{cases} 0 & \text{si } \mathbf{W}_j \cdot \mathbf{X} \leq 0 \\ 1 & \text{si } \mathbf{W}_j \cdot \mathbf{X} > 0 \end{cases} \quad (12.48)$$

12.7.3. Preprocesamiento de datos

Cuando usamos una función de activación logística las redes neuronales se desempeñan mejor cuando los predictores y la variable objetivo están en el intervalo $[0, 1]$; considerando:

$$X_{normalizada} = \frac{X - a}{b - a} \quad (12.49)$$

Donde $a = \min(X)$ y $b = \max(X)$.

Adicionalmente, existe una función de normalización de los valores contenidos en los vectores que se forman en cada nodo $Z_1, Z_2, \dots, Z_d$. Esta función es conocida como función Softmax:

$$Softmax(Z_j) = \frac{z_j}{\sum_{i=1}^d e^{z_i}} \quad (12.50)$$

Donde $1 \leq i \leq d$.

12.7.4. Entrenamiento del modelo

Entrenar un modelo significa estimar los pesos $\theta_j, w_{1j}, w_{2j}, \dots, w_{pj}$ que llevan al mejor resultado de predicción posible.

El mecanismo seguido para este proceso se le conoce como **back propagation**. Es el método más popular usado para determinar los pesos (aprender). Como su nombre lo indica, los errores son calculados en forma recursiva; iniciando en la última capa (la capa de output) y continuando con la previa hasta llegar a la capa de input.

El proceso de entrenamiento se puede pensar como los siguientes pasos:

1. Establecemos una función de pérdida que modele la distancia entre el output conseguido y el el objetivo. A esa función se le suele llamar **función de entropía cruzada**.

2. Para encontrar los parámetros que minimicen la función de pérdida, usaremos el algoritmo de optimización del gradiente descendiente.
3. Finalmente, implementamos un algoritmo de **backpropagation**.

Bibliografía

- [Aba21] Alberto Abadie. «Using synthetic controls: Feasibility, data requirements, and metodological aspects». En: *Journal of Econometric Literature* (2021).
- [Ada20] Christopher P. Adams. *Learning Microeconometrics with R*. Estados Unidos: CRC Press, 2020.
- [AI17] Susan Athey y Guido W. Imbens. «The State of Applied Econometrics: Causality and Policy Evaluation». En: *Journal of Economic Perspectives* 2 (2017), págs. 3-32.
- [CT05] Colin Cameron y Pravin K. Trivedi. *Microeconometrics: Methods and Applications*. Estados Unidos: Cambridge University Press, 2005.
- [Cha20] Mark Chang. *Artificial Intelligence for Drug Development, Precision Medicine, and Healthcare*. Estados Unidos: CRC Press Taylor & Francis Group, 2020.
- [Cun21] Scott Cunningham. *Causal inference: The mixtape*. Estados Unidos: Yale University Press, 2021.
- [Gre12] William Greene. *Econometric Analysis*. Estados Unidos: Prentice Hall, 2012.
- [HTF17] Trevor Hastie, Robert Tibshirani y Jerome Friedman. *The Elements of Statistical Learning. Data Mining, Inference, and Prediction*. LLC: Springer, 2017.
- [Jam+13] Gareth James et al. *An Introduction to Statistical Learning with Applications in R*. New York: Springer, 2013.
- [JM23] Dan Jurafsky y James H. Martin. *Speech and Language Processing*. New York: Stanford, 2023.

- [Rot+23] Jonathan Roth et al. «What's trending in difference-in-differences? A synthesis of the recent econometrics literature». En: *Journal of Econometrics* (2023).
- [Shm+19] Galit Shmueli et al. *Data Mining for Business Analytics: Concepts, Techniques and Applications in Python*. Estados Unidos: Wiley, 2019.
- [Woo10] Jeffrey M. Wooldridge. *Econometric Analysis of Cross Section and Panel Data*. Estados Unidos: The MIT Pres, 2010.

Apéndice A

Algunos resultados importantes